

MODELOS NO LINEALES - MÁS ALLÁ DE LA LINEALIDAD

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM
haydeeperuyero@unam.com*

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1



ENES
JURIQUILLA

1 Por qué ir más allá de la linealidad

2 Regresión polinomial

3 Regresión logística polinomial

POR QUÉ IR MÁS ALLA DE LA LINEALIDAD

El problema de la linealidad

A lo largo de un curso de regresión lineal se estudia el modelo

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon, \quad (1)$$

donde ε es un término de error aleatorio con $\mathbb{E}[\varepsilon \mid X] = 0$. Este modelo es atractivo porque:

- ▶ es fácil de ajustar (mínimos cuadrados ordinarios tiene solución cerrada),
- ▶ es fácil de interpretar (β_j es el cambio esperado en Y ante un incremento unitario en X_j , manteniendo lo demás fijo),
- ▶ posee una teoría de inferencia (errores estándar, pruebas t y F , intervalos de confianza) muy bien desarrollada.

El problema de la linealidad

Sin embargo, la hipótesis de linealidad es, casi siempre, una **aproximación conveniente** y no una verdad sobre el fenómeno que se modela.

Cuando la verdadera relación f entre X y Y es curva, el modelo lineal produce un sesgo sistemático: subestima Y en algunas regiones del espacio de predictores y lo sobreestima en otras.

Ejemplo: Salario en función de la edad

El conjunto de datos Wage, incluido en el paquete ISLP, contiene información sobre los salarios y características demográficas de trabajadores de la región del Atlántico medio de Estados Unidos.

Cada observación corresponde a un trabajador e incluye, entre otras variables:

- ▶ wage: salario del trabajador, que utilizaremos como variable respuesta;
- ▶ age: edad del trabajador;
- ▶ year: año en que se registró la observación;
- ▶ education: nivel educativo.

Vamos a ocupar estos datos para estudiar distintas formas de modelar relaciones **no lineales**.

Ejemplo: salario y edad

Al explorar la relación entre age y wage, observamos que el salario no parece cambiar linealmente con la edad.

- ▶ En edades tempranas, el salario tiende a aumentar con la edad.
- ▶ Este crecimiento se desacelera en edades intermedias.
- ▶ Para edades mayores, la tendencia puede incluso disminuir.


Por lo tanto, una relación de la forma

$$\text{wage} = \beta_0 + \beta_1 \text{age} + \varepsilon$$

puede resultar demasiado restrictiva.

¿Cómo podemos permitir que la relación entre edad y salario sea curva?

Ejemplo




Ejemplo: Salario en función de la edad

Una recta no puede capturar esta forma de “joroba”; se requiere una función más flexible, por ejemplo, un polinomio de grado 2, 3 o 4 en la variable age.

Ejemplo

Salario en función de la edad (ajuste polinómico grado 4)




La estrategia de esta unidad

Todos los métodos que se estudiarán en comparten una misma filosofía: en lugar de ajustar Y directamente contra X , se ajusta Y contra un conjunto de **funciones de X construidas de antemano** (transformaciones, indicadoras de intervalos, funciones base tipo *spline*, pesos locales, etc.), de manera que el problema *siga siendo lineal en los parámetros* aunque la función resultante $\hat{f}(X)$ sea no lineal en X .

Importante

Esta es una idea profundamente importante en estadística: la linealidad del modelo se refiere a los **parámetros** β_j , no a la variable X .

Mapa general



REGRESIÓN POLINOMIAL

Regresión polinomial

En regresión lineal simple suponemos que

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

es decir, que la relación entre X y Y puede representarse mediante una recta.

Una forma sencilla de introducir **no linealidad** consiste en reemplazar esta recta por una función polinomial:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_d X^d + \varepsilon.$$

El grado d controla la **flexibilidad** del modelo:

- ▶ $d = 1$: relación lineal,
- ▶ $d = 2$: relación cuadrática,
- ▶ $d = 3$: relación cúbica,
- ▶ grados mayores permiten relaciones cada vez más flexibles.

Definición: Regresión polinomial

Una **regresión polinomial de grado** d tiene la forma

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_d X^d + \varepsilon.$$

Si definimos nuevos predictores

$$X_1 = X, \quad X_2 = X^2, \quad \dots, \quad X_d = X^d,$$

podemos escribir

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_d X_d + \varepsilon.$$

Por tanto, aunque el modelo es **no lineal en** X , sigue siendo **lineal en los parámetros** $\beta_0, \dots, \beta_d$.

¡Podemos ajustarlo utilizando regresión lineal ordinaria!

Recordatorio. En regresión lineal estimamos los parámetros minimizando la suma de cuadrados de los residuos (residual sum of squares):

$$RSS(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^d \beta_j x_i^j \right)^2 .$$

Ejercicio

1. ¿Cómo podemos escribir este problema en forma matricial?
2. ¿Cuál es la matriz de diseño $\mathbf{X}$?
3. ¿Cuál es la solución de mínimos cuadrados?

Para una regresión polinomial de grado d , la matriz de diseño es

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^d \\ 1 & x_2 & x_2^2 & \cdots & x_2^d \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^d \end{pmatrix}.$$

Por tanto,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

y el estimador de mínimos cuadrados es

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Es exactamente el mismo procedimiento que en regresión lineal múltiple: las columnas $X, X^2, \dots, X^d$ se tratan simplemente como **predictores adicionales**.

¿Qué grado del polinomio utilizar?

Al aumentar el grado d , aumenta la flexibilidad del modelo.

- ▶ Un grado demasiado bajo puede producir **subajuste**.
- ▶ Un grado demasiado alto puede producir **sobreajuste** y predicciones inestables, especialmente cerca de los extremos.
- ▶ En la práctica, rara vez es necesario utilizar grados muy altos.

El grado d puede considerarse un **hiperparámetro** del modelo y seleccionarse, por ejemplo, mediante **validación cruzada**. Otro método es ajustar de forma sucesiva los modelos en orden creciente hasta que la prueba t para el término de orden máximo sea no significativa.

Mayor flexibilidad no implica necesariamente mejor capacidad predictiva.

Ejemplo: salario en función de la edad

Retomemos el conjunto de datos Wage. Lo que queremos modelar es la relación entre el salario y la edad mediante


$$\text{wage} = \beta_0 + \beta_1 \text{age} + \beta_2 \text{age}^2 + \cdots + \beta_d \text{age}^d + \varepsilon.$$

Para observar el efecto del grado d , podríamos ajustar modelos de regresión polinomial con

$$d = 1, \quad d = 2, \quad d = 3, \quad d = 4.$$

- ▶ ¿Cómo cambia la forma de la curva al aumentar d ?
- ▶ ¿Qué ganamos al aumentar la flexibilidad del modelo?

Regresión polinomial: distintos grados



Al aumentar el grado d , aumenta la flexibilidad del modelo.

COLINEALIDAD: ¿CUÁL ES EXACTAMENTE EL PROBLEMA?

Colinealidad: ¿cuál es exactamente el problema?

- La **colinealidad** ocurre cuando dos o más columnas de $\mathbf{X}$ son (casi) combinaciones lineales entre sí. Con $x, x^2, x^3, \dots$ esto es casi inevitable: si X toma valores en un rango angosto y alejado de cero (por ejemplo, edades entre 20 y 60), entonces x y x^2 están fuertemente correlacionadas.

Ejemplo

Si $x \in [20, 60]$, la correlación muestral entre x y x^2 suele superar 0.99. Geométricamente, los vectores columna $(x_1, \dots, x_n)$ y $(x_1^2, \dots, x_n^2)$ casi apuntan en la misma dirección en $\mathbb{R}^n$.

Colinealidad: ¿cuál es exactamente el problema?

- Formalmente, $\mathbf{X}^\top \mathbf{X}$ se vuelve **casi singular**: su determinante se acerca a cero y su **número de condición**

$$\kappa(\mathbf{X}^\top \mathbf{X}) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

(razón entre el mayor y el menor valor propio) se dispara. Un κ grande significa que pequeños errores de redondeo al invertir la matriz se amplifican enormemente.

Consecuencias prácticas de la colinealidad

- ▶ **Inestabilidad numérica:** al calcular $(\mathbf{X}^\top \mathbf{X})^{-1}$ en la computadora, errores de precisión de punto flotante (inevitables en cualquier software) pueden producir coeficientes $\hat{\beta}_j$ completamente distintos ante cambios mínimos en los datos, o incluso una matriz no invertible en la práctica.
- ▶ **Varianza inflada:** aunque $(\mathbf{X}^\top \mathbf{X})^{-1}$ exista, cuando las columnas están correlacionadas los elementos de la diagonal de $\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2(\mathbf{X}^\top \mathbf{X})^{-1}$ se vuelven muy grandes: los errores estándar de $\hat{\beta}_j$ crecen, y las pruebas t individuales pierden potencia (coeficientes “no significativos” aunque el modelo en conjunto sí sea útil).

Consecuencias prácticas de la colinealidad

- **Dificultad de interpretación:** con la base cruda $1, x, x^2, x^3, \dots$, el coeficiente $\hat{\beta}_2$ (asociado a x^2) no puede interpretarse aisladamente, porque x y x^2 comparten prácticamente la misma información.

Construcción de los polinomios ortogonales

Partimos de la base

$$1, x, x^2, \dots, x^d$$

y utilizamos el producto interno muestral

$$\langle f, g \rangle = \sum_{i=1}^n f(x_i)g(x_i).$$

- ▶ Aplicando el proceso de **Gram–Schmidt**, construimos polinomios $P_0, P_1, \dots, P_d$ tales que

$$\langle P_j, P_k \rangle = 0, \quad j \neq k.$$

- ▶ Por ejemplo,

$$P_0(x) = 1,$$
$$P_1(x) = x - \frac{\langle x, P_0 \rangle}{\langle P_0, P_0 \rangle} P_0(x),$$

- ▶ en general,

$$P_k(x) = x^k - \sum_{j=0}^{k-1} \frac{\langle x^k, P_j \rangle}{\langle P_j, P_j \rangle} P_j(x).$$

- ▶ Así, a x^k le quitamos las componentes que ya están representadas por los polinomios de menor grado.
- ▶ El resultado es una base diferente del **mismo espacio de polinomios de grado $\leq d$** .

Ejemplo

Supongamos $x = (-1, 0, 1)$ (tres puntos, por simplicidad).

Con el producto interno $\langle f, g \rangle = \sum_i f(x_i)g(x_i)$:

- ▶ $P_0(x) = 1$ para todo x (vector $(1, 1, 1)$).
- ▶ Para P_1 : partimos de $x = (-1, 0, 1)$. Como $\langle x, P_0 \rangle = -1 + 0 + 1 = 0$, ya resulta que x es ortogonal a P_0 ; así, $P_1(x) = x$ (vector $(-1, 0, 1)$).
- ▶ Para P_2 : partimos de $x^2 = (1, 0, 1)$. Su proyección sobre P_0 es $\frac{\langle x^2, P_0 \rangle}{\langle P_0, P_0 \rangle} P_0 = \frac{2}{3}(1, 1, 1)$; su proyección sobre P_1 es cero (por simetría). Entonces

$$P_2(x) = (1, 0, 1) - \frac{2}{3}(1, 1, 1) = \left(\frac{1}{3}, -\frac{2}{3}, \frac{1}{3}\right).$$

Ejercicio

Verificar que, en efecto, $\sum_i P_1(x_i)P_2(x_i) = 0$ y $\sum_i P_0(x_i)P_2(x_i) = 0$.

¿Por qué las predicciones no cambian?

- ▶ Tanto la base cruda $\{1, x, \dots, x^d\}$ como la base ortogonal $\{P_0, \dots, P_d\}$ **generan exactamente el mismo subespacio** de $\mathbb{R}^n$: todo polinomio de grado $\leq d$ evaluado en los datos puede escribirse como combinación lineal de cualquiera de las dos bases.
- ▶ El ajuste por mínimos cuadrados es, geométricamente, la **proyección ortogonal** del vector y sobre ese subespacio. La proyección ortogonal de un vector sobre un subespacio dado es **única**, sin importar qué base se use para describir ese subespacio.

¿Por qué las predicciones no cambian?

- En consecuencia: $\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ (base cruda) y $\hat{\mathbf{y}} = \mathbf{P}(\mathbf{P}^\top \mathbf{P})^{-1} \mathbf{P}^\top \mathbf{y}$ (base ortogonal, con $\mathbf{P}$ la matriz de diseño ortogonal) dan **exactamente el mismo vector $\hat{\mathbf{y}}$** . Solo cambian los coeficientes $\hat{\beta}_j$ individuales, no la curva ajustada $\hat{f}(x)$.

Ventaja adicional de la base ortogonal

Como $\mathbf{P}^\top \mathbf{P}$ es **diagonal** (por construcción, las columnas son ortogonales), su inversa es trivial: basta invertir cada entrada de la diagonal. Además, cada prueba t sobre $\hat{\beta}_j$ en esta base corresponde exactamente a la prueba F secuencial de agregar el término de grado j al modelo de grado $j - 1$, lo cual conecta directamente con la selección de grado por ANOVA que vimos antes.

Incertidumbre en la curva estimada

Una vez ajustado el modelo

$$\hat{f}(x) = \hat{\beta}_0 + \hat{\beta}_1 x + \cdots + \hat{\beta}_d x^d,$$

no sólo queremos estimar la relación entre X y Y , sino también **cuantificar la incertidumbre** de esa estimación.

Para un valor dado x_0 queremos estimar

$$f(x_0) = E[Y \mid X = x_0]$$

y construir un intervalo de confianza para este valor.

La curva $\hat{f}(x)$ es una estimación y, por tanto, también tiene incertidumbre.

Error estándar de $\hat{f}(x_0)$

Para un valor concreto x_0 ,

$$\hat{f}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \cdots + \hat{\beta}_d x_0^d.$$

Definimos

$$\ell(x_0) = (1, x_0, x_0^2, \dots, x_0^d)^\top,$$

de modo que

$$\hat{f}(x_0) = \ell(x_0)^\top \hat{\beta}.$$

Como

$$\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2 (\mathbf{X}^\top \mathbf{X})^{-1},$$

tenemos

$$\widehat{\text{Var}}(\hat{f}(x_0)) = \ell(x_0)^\top \widehat{\text{Var}}(\hat{\beta}) \ell(x_0).$$

Intervalos de confianza puntuales

Un intervalo de confianza al $(1 - \alpha)100\%$ para $f(x_0) = E[Y \mid X = x_0]$ es

$$\hat{f}(x_0) \pm t_{1-\alpha/2, n-d-1} \text{SE}\left(\hat{f}(x_0)\right),$$

donde

$$\text{SE}\left(\hat{f}(x_0)\right) = \sqrt{\widehat{\text{Var}}\left(\hat{f}(x_0)\right)}.$$

Al calcular estos intervalos para muchos valores de x_0 obtenemos visualmente una **banda alrededor de la curva estimada**.

Cada intervalo es válido para un x_0 individualmente; esto no constituye, en general, una banda de confianza simultánea.

Intervalo de confianza vs. intervalo de predicción

Para una edad específica x_0 podemos plantear dos preguntas diferentes:

Intervalo de confianza

¿Dónde está la media?

Queremos estimar

$$f(x_0) = E[Y \mid X = x_0].$$

El intervalo cuantifica la incertidumbre asociada a nuestra estimación $\hat{f}(x_0)$.

En el ejemplo de Wage:

¿Cuál es el **salario promedio** de los trabajadores de edad x_0 ?

Intervalo de predicción

¿Dónde caerá una nueva observación?

Queremos predecir

$$Y_{\text{nuevo}} \mid X = x_0.$$

debemos considerar la variabilidad individual alrededor de la media.

En el ejemplo de Wage:

¿Cuál podría ser el salario de **un nuevo trabajador** de edad x_0 ?

¿Por qué el intervalo de predicción es más ancho?

Nuestro modelo supone que

$$Y = f(X) + \varepsilon, \quad \text{Var}(\varepsilon) = \sigma^2.$$

Para estimar la **media** $f(x_0)$, la incertidumbre es

$$\widehat{\text{Var}}\left(\hat{f}(x_0)\right).$$

Por tanto, el intervalo de confianza tiene la forma

$$\hat{f}(x_0) \pm t_{1-\alpha/2, n-d-1} \sqrt{\widehat{\text{Var}}\left(\hat{f}(x_0)\right)}$$


¿Por qué el intervalo de predicción es más ancho?

En cambio, para predecir una **nueva observación**, debemos incorporar también la variabilidad del error ε :

$$\hat{f}(x_0) \pm t_{1-\alpha/2, n-d-1} \sqrt{\widehat{\text{Var}}(\hat{f}(x_0)) + \hat{\sigma}^2}$$

El intervalo de predicción siempre es más ancho que el intervalo de confianza para la media.

Ejemplo



REGRESIÓN LOGÍSTICA POLINOMIAL

Recordatorio: regresión logística

Cuando $Y \in \{0, 1\}$, la regresión logística modela la probabilidad

$$p(X) = P(Y = 1 \mid X).$$

Ejercicio

Recordemos:

1. ¿Cómo se relaciona $p(X)$ con los predictores?
2. ¿Qué son los *odds*?
3. ¿Qué es el *logit* o log-odds?

Recordatorio: regresión logística

Cuando $Y \in \{0, 1\}$, la regresión logística modela la probabilidad

$$p(X) = P(Y = 1 \mid X).$$

Ejercicio

Recordemos:

1. ¿Cómo se relaciona $p(X)$ con los predictores?
2. ¿Qué son los *odds*?
3. ¿Qué es el *logit* o log-odds?

En regresión logística simple suponemos que

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X.$$

Regresión logística polinomial

En regresión logística simple suponemos una relación **lineal** entre X y el log-odds:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X.$$

Si esta relación es demasiado restrictiva, podemos introducir **términos polinomiales**:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_d X^d$$

Regresión logística polinomial

Equivalentemente,

$$p(X) = \frac{\exp(\beta_0 + \beta_1 X + \cdots + \beta_d X^d)}{1 + \exp(\beta_0 + \beta_1 X + \cdots + \beta_d X^d)}.$$

o

$$\Pr(y_i = 1 \mid x_i) = \frac{\exp(\beta_0 + \beta_1 x_i + \cdots + \beta_d x_i^d)}{1 + \exp(\beta_0 + \beta_1 x_i + \cdots + \beta_d x_i^d)},$$

La idea es exactamente la misma que en regresión polinomial: ampliamos el conjunto de predictores a $X, X^2, \dots, X^d$.

Estimación

Los coeficientes $\beta_0, \dots, \beta_d$ se estiman, como en la regresión logística usual, mediante **máxima verosimilitud**.

Ejemplo: salarios altos

Retomemos nuevamente los datos Wage. Definimos una nueva variable respuesta binaria:

$$Y = \begin{cases} 1, & \text{si wage} > 250, \\ 0, & \text{si wage} \leq 250. \end{cases}$$

Ahora queremos modelar


$$P(\text{wage} > 250 \mid \text{age}).$$

Con un polinomio de grado d :

$$\log \left(\frac{P(\text{wage} > 250 \mid \text{age})}{1 - P(\text{wage} > 250 \mid \text{age})} \right) = \beta_0 + \beta_1 \text{age} + \cdots + \beta_d \text{age}^d.$$

¿La probabilidad de tener un salario alto cambia linealmente con la edad?

Probabilidad de un salario alto



La regresión logística polinomial permite que $P(\text{wage} > 250 \mid \text{age})$ varíe de forma no lineal con la edad.

Una misma idea, dos tipos de respuesta

Regresión polinomial

Respuesta continua:

$$Y \in \mathbb{R}$$

Modelamos la media de Y :

$$E[Y \mid X] = \beta_0 + \beta_1 X + \cdots + \beta_d X^d.$$

Ejemplo:

$$\text{wage} \sim \text{age}$$

Una misma idea, dos tipos de respuesta

Regresión logística polinomial

Respuesta binaria:

$$Y \in \{0, 1\}$$

Modelamos el log-odds:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X + \dots + \beta_d X^d.$$

Ejemplo:

$$I(\text{wage} > 250) \sim \text{age}$$

Una misma idea, dos tipos de respuesta

En ambos casos utilizamos la misma **expansión de la base**:

$$X \mapsto (X, X^2, \dots, X^d)$$

La idea es introducir flexibilidad transformando los predictores.

Idea central de la regresión polinomial

Idea central

La regresión polinomial resuelve el problema de la no linealidad **sin abandonar el marco lineal**: basta con ampliar la matriz de diseño con potencias del predictor. Esta misma receta, ampliar la matriz de diseño con funciones transformadas del predictor original, es la idea que unifica *toda* esta unidad : funciones escalón, splines y modelos aditivos generalizados son, en el fondo, distintas elecciones de qué funciones usar para ampliar $\mathbf{X}$.