

FUNCIONES ESCALONADAS

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM*

haydeeperuyero@unam.mx



ENES
JURIQUILLA

- ▶ La regresión polinomial impone una forma **global** sobre f : un solo polinomio debe describir la relación en todo el rango de X .
- ▶ Esto puede ser indeseable: cambios de comportamiento en una zona del predictor pueden “contaminar” el ajuste en zonas alejadas.
- ▶ Una alternativa es dividir el rango de X en intervalos y ajustar una constante distinta en cada uno.
- ▶ Convertimos una variable continua en una variable categórica ordenada.

Definición: Funciones escalón

Sean $c_1 < c_2 < \cdots < c_K$ puntos de corte (*cutpoints*) elegidos dentro del rango de X . Se definen $K + 1$ variables indicadoras (*dummy*):

$$\begin{aligned}C_0(X) &= \mathbf{1}(X < c_1), \\C_1(X) &= \mathbf{1}(c_1 \leq X < c_2), \\&\vdots \\C_K(X) &= \mathbf{1}(X \geq c_K),\end{aligned}$$

donde $\mathbf{1}(\cdot)$ es la función indicadora. Noten que $C_0(X) + C_1(X) + \cdots + C_K(X) = 1$ para todo X : exactamente una de estas variables vale 1. El modelo de regresión es

$$y_i = \beta_0 + \beta_1 C_1(x_i) + \beta_2 C_2(x_i) + \cdots + \beta_K C_K(x_i) + \varepsilon_i.$$

- ▶ Observemos que $C_0(X)$ se omite del modelo (queda absorbida en el intercepto β_0) para evitar colinealidad perfecta
- ▶ Estas variable se suelen llamar variables *dummy*.
- ▶ La interpretación es directa:
 - ▶ β_0 = valor esperado de Y para $X < c_1$ (categoría de referencia).
 - ▶ β_j ($j \geq 1$) = diferencia esperada en Y entre la categoría $[c_j, c_{j+1})$ y la categoría de referencia.

Naturaleza del ajuste

El modelo anterior es, de nuevo, un modelo **lineal** en los parámetros β_j : sólo cambiaron las columnas de la matriz de diseño, que ahora son indicadoras de pertenencia a un intervalo en lugar de potencias de X .

La función ajustada $\hat{f}(x)$ es una **función escalonada**: constante a trozos, con saltos exactamente en los puntos de corte $c_1, \dots, c_K$.

Ejemplo: funciones escalonadas en Wage

Consideremos los datos Wage y queremos modelar la relación entre el salario y la edad.

En lugar de suponer una relación lineal

$$E[Wage \mid Age = x] = \beta_0 + \beta_1 x,$$

dividimos la variable Age en cuatro intervalos utilizando **cuartiles**:

$$C_0, \quad C_1, \quad C_2, \quad C_3.$$

De esta manera, aproximadamente el 25% de las observaciones pertenece a cada grupo.

Ejemplo: funciones escalonadas en Wage

Tomamos C_0 como categoría de referencia y utilizamos las otras tres variables indicadoras. El modelo puede escribirse como

$$Wage_i = \beta_0 + \beta_1 C_1(Age_i) + \beta_2 C_2(Age_i) + \beta_3 C_3(Age_i) + \varepsilon_i.$$

Por tanto,

$$\beta_0 = E[Wage \mid Age \in C_0],$$

mientras que $\beta_1, \beta_2, \beta_3$ representan diferencias con respecto al grupo de referencia.

Dos parametrizaciones equivalentes

El modelo de referencia es:

$$Wage_i = \beta_0 + \beta_1 C_1(Age_i) + \cdots + \beta_K C_K(Age_i) + \varepsilon_i.$$

pero podemos usar alguna de las siguientes dos convenciones.

Dos opciones

Para una variable categórica con G grupos podemos utilizar:


1. un intercepto y $G - 1$ variables indicadoras;
2. G variables indicadoras y ningún intercepto.

Ambas parametrizaciones producen los **mismos valores ajustados**.

Si en el ejemplo de Wage utilizamos la segunda opción, tiene la interpretación especialmente sencilla:

$$\hat{\beta}_j = \text{salario promedio del grupo } j.$$

Ejemplo: salario como función escalonada de la edad



El modelo estima

$$\hat{f}(x) = \hat{E}[Wage \mid Age = x].$$

- ▶ Línea sólida: salario medio estimado.
- ▶ Líneas discontinuas: IC del 95% para la media.
- ▶ Cada escalón corresponde a un grupo de edad.

¿Qué está estimando realmente el modelo?

Con C_0 como categoría de referencia,

$$\hat{\mu}_0 = \hat{\beta}_0.$$

Para los demás grupos,

$$\hat{\mu}_1 = \hat{\beta}_0 + \hat{\beta}_1,$$

$$\hat{\mu}_2 = \hat{\beta}_0 + \hat{\beta}_2, \quad \hat{\mu}_3 = \hat{\beta}_0 + \hat{\beta}_3.$$

Por tanto,

$$\hat{\beta}_j = \hat{\mu}_j - \hat{\mu}_0, \quad j = 1, 2, 3.$$

¿Qué está estimando realmente el modelo?

Interpretación

El intercepto es la media del grupo de referencia y los demás coeficientes miden cuánto difiere cada grupo respecto a éste.

¿Y si eliminamos el intercepto?

Podemos escribir el mismo ajuste utilizando las cuatro variables indicadoras y eliminando el intercepto:

$$Wage_i = \gamma_1 C_1(Age_i) + \gamma_2 C_2(Age_i) + \gamma_3 C_3(Age_i) + \gamma_4 C_4(Age_i) + \varepsilon_i.$$

En esta parametrización,

$$\hat{\gamma}_j = \overline{Wage_j}$$

para $j = 1, 2, 3, 4$.

Importante

Las dos parametrizaciones producen exactamente la misma función escalonada; únicamente cambia la interpretación de los coeficientes.

Funciones escalonadas en regresión logística

Las mismas variables indicadoras pueden utilizarse dentro de una **regresión logística**.

En los datos Wage, definimos

$$Y_i = \mathbf{1}(Wage_i > 250).$$

Entonces

$$Y_i = \begin{cases} 1, & Wage_i > 250, \\ 0, & Wage_i \leq 250. \end{cases}$$

Ahora queremos modelar

$$p(x) = P(Wage > 250 \mid Age = x).$$

Funciones escalonadas en regresión logística

Utilizando los mismos grupos de edad,

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \beta_1 C_1(x) + \beta_2 C_2(x) + \beta_3 C_3(x).$$

De log-odds a probabilidades

El modelo logístico especifica los *log-odds* como

$$\eta(x) = \beta_0 + \beta_1 C_1(x) + \beta_2 C_2(x) + \beta_3 C_3(x).$$

La probabilidad se obtiene aplicando la función logística:

$$P(Wage > 250 \mid Age = x) = \frac{\exp\{\eta(x)\}}{1 + \exp\{\eta(x)\}}.$$

Es decir,

$$P(Wage > 250 \mid Age = x) = \frac{\exp\{\beta_0 + \beta_1 C_1(x) + \cdots + \beta_3 C_3(x)\}}{1 + \exp\{\beta_0 + \beta_1 C_1(x) + \cdots + \beta_3 C_3(x)\}}.$$

De log-odds a probabilidades

Importante

Los coeficientes β_j **no son probabilidades**: son log-odds.

Interpretación de los coeficientes

Para el grupo de referencia C_0 ,

$$\log \left(\frac{p_0}{1 - p_0} \right) = \beta_0.$$

Para los demás grupos,

$$\log \left(\frac{p_j}{1 - p_j} \right) = \beta_0 + \beta_j, \quad j = 1, 2, 3.$$

Por tanto,

$$\beta_j = \text{logit}(p_j) - \text{logit}(p_0).$$

Interpretación: β_j representa la diferencia en *log-odds* entre el grupo j y el grupo de referencia.

Interpretación de los coeficientes logísticos


En esta parametrización,

$$\hat{p}_j = \frac{\#\{Wage > 250 \text{ en el grupo } j\}}{\#\{\text{observaciones en el grupo } j\}}$$

Interpretación

La regresión logística escalonada estima esencialmente una **proporción diferente para cada grupo de edad.**

Probabilidad de un salario mayor a \$250,000



La línea sólida representa

$$\hat{P}(Wage > 250 \mid Age).$$

- ▶ La probabilidad es constante dentro de cada grupo de edad.
- ▶ Las líneas discontinuas representan un IC del 95%.
- ▶ Las pequeñas marcas superiores corresponden a individuos con $Wage > 250$.
- ▶ Las marcas inferiores corresponden a individuos con $Wage \leq 250$.

Dos preguntas diferentes, la misma idea

En ambos paneles dividimos Age en los mismos intervalos.

Regresión lineal

Modelamos

$$E[Wage \mid Age].$$

Para cada grupo,

$$\hat{\beta}_j = \overline{Wage}_j.$$

Cada escalón es una media.

Regresión logística

Modelamos

$$P(Wage > 250 \mid Age).$$

Para cada grupo,

$$\hat{p}_j = \frac{\#\{Wage > 250\}}{\#\{\text{observaciones}\}}.$$

Cada escalón es una probabilidad.

En ambos casos, la relación con la edad es **constante por intervalos** y cambia únicamente al atravesar un punto de corte.

¿Qué perdemos al discretizar?

La simplicidad de las funciones escalonadas tiene un costo.

En los datos Wage existe una tendencia aproximadamente suave del salario con la edad. Sin embargo, el modelo supone que

$$\hat{f}(x)$$

es completamente constante dentro de cada intervalo.

- ▶ Una persona justo antes y otra justo después de un punto de corte pueden recibir predicciones distintas.
- ▶ Dos personas bastante separadas dentro del mismo intervalo reciben exactamente la misma predicción.
- ▶ Los saltos son consecuencia de nuestra discretización, no necesariamente del fenómeno real.

Limitación principal

Limitación principal

Si no existen puntos de corte naturales, una función constante a trozos puede **perder tendencias suaves importantes** en los datos.

Ventajas:

- ▶ Evita imponer una estructura global; es útil cuando se sospecha un cambio de régimen o umbral (por ejemplo, políticas públicas con umbrales de edad o de ingreso).
- ▶ Muy usado en bioestadística y ciencias sociales para categorizar variables continuas con sentido clínico o normativo (por ejemplo, categorías de índice de masa corporal).

Desventajas.

- ▶ A menos que existan puntos de corte naturales sugeridos por el problema, la elección de $c_1, \dots, c_K$ es arbitraria y el modelo es sensible a ella.
- ▶ Con frecuencia se “pierden” tendencias suaves reales dentro de cada intervalo, generando artefactos discontinuos que no reflejan el fenómeno.

Nota

Las funciones escalón siguen siendo muy utilizadas cuando existen puntos de corte naturales o categorías con interpretación sustantiva, particularmente en bioestadística y epidemiología. Sin embargo, cuando la relación subyacente es suave, métodos como los *splines* permiten conservar esa suavidad sin imponer una forma polinómica global.