

SPLINES DE SUAVIZAMIENTO

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM
haydeeperuyero@unam.mx*



ENES
JURIQUILLA

1 Splines de suavizamiento

2 Elección del parámetro λ

SPLINES DE SUAVIZAMIENTO

Splines de suavizamiento

En los **splines de regresión** seguimos, en términos generales, los siguientes pasos:

1. Elegimos un conjunto de **nodos** (*knots*).
2. Construimos funciones base a partir de esos nodos.
3. Estimamos los coeficientes mediante mínimos cuadrados.

Los **splines de suavizamiento** (*smoothing splines*) parten de una idea diferente.

En lugar de decidir directamente dónde colocar unos cuantos nodos, buscamos una función $g(x)$ que satisfaga simultáneamente dos objetivos:

- ▶ ajustarse bien a los datos;
- ▶ ser suficientemente suave.

Pregunta central

La pregunta central será:

¿Cómo podemos medir y controlar la suavidad de una función?

El problema: ajustar demasiado bien

Supongamos que tenemos observaciones

$$(x_1, y_1), \dots, (x_n, y_n)$$

y queremos encontrar una función $g(x)$ que describa la relación entre X y Y .

Una posibilidad sería buscar g de manera que el error cuadrático residual sea pequeño:

$$RSS = \sum_{i=1}^n (y_i - g(x_i))^2.$$

Si g es completamente flexible

Si g es completamente flexible

Pero si permitimos que g sea **completamente flexible**, podemos construir una función que pase exactamente por todos los puntos:

$$g(x_i) = y_i \quad \text{para todo } i.$$

Entonces,

$$RSS = 0.$$

Si g es completamente flexible

Pero si permitimos que g sea **completamente flexible**, podemos construir una función que pase exactamente por todos los puntos:

$$g(x_i) = y_i \quad \text{para todo } i.$$

Entonces,

$$RSS = 0.$$

Problema

Un ajuste perfecto a los datos de entrenamiento no necesariamente es un buen modelo.

Una función que interpola todos los puntos puede ser extremadamente irregular y presentar **sobreajuste**.

Queremos ajuste y suavidad

Nuestro objetivo no es solamente minimizar

$$\sum_{i=1}^n (y_i - g(x_i))^2,$$

sino encontrar una función que además sea **suave**.

Para lograrlo, los splines de suavizamiento buscan la función g que minimiza

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt$$

donde $\lambda \geq 0$ es un **parámetro de suavizamiento**.

De Ridge y Lasso a Splines

Esta expresión tiene la forma

$$\text{Error de ajuste} + \lambda \text{ Penalización}$$

De Ridge y Lasso a Splines

Esta expresión tiene la forma

$$\text{Error de ajuste} + \lambda \text{ Penalización}$$

Es la misma filosofía general que aparece en métodos de regularización como **Ridge** y **Lasso**:

permitimos cierto error de ajuste a cambio de controlar la complejidad del modelo.

¿Qué significa cada término?

Consideremos nuevamente

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt.$$

1. Error de ajuste

$$\sum_{i=1}^n (y_i - g(x_i))^2$$

Mide qué tan lejos están las predicciones $g(x_i)$ de las observaciones y_i .

- ▶ Valor pequeño $\Rightarrow$ la curva se ajusta bien a los datos.
- ▶ Valor grande $\Rightarrow$ la curva está lejos de los datos.

¿Qué significa cada término?

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt.$$

2. Penalización por falta de suavidad

$$\int [g''(t)]^2 dt$$

Mide qué tanto cambia la pendiente de g a lo largo de su dominio.

¿Por qué aparece la segunda derivada?

Recordemos la interpretación geométrica de las derivadas.

La primera derivada

$$g'(t)$$

mide la **pendiente** de la función.

La segunda derivada

$$g''(t)$$

mide **qué tan rápidamente cambia esa pendiente**.

Ejemplo

Por ejemplo, para una recta

$$g(t) = \beta_0 + \beta_1 t,$$

tenemos

$$g'(t) = \beta_1$$

y

$$g''(t) = 0.$$

Por lo tanto,

$$\int [g''(t)]^2 dt = 0.$$

Interpretación

Interpretación

Si $g''(t)$ toma valores grandes en muchas regiones, la curva cambia constantemente de dirección y presenta mayor **curvatura o rugosidad**.

La penalización de rugosidad

La cantidad

$$\int [g''(t)]^2 dt$$

se conoce como una **penalización de rugosidad**.

¿Por qué elevamos $g''(t)$ al cuadrado?

- ▶ Evitamos que curvaturas positivas y negativas se cancelen.
- ▶ Tanto una curvatura positiva grande como una negativa grande contribuyen a la penalización.

La penalización de rugosidad

Así,

$$\int [g''(t)]^2 dt \approx 0$$

indica una función muy suave, mientras que

$$\int [g''(t)]^2 dt \gg 0$$

indica una función con muchos cambios en su pendiente.

Por tanto,

$$\lambda \int [g''(t)]^2 dt$$

castiga las funciones excesivamente irregulares.

El papel de λ

El parámetro λ determina cuánto penalizamos la falta de suavidad:

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt.$$

λ pequeño

La penalización tiene poca importancia.

La prioridad es reducir el RSS.

⇒ Curva más flexible.

⇒ Mayor riesgo de sobreajuste.

λ grande

La penalización tiene mucha importancia.

La prioridad es reducir la curvatura.

⇒ Curva más suave.

⇒ Mayor riesgo de subajuste.

Por lo tanto, λ controla el compromiso

ajuste a los datos $\longleftrightarrow$ suavidad

Los casos extremos

Consideremos los dos extremos posibles para λ .

Caso 1: $\lambda = 0$

El problema se convierte en

$$\min_g \sum_{i=1}^n (y_i - g(x_i))^2.$$

No existe ninguna penalización por rugosidad.

La función puede ser extremadamente flexible y, en el límite,
interpolar los datos:

$$g(x_i) = y_i.$$

Caso 2: $\lambda \rightarrow \infty$

La penalización domina y buscamos que

$$g''(t) \approx 0.$$

Por tanto, g se aproxima a una **recta**.

En el límite obtenemos el ajuste lineal por mínimos cuadrados.

Interpretación de λ

Podemos pensar en λ como un “control de suavidad”:

$\lambda = 0 \quad \longrightarrow \quad \text{máxima flexibilidad}$

λ pequeño $\longrightarrow$ curva flexible

λ intermedio $\longrightarrow$ compromiso ajuste–suavidad

λ grande $\longrightarrow$ curva muy suave

$\lambda \rightarrow \infty \quad \longrightarrow \quad \text{regresión lineal}$

Esto corresponde nuevamente al compromiso **sesgo–varianza**:

- ▶ λ pequeño $\Rightarrow$ menor sesgo, mayor varianza.
- ▶ λ grande $\Rightarrow$ mayor sesgo, menor varianza.

¿Qué función obtenemos?

Una propiedad importante es que no necesitamos buscar entre todas las funciones posibles de manera arbitraria.

Se puede demostrar que la función $g(x)$ que minimiza

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt$$

es un **spline cúbico natural**.

¿Qué función obtenemos?

Una propiedad importante es que no necesitamos buscar entre todas las funciones posibles de manera arbitraria.

Se puede demostrar que la función $g(x)$ que minimiza

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt$$

es un **spline cúbico natural**.

Además:

- ▶ tiene nodos en los valores únicos $x_1, \dots, x_n$;
- ▶ es un polinomio cúbico por partes;
- ▶ $g(x)$, $g'(x)$ y $g''(x)$ son continuas en los nodos;
- ▶ fuera de los nodos extremos, el spline es **lineal**.

Una diferencia importante

Aquí potencialmente tenemos un nodo en **cada valor observado de X** .

La flexibilidad no se controla principalmente reduciendo el número de nodos, sino mediante λ .

El spline cúbico no es exactamente el mismo de antes, es una versión reducida de este.

Spline de regresión vs. spline de suavizamiento

Spline de regresión

Elegimos un número relativamente pequeño de nodos.

La flexibilidad depende fuertemente del número y posición de los nodos.

Se estiman los coeficientes mediante mínimos cuadrados.

Más nodos generalmente implican mayor flexibilidad.

Spline de suavizamiento

Puede tener nodos en todos los valores únicos de X .

La flexibilidad se controla mediante λ .

Se minimiza una función de pérdida penalizada.

Menor λ implica mayor flexibilidad.

En ambos casos obtenemos modelos flexibles contruidos a partir de polinomios por partes, pero el mecanismo utilizado para **controlar la complejidad** es diferente.

Idea central

Un spline de suavizamiento resuelve

$$\min_g \left\{ \underbrace{\sum_{i=1}^n (y_i - g(x_i))^2}_{\text{ajuste a los datos}} + \underbrace{\lambda \int [g''(t)]^2 dt}_{\text{penalización por rugosidad}} \right\}$$

Tenemos entonces tres ideas fundamentales:

1. No queremos únicamente una función que se ajuste bien a los datos.
2. También queremos controlar qué tan irregular puede ser esa función.
3. El parámetro λ determina el compromiso entre ambos objetivos.

ELECCIÓN DEL PARÁMETRO λ

¿Cómo elegimos λ ?

Un spline de suavizamiento minimiza

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int [g''(t)]^2 dt.$$

Ya sabemos que λ controla la flexibilidad.

Por tanto, aparece una pregunta fundamental:

¿qué valor de λ debemos utilizar?

Para responderla, primero necesitamos una forma de cuantificar **qué tan flexible es el modelo**.

¿Cuántos parámetros tiene el modelo?

Un spline de suavizamiento es un **spline cúbico natural** con nodos en cada valor único de x_i .

Esto parece problemático:

- ▶ podemos tener una gran cantidad de nodos;
- ▶ por tanto, podemos tener una gran cantidad de parámetros;
- ▶ parecería que el modelo tiene una enorme flexibilidad.

¿Cuántos parámetros tiene el modelo?

Un spline de suavizamiento es un **spline cúbico natural** con nodos en cada valor único de x_i .

Esto parece problemático:

- ▶ podemos tener una gran cantidad de nodos;
- ▶ por tanto, podemos tener una gran cantidad de parámetros;
- ▶ parecería que el modelo tiene una enorme flexibilidad.

Sin embargo, estos parámetros **no pueden variar libremente**.

La penalización

$$\lambda \int [g''(t)]^2 dt$$

restringe cuánto puede cambiar la función.

Idea importante

Aunque el modelo tenga muchos parámetros, la penalización puede hacer que se comporte como un modelo mucho más sencillo.

Grados de libertad

En un modelo tradicional, los **grados de libertad** están relacionados con el número de parámetros libres que estimamos.

Por ejemplo, en una regresión lineal simple

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

estimamos dos parámetros:

$$\beta_0, \quad \beta_1.$$

Podemos pensar entonces en un modelo con aproximadamente **dos grados de libertad**.

Grados de libertad

Si utilizamos un polinomio de grado d ,

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_d X^d + \varepsilon,$$

tenemos

$$d + 1$$

coeficientes que debemos estimar.

Grados de libertad

Si utilizamos un polinomio de grado d ,

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_d X^d + \varepsilon,$$

tenemos

$$d + 1$$

coeficientes que debemos estimar.

Pero en un spline de suavizamiento...

El número de parámetros nominales no describe adecuadamente la complejidad del modelo porque los parámetros están **restringidos por la penalización**.

Grados de libertad efectivos

Para los splines de suavizamiento utilizamos los **grados de libertad efectivos**, que denotaremos por

$$df_{\lambda}.$$

Estos miden la **flexibilidad real** del ajuste después de considerar el efecto de la penalización.

Existe una relación directa entre λ y df_{λ} :

$$\boxed{\lambda \uparrow \implies df_{\lambda} \downarrow}$$

Grados de libertad efectivos

En los extremos:

$$\lambda = 0 \implies df_{\lambda} = n,$$

mientras que

$$\lambda \rightarrow \infty \implies df_{\lambda} \rightarrow 2.$$

Interpretación

Más grados de libertad efectivos $\Rightarrow$ mayor flexibilidad.

Menos grados de libertad efectivos $\Rightarrow$ mayor suavidad.

De λ a los grados de libertad

Podemos resumir la relación como

$$\lambda = 0 \quad \longrightarrow \quad df_{\lambda} = n$$

$$\lambda \text{ pequeño} \quad \longrightarrow \quad df_{\lambda} \text{ grande}$$

$$\lambda \text{ intermedio} \quad \longrightarrow \quad df_{\lambda} \text{ intermedio}$$

$$\lambda \text{ grande} \quad \longrightarrow \quad df_{\lambda} \text{ pequeño}$$

$$\lambda \rightarrow \infty \quad \longrightarrow \quad df_{\lambda} = 2$$

Por tanto,

$\lambda \uparrow \implies \text{suavidad} \uparrow \implies df_{\lambda} \downarrow$

Esto también está relacionado con el compromiso sesgo–varianza:

$$df_{\lambda} \uparrow \Rightarrow \text{sesgo} \downarrow, \quad \text{varianza} \uparrow.$$

¿Por qué el mínimo es $df_\lambda = 2$?

Cuando

$$\lambda \rightarrow \infty,$$

la penalización por curvatura domina:

$$\lambda \int [g''(t)]^2 dt.$$

Para minimizarla necesitamos

$$g''(t) \approx 0.$$

¿Por qué el mínimo es $df_\lambda = 2$?

Pero si

$$g''(t) = 0,$$

entonces

$$g'(t) = \beta_1$$

es constante y, por tanto,

$$g(t) = \beta_0 + \beta_1 t.$$

¿Por qué el mínimo es $df_\lambda = 2$?

Conclusión

El modelo más sencillo al que puede reducirse el spline de suavizamiento es una recta, que tiene dos parámetros:

$$\beta_0, \quad \beta_1.$$

Por eso el límite inferior es $df_\lambda = 2$.

El spline como un suavizador lineal

Para un valor determinado de λ , consideremos las predicciones del spline en los puntos de entrenamiento:

$$\hat{\mathbf{g}}_{\lambda} = \begin{pmatrix} \hat{g}_{\lambda}(x_1) \\ \hat{g}_{\lambda}(x_2) \\ \vdots \\ \hat{g}_{\lambda}(x_n) \end{pmatrix}.$$

También tenemos el vector de respuestas:

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Matriz de suavizamiento

Una propiedad muy importante de los splines de suavizamiento es que

$$\hat{\mathbf{g}}_{\lambda} = \mathbf{S}_{\lambda} \mathbf{y}$$

donde $\mathbf{S}_{\lambda}$ es una matriz de tamaño $n \times n$.

Esta matriz se conoce como **matriz de suavizamiento** (*smoother matrix*).

¿Qué hace la matriz S_λ ?

La expresión

$$\hat{\mathbf{g}}_\lambda = \mathbf{S}_\lambda \mathbf{y}$$

significa que cada valor ajustado puede escribirse como una combinación lineal de las observaciones:

$$\hat{g}_\lambda(x_i) = \sum_{j=1}^n (S_\lambda)_{ij} y_j.$$

Es decir,

$$\hat{g}_\lambda(x_i) = (S_\lambda)_{i1} y_1 + (S_\lambda)_{i2} y_2 + \cdots + (S_\lambda)_{in} y_n.$$

¿Qué hace la matriz $\mathbf{S}_\lambda$?

Interpretación

La matriz $\mathbf{S}_\lambda$ determina cómo se combinan los valores observados de Y para producir la curva suavizada.

Además, $\mathbf{S}_\lambda$ depende de λ :

$$\lambda \longrightarrow \mathbf{S}_\lambda \longrightarrow \hat{\mathbf{g}}_\lambda.$$

Grados de libertad efectivos

Ahora podemos definir formalmente los grados de libertad efectivos.

Si

$$\hat{\mathbf{g}}_{\lambda} = \mathbf{S}_{\lambda} \mathbf{y},$$

entonces

$$df_{\lambda} = \sum_{i=1}^n (S_{\lambda})_{ii}$$

es decir,

$$df_{\lambda} = \text{tr}(\mathbf{S}_{\lambda})$$

Si

$$\mathbf{S}_\lambda = \begin{pmatrix} s_{11} & \cdots & s_{1n} \\ \vdots & \ddots & \vdots \\ s_{n1} & \cdots & s_{nn} \end{pmatrix},$$

entonces

$$df_\lambda = s_{11} + s_{22} + \cdots + s_{nn}.$$

¿Cómo interpretar la diagonal de S_λ ?

Recordemos que

$$\hat{g}_\lambda(x_i) = \sum_{j=1}^n (S_\lambda)_{ij} y_j.$$

En particular, el término

$$(S_\lambda)_{ii}$$

indica cuánto contribuye la observación y_i a su **propio valor ajustado** $\hat{g}_\lambda(x_i)$.

Si los elementos diagonales son grandes, cada observación tiene mayor influencia sobre su propia predicción.

¿Cómo interpretar la diagonal de $\mathbf{S}_\lambda$?

Si son pequeños, el ajuste depende más de la información compartida con las demás observaciones.

Por eso

La cantidad

$$\text{tr}(\mathbf{S}_\lambda)$$

proporciona una medida de la flexibilidad global del suavizador.

Entonces, ¿cómo escogemos λ ?

En los splines de regresión debíamos tomar decisiones como:

- ▶ ¿cuántos nodos utilizar?
- ▶ ¿dónde colocar los nodos?

En un spline de suavizamiento no tenemos ese problema: los nodos están asociados a los valores observados de X .

Pero aparece una nueva decisión:

¿qué valor de λ debemos utilizar?

Entonces, ¿cómo escogemos λ ?

En los splines de regresión debíamos tomar decisiones como:

- ▶ ¿cuántos nodos utilizar?
- ▶ ¿dónde colocar los nodos?

En un spline de suavizamiento no tenemos ese problema: los nodos están asociados a los valores observados de X .

Pero aparece una nueva decisión:

¿qué valor de λ debemos utilizar?

Queremos elegir un λ que produzca un buen desempeño **fuera de los datos utilizados para ajustar el modelo**.

Una solución natural es utilizar

validación cruzada.

Leave-One-Out Cross-Validation

En **LOOCV** (*Leave-One-Out Cross-Validation*) repetimos conceptualmente el siguiente procedimiento para cada observación i :

1. Eliminamos (x_i, y_i) del conjunto de entrenamiento.
2. Ajustamos el spline utilizando las $n - 1$ observaciones restantes.
3. Predecimos el valor de Y en x_i .
4. Calculamos el error de predicción.

Denotamos por

$$\hat{g}_{\lambda}^{(-i)}(x_i)$$

la predicción en x_i obtenida con el modelo que **no utilizó la observación i para entrenar**.

Leave-One-Out Cross-Validation

Entonces,

$$RSS_{CV}(\lambda) = \sum_{i=1}^n \left(y_i - \hat{g}_{\lambda}^{(-i)}(x_i) \right)^2.$$

Elegir λ mediante LOOCV

Para distintos valores de λ calculamos

$$RSS_{CV}(\lambda) = \sum_{i=1}^n \left(y_i - \hat{g}_{\lambda}^{(-i)}(x_i) \right)^2.$$

Después elegimos

$$\lambda^* = \arg \min_{\lambda} RSS_{CV}(\lambda)$$

Conceptualmente:

$\lambda \longrightarrow \text{spline} \longrightarrow \text{predicciones fuera de muestra} \longrightarrow RSS_{CV}.$

Elegir λ mediante LOOCV

Objetivo

No buscamos el λ que mejor ajuste los datos de entrenamiento, sino el que tenga mejor capacidad de **generalización**.

Pero LOOCV parece costoso...

Si tenemos n observaciones, el procedimiento tradicional de LOOCV parecería requerir:

$$n$$

ajustes diferentes del modelo para **cada valor de λ** .

Por ejemplo, si tenemos

$$n = 1000,$$

tendríamos que ajustar 1000 splines para evaluar un solo valor de λ .

Pero LOOCV parece costoso...

Sin embargo, los splines de suavizamiento tienen una propiedad especial.

Resultado importante

El error LOOCV puede calcularse a partir del ajuste realizado con **todos los datos**, sin necesidad de volver a ajustar explícitamente n modelos diferentes.

Una fórmula eficiente para LOOCV

Para los splines de suavizamiento se puede demostrar que

$$RSS_{CV}(\lambda) = \sum_{i=1}^n \left[\frac{y_i - \hat{g}_\lambda(x_i)}{1 - (S_\lambda)_{ii}} \right]^2$$

Recordemos:

- ▶ $\hat{g}_\lambda(x_i)$ es la predicción obtenida ajustando el spline con **todos los datos**;
- ▶ $(S_\lambda)_{ii}$ es el elemento i -ésimo de la diagonal de la matriz de suavizamiento.

Una fórmula eficiente para LOOCV

Por tanto, no necesitamos calcular explícitamente

$$\hat{g}_{\lambda}^{(-1)}, \hat{g}_{\lambda}^{(-2)}, \dots, \hat{g}_{\lambda}^{(-n)}.$$

Ventaja

LOOCV puede calcularse de manera muy eficiente para los splines de suavizamiento.

¿Qué significa la corrección de LOOCV?

Comparemos el residuo ordinario

$$e_i = y_i - \hat{g}_\lambda(x_i)$$

con el residuo utilizado por LOOCV:

$$e_i^{CV} = \frac{y_i - \hat{g}_\lambda(x_i)}{1 - (S_\lambda)_{ii}}$$

El término $(S_\lambda)_{ii}$ mide cuánto influye la observación i sobre su propio valor ajustado.

¿Qué significa la corrección de LOOCV?

Si $(S_\lambda)_{ii}$ es grande,

$$1 - (S_\lambda)_{ii}$$

es pequeño y el residuo se **amplifica**.

Intuición

Si una observación tuvo mucha influencia en su propia predicción, su pequeño error de entrenamiento puede ser engañoso. LOOCV corrige precisamente este efecto.

Complejidad vs. desempeño

Supongamos que tenemos dos modelos con desempeño muy similar:

Modelo A: $df = 16$,

Modelo B: $df = 6.8$.

Si el modelo más complejo no produce una mejora importante en la capacidad predictiva, generalmente preferimos el modelo más sencillo.

Principio general

No debemos aumentar la complejidad de un modelo simplemente porque podemos hacerlo.

Los datos deben proporcionar evidencia de que esa complejidad adicional es necesaria.

Resumen: elección del parámetro de suavizamiento

El spline de suavizamiento depende del parámetro λ :

$$\lambda \uparrow \implies \text{suavidad} \uparrow \implies df_\lambda \downarrow.$$

Los grados de libertad efectivos se definen mediante

$$df_\lambda = \text{tr}(\mathbf{S}_\lambda)$$

donde

$$\hat{\mathbf{g}}_\lambda = \mathbf{S}_\lambda \mathbf{y}.$$

Resumen: elección del parámetro de suavizamiento

Finalmente, podemos seleccionar λ mediante LOOCV:

$$RSS_{CV}(\lambda) = \sum_{i=1}^n \left[\frac{y_i - \hat{g}_\lambda(x_i)}{1 - (S_\lambda)_{ii}} \right]^2$$

y elegir el valor de λ que minimice este error.