

REGRESIÓN LOCAL

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM*

haydeeperuyero@unam.mx



ENES
JURIQUILLA

Regresión local: idea general

Hasta ahora hemos construido modelos flexibles utilizando una **representación global** de los datos.

- ▶ En regresión polinomial ajustamos un polinomio a todas las observaciones.
- ▶ En splines dividimos el dominio mediante nodos y combinamos funciones base.
- ▶ En smoothing splines controlamos la flexibilidad mediante una penalización.

Regresión local: idea general

La **regresión local** propone una estrategia diferente:

Idea principal

Para predecir la respuesta en un punto x_0 , utilizamos principalmente las observaciones que se encuentran **cerca de** x_0 .

Por tanto, en lugar de construir una única función global, realizamos **pequeños ajustes locales** a lo largo del dominio.

¿Qué significa “local”?

Supongamos que tenemos observaciones

$$(x_1, y_1), \dots, (x_n, y_n)$$

y queremos estimar la respuesta en un punto particular x_0 .

¿Qué significa “local”?

Supongamos que tenemos observaciones

$$(x_1, y_1), \dots, (x_n, y_n)$$

y queremos estimar la respuesta en un punto particular x_0 .

La idea es:

1. Identificar las observaciones más cercanas a x_0 .
2. Dar mayor importancia a las observaciones más próximas.
3. Ajustar una regresión utilizando esas observaciones.
4. Evaluar el modelo obtenido en x_0 .

IMPORTANTE

Importante

Si cambiamos x_0 , cambian las observaciones relevantes y sus pesos. Por lo tanto, para cada nuevo valor de x_0 se realiza **un nuevo ajuste**.

Paso 1: elegir el vecindario

Para realizar una predicción en x_0 , seleccionamos los k puntos de entrenamiento cuyos valores de x_i son más cercanos a x_0 .

La proporción de datos utilizados se denomina **span**:

$$s = \frac{k}{n},$$

donde

- ▶ n es el número total de observaciones,
- ▶ k es el número de observaciones utilizadas localmente.

Ejemplo

Por ejemplo, si

$$n = 100 \quad \text{y} \quad s = 0.20,$$

entonces

$$k = 0.20(100) = 20.$$

Para estimar en x_0 utilizaríamos las **20 observaciones más cercanas**.

Paso 2: asignar pesos

No todas las observaciones del vecindario tienen la misma importancia.

A cada observación se le asigna un peso

$$K_{i0} = K(x_i, x_0),$$

que depende de su distancia respecto a x_0 .

Paso 2: asignar pesos

No todas las observaciones del vecindario tienen la misma importancia.

A cada observación se le asigna un peso

$$K_{i0} = K(x_i, x_0),$$

que depende de su distancia respecto a x_0 .

La idea general es:

- ▶ observaciones muy cercanas a $x_0 \rightarrow$ pesos grandes;
- ▶ observaciones más alejadas $\rightarrow$ pesos pequeños;
- ▶ observaciones fuera del vecindario $\rightarrow$ peso igual a cero.

Función ponderación


Función de ponderación

La función K determina cómo disminuye la influencia de una observación conforme aumenta su distancia a x_0 .

Así, el ajuste está dominado por la información que se encuentra **localmente alrededor de** x_0 .

¿Cómo funcionan los pesos?

Consideremos un punto objetivo x_0 .



Función ponderación

- ▶ Los puntos más cercanos a x_0 reciben **mayor peso**.
- ▶ Los puntos más alejados reciben menor peso.
- ▶ Los puntos fuera del vecindario tienen peso cero.

Idea

La recta se ajusta para describir bien el comportamiento de los datos **alrededor de** x_0 , no necesariamente en todo el dominio.

Paso 3: regresión lineal ponderada

Una vez seleccionadas las observaciones y calculados sus pesos, ajustamos una regresión lineal local

$$y_i \approx \beta_0 + \beta_1 x_i.$$

Pero ahora no minimizamos la suma usual de residuos cuadrados.

Paso 3: regresión lineal ponderada

Una vez seleccionadas las observaciones y calculados sus pesos, ajustamos una regresión lineal local

$$y_i \approx \beta_0 + \beta_1 x_i.$$

Pero ahora no minimizamos la suma usual de residuos cuadrados.

Buscamos $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen

$$\sum_{i=1}^n K_{i0} (y_i - \beta_0 - \beta_1 x_i)^2.$$

Diferencia con mínimos cuadrados

La diferencia con mínimos cuadrados ordinarios está en K_{i0} :

- ▶ un punto con peso grande influye mucho en el ajuste;
- ▶ un punto con peso pequeño influye poco;
- ▶ un punto con $K_{i0} = 0$ no participa en el ajuste.

Paso 4: obtener la predicción

Después de resolver el problema de mínimos cuadrados ponderados, obtenemos

$$\hat{\beta}_0 \quad \text{y} \quad \hat{\beta}_1.$$

El ajuste local alrededor de x_0 es

$$\hat{f}(x) = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Pero nuestro objetivo era estimar específicamente la respuesta en x_0 .

Por tanto,

$$\boxed{\hat{f}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0}$$

¿Cómo obtenemos la curva final?

Para obtener toda la curva repetimos este procedimiento para muchos valores de x_0 .

Consecuencia

La curva final no proviene de una única regresión lineal: es el resultado de **muchas regresiones locales**.


De ajustes locales a una curva

El procedimiento anterior produce una predicción **solamente para un punto** x_0 .

De ajustes locales a una curva

El procedimiento anterior produce una predicción **solamente para un punto** x_0 .

Para construir una curva completa repetimos el procedimiento:



De ajustes locales a una curva

Para cada nuevo punto:

$$x_0^{(1)}, x_0^{(2)}, x_0^{(3)}, \dots$$


obtenemos un **nuevo vecindario, nuevos pesos y una nueva recta local.**

De ajustes locales a una curva

Al repetir el procedimiento para muchos valores de x_0 obtenemos

$$\hat{f}(x_0^{(1)}), \hat{f}(x_0^{(2)}), \dots, \hat{f}(x_0^{(m)}).$$

Uniendo estas predicciones aparece una función suave:



Clave:

Punto clave

Aunque localmente ajustamos rectas, el resultado global **no tiene por qué ser una recta**.

La no linealidad aparece porque utilizamos **una recta diferente en cada región**.

El parámetro *span*

La decisión más importante en regresión local suele ser el **span** s .

Recordemos:

$$s = \frac{k}{n}.$$

El span controla qué proporción de los datos se utiliza para cada ajuste local.

El parámetro *span*

La decisión más importante en regresión local suele ser el **span** s .

Recordemos:

$$s = \frac{k}{n}.$$

El span controla qué proporción de los datos se utiliza para cada ajuste local.

Span pequeño

- ▶ pocos vecinos;
- ▶ ajuste muy local;
- ▶ mayor flexibilidad;
- ▶ curva más irregular;
- ▶ mayor sensibilidad al ruido.

Span grande

- ▶ más vecinos;
- ▶ ajuste menos local;
- ▶ menor flexibilidad;
- ▶ curva más suave;
- ▶ comportamiento más global.

¿Cómo elegir el *span*?

Existe un compromiso entre flexibilidad y suavidad.

Span	Vecindario	Ajuste
pequeño	pequeño	flexible / irregular
grande	grande	suave / global

¿Cómo elegir el *span*?

Existe un compromiso entre flexibilidad y suavidad.

Span	Vecindario	Ajuste
pequeño	pequeño	flexible / irregular
grande	grande	suave / global

Por ejemplo,

$$s = 0.2$$

utiliza aproximadamente el 20% de las observaciones más cercanas para cada ajuste, mientras que

$$s = 0.7$$

utiliza aproximadamente el 70%.

¿Cómo elegir el span?

Por ello, normalmente esperamos que

$s = 0.2 \Rightarrow$ curva más flexible,

mientras que

$s = 0.7 \Rightarrow$ curva más suave.

Selección

El valor de s puede especificarse directamente o seleccionarse mediante validación cruzada.

Relación con splines de suavizamiento

El *span* desempeña un papel parecido al parámetro de suavizamiento λ de los splines de suavizamiento:

ambos controlan la **flexibilidad del ajuste**.

	Más flexible	Más suave
Regresión local	s pequeño	s grande
Spline de suavizamiento	λ pequeño	λ grande

Relación con splines de suavizamiento

El *span* desempeña un papel parecido al parámetro de suavizamiento λ de los splines de suavizamiento:

ambos controlan la **flexibilidad del ajuste**.

	Más flexible	Más suave
Regresión local	s pequeño	s grande
Spline de suavizamiento	λ pequeño	λ grande

No confundir

En regresión local controlamos principalmente **cuántas observaciones participan localmente**.

En splines de suavizamiento, λ controla **cuánto penalizamos la curvatura de la función**.

¿Por qué se llama un método basado en memoria?

Para predecir en un nuevo punto x_0 debemos:

1. consultar nuevamente los datos de entrenamiento;
2. encontrar las observaciones cercanas;
3. calcular nuevos pesos;
4. ajustar una nueva regresión ponderada.

¿Por qué se llama un método basado en memoria?

Para predecir en un nuevo punto x_0 debemos:

1. consultar nuevamente los datos de entrenamiento;
2. encontrar las observaciones cercanas;
3. calcular nuevos pesos;
4. ajustar una nueva regresión ponderada.

Por tanto, el modelo necesita conservar los datos de entrenamiento para realizar nuevas predicciones.

Método basado en memoria

La regresión local es un procedimiento *memory-based*, de manera similar a los métodos de vecinos cercanos.

Esto contrasta con modelos donde, una vez estimados unos cuantos parámetros, las observaciones originales ya no son necesarias para realizar una predicción.

Extensiones de la regresión local

La regresión local no tiene que limitarse a una recta.

Dentro de cada vecindario podemos ajustar, por ejemplo,

- ▶ una constante local;
- ▶ una regresión lineal local;
- ▶ una regresión cuadrática local.

Se puede extender

También puede extenderse a varias variables predictoras:

$$X_1, X_2, \dots, X_p.$$

Por ejemplo, podemos construir vecindarios en el espacio

$$(X_1, X_2)$$

y ajustar una regresión utilizando las observaciones cercanas a un punto objetivo (x_{01}, x_{02}) .

Limitaciones en dimensiones altas

La regresión local funciona especialmente bien cuando tenemos pocas variables predictoras.

¿Por qué?

Limitaciones en dimensiones altas

La regresión local funciona especialmente bien cuando tenemos pocas variables predictoras.

¿Por qué?

Al aumentar la dimensión p , las observaciones tienden a encontrarse cada vez más dispersas en el espacio.

Por tanto, alrededor de un punto x_0 puede haber **muy pocas observaciones realmente cercanas**.

Maldición de la dimensionalidad

Maldición de la dimensionalidad

En dimensiones altas resulta difícil construir vecindarios que sean simultáneamente pequeños y que contengan suficientes observaciones.

En la práctica, la regresión local puede presentar problemas cuando

$$p \gtrsim 3 \text{ o } 4.$$

Este problema también aparece en métodos como k -nearest neighbors.

Regresión local: resumen

Para estimar $f(x_0)$:

1. Seleccionamos los k vecinos más cercanos a x_0 .
2. Calculamos pesos

$$K_{i0} = K(x_i, x_0).$$

3. Ajustamos una regresión ponderada minimizando

$$\sum_{i=1}^n K_{i0} (y_i - \beta_0 - \beta_1 x_i)^2.$$

4. Evaluamos el modelo local:

$$\hat{f}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

IMPORTANTE

Idea principal

No buscamos una única ecuación que describa todos los datos. Construimos la curva utilizando **información local diferente en cada punto**.