

MODELOS ADITIVOS GENERALIZA- DOS(GAMs)

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM
haydeeperuyero@unam.mx*

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1



ENES
JURIQUILLA

De una variable a varias variables

Hasta ahora hemos estudiado métodos flexibles para modelar una respuesta Y utilizando principalmente **una variable predictora X** .

Por ejemplo:

- ▶ regresión polinomial;
- ▶ funciones escalonadas;
- ▶ splines;
- ▶ smoothing splines;
- ▶ regresión local.

De una variable a varias variables

Hasta ahora hemos estudiado métodos flexibles para modelar una respuesta Y utilizando principalmente **una variable predictora** X .

Por ejemplo:

- ▶ regresión polinomial;
- ▶ funciones escalonadas;
- ▶ splines;
- ▶ smoothing splines;
- ▶ regresión local.

Pero en muchos problemas tenemos varias variables predictoras:

$$X_1, X_2, \dots, X_p.$$

Pregunta

Pregunta

¿Cómo podemos permitir relaciones no lineales entre Y y cada predictor, sin perder completamente la interpretabilidad del modelo?

La respuesta es utilizar un **Modelo Aditivo Generalizado (GAM)**.

Recordatorio: regresión lineal múltiple

En una regresión lineal múltiple tenemos

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i.$$

Cada predictor tiene un efecto lineal sobre la respuesta.

Recordatorio: regresión lineal múltiple

En una regresión lineal múltiple tenemos

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i.$$

Cada predictor tiene un efecto lineal sobre la respuesta.

Por ejemplo,

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2.$$

impone que

- ▶ el efecto de X_1 sobre Y sea una recta;
- ▶ el efecto de X_2 sobre Y sea una recta.

Recordatorio: regresión lineal múltiple

En una regresión lineal múltiple tenemos

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i.$$

Cada predictor tiene un efecto lineal sobre la respuesta.

Por ejemplo,

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2.$$

impone que

- ▶ el efecto de X_1 sobre Y sea una recta;
- ▶ el efecto de X_2 sobre Y sea una recta.

Esto puede ser demasiado restrictivo cuando las relaciones reales son no lineales.

Idea de un Modelo Aditivo Generalizado

La idea consiste en reemplazar cada término lineal

$$\beta_j X_j$$

por una función flexible

$$f_j(X_j).$$

Así obtenemos

$$Y_i = \beta_0 + \sum_{j=1}^p f_j(X_{ij}) + \varepsilon_i$$

Equivalentemente,

$$Y_i = \beta_0 + f_1(X_{i1}) + f_2(X_{i2}) + \cdots + f_p(X_{ip}) + \varepsilon_i.$$

Equivalentemente

Equivalentemente,

$$Y_i = \beta_0 + f_1(X_{i1}) + f_2(X_{i2}) + \cdots + f_p(X_{ip}) + \varepsilon_i.$$

¿Por qué “aditivo”?

Porque el efecto total se construye **sumando las contribuciones individuales** de cada predictor.

¿Qué son las funciones f_j ?

Cada función

$$f_j(X_j)$$

describe cómo cambia la respuesta cuando cambia X_j , manteniendo los demás predictores fijos.

¿Qué son las funciones f_j ?

Cada función

$$f_j(X_j)$$

describe cómo cambia la respuesta cuando cambia X_j , manteniendo los demás predictores fijos.

Estas funciones pueden construirse utilizando diferentes métodos:

- ▶ regresión polinomial;
- ▶ splines de regresión;
- ▶ splines naturales;
- ▶ smoothing splines;
- ▶ regresión local.

Idea de los GAMs

Por tanto, un GAM no es un único método de suavizamiento.

Idea importante

Un GAM es un **marco general** que permite combinar diferentes formas de modelar relaciones no lineales.

Ejemplo: datos *Wage*

Supongamos que queremos modelar el salario utilizando

- ▶ el año;
- ▶ la edad;
- ▶ el nivel educativo.

Podemos plantear

$$\text{wage} = \beta_0 + f_1(\text{year}) + f_2(\text{age}) + f_3(\text{education}) + \varepsilon.$$

Ejemplo: datos *Wage*

Supongamos que queremos modelar el salario utilizando

- ▶ el año;
- ▶ la edad;
- ▶ el nivel educativo.

Podemos plantear

$$\text{wage} = \beta_0 + f_1(\text{year}) + f_2(\text{age}) + f_3(\text{education}) + \varepsilon.$$

Podemos elegir, por ejemplo,

- ▶ f_1 : spline natural para year;
- ▶ f_2 : spline natural para age;
- ▶ f_3 : variables indicadoras para education.

NOTA: Variables Cualitativas

Variables cualitativas

Una variable categórica puede incorporarse utilizando variables dummy, de manera similar a una regresión lineal.

¿Cómo interpretar un GAM?

Una de las principales ventajas de los GAMs es que cada función

$$f_j(X_j)$$

puede estudiarse por separado.

¿Cómo interpretar un GAM?

Una de las principales ventajas de los GAMs es que cada función

$$f_j(X_j)$$

puede estudiarse por separado.

Por ejemplo,

$$f_2(\text{age})$$

representa el efecto de la edad sobre el salario **manteniendo constantes las demás variables**.

Analizar individualmente cada predictor

Esto permite realizar gráficas del tipo

$$X_j \quad \text{vs.} \quad \hat{f}_j(X_j)$$

y analizar individualmente la contribución de cada predictor.

Interpretación parcial

Cada gráfica muestra el efecto de una variable **condicionado a que las demás permanezcan fijas**.

GAMs como suma de efectos

Consideremos un modelo con dos predictores:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \varepsilon.$$

Entonces la predicción es

$$\hat{Y} = \hat{\beta}_0 + \hat{f}_1(X_1) + \hat{f}_2(X_2).$$

GAMs como suma de efectos

Consideremos un modelo con dos predictores:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \varepsilon.$$

Entonces la predicción es

$$\hat{Y} = \hat{\beta}_0 + \hat{f}_1(X_1) + \hat{f}_2(X_2).$$

Por ejemplo, para una observación particular:

$$\hat{\beta}_0 = 50, \hat{f}_1(X_1) = 12, \hat{f}_2(X_2) = -4.$$

Entonces

$$\hat{Y} = 50 + 12 - 4 = 58.$$

Aditividad

Cada variable aporta una contribución separada, y las contribuciones se suman para obtener la predicción final.

GAMs con smoothing splines

También podemos construir cada función utilizando smoothing splines:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p) + \varepsilon.$$

Cada f_j puede tener un nivel diferente de flexibilidad.

GAMs con smoothing splines

También podemos construir cada función utilizando smoothing splines:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p) + \varepsilon.$$

Cada f_j puede tener un nivel diferente de flexibilidad.

Por ejemplo,

f_1 puede tener 4 grados de libertad,

mientras que

f_2 puede tener 6 grados de libertad.

Ventaja

Cada predictor puede necesitar un grado distinto de suavizamiento.

No estamos obligados a utilizar la misma complejidad para todas las variables.

¿Cómo se ajustan los GAMs?

Cuando utilizamos funciones base, como splines naturales, el ajuste puede expresarse como una regresión sobre las funciones base correspondientes.

¿Cómo se ajustan los GAMs?

Cuando utilizamos funciones base, como splines naturales, el ajuste puede expresarse como una regresión sobre las funciones base correspondientes.

Cuando utilizamos suavizadores más generales, puede emplearse un procedimiento conocido como **backfitting**.

La idea es actualizar una función a la vez:

1. mantenemos las demás funciones fijas;
2. calculamos el residuo parcial;
3. ajustamos f_j a ese residuo;
4. repetimos el procedimiento para cada predictor.

¿Cómo se ajustan los GAMs?

Cuando utilizamos funciones base, como splines naturales, el ajuste puede expresarse como una regresión sobre las funciones base correspondientes.

Cuando utilizamos suavizadores más generales, puede emplearse un procedimiento conocido como **backfitting**.

La idea es actualizar una función a la vez:

1. mantenemos las demás funciones fijas;
2. calculamos el residuo parcial;
3. ajustamos f_j a ese residuo;
4. repetimos el procedimiento para cada predictor.

Este proceso se repite hasta que los ajustes cambien muy poco.

Supongamos que tenemos

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + f_3(X_3) + \varepsilon.$$

Si queremos actualizar f_2 , mantenemos fijas las demás funciones.

Definimos el residuo parcial

$$r_i = y_i - \hat{\beta}_0 - \hat{f}_1(X_{i1}) - \hat{f}_3(X_{i3}).$$

Supongamos que tenemos

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + f_3(X_3) + \varepsilon.$$

Si queremos actualizar f_2 , mantenemos fijas las demás funciones.

Definimos el residuo parcial

$$r_i = y_i - \hat{\beta}_0 - \hat{f}_1(X_{i1}) - \hat{f}_3(X_{i3}).$$

Entonces ajustamos

$$r_i \approx f_2(X_{i2}).$$

Interpretación

Estamos preguntando:

después de descontar el efecto de las demás variables, ¿qué estructura sigue explicando X_2 ?

Ventajas de los GAMs

Los GAMs presentan varias ventajas importantes.

- ▶ Permiten modelar relaciones **no lineales** entre cada X_j y Y .

Ventajas de los GAMs

Los GAMs presentan varias ventajas importantes.

- ▶ Permiten modelar relaciones **no lineales** entre cada X_j y Y .
- ▶ No necesitamos decidir manualmente una transformación específica para cada predictor.

Ventajas de los GAMs

Los GAMs presentan varias ventajas importantes.

- ▶ Permiten modelar relaciones **no lineales** entre cada X_j y Y .
- ▶ No necesitamos decidir manualmente una transformación específica para cada predictor.
- ▶ Pueden producir mejores predicciones que un modelo estrictamente lineal.

Ventajas de los GAMs

Los GAMs presentan varias ventajas importantes.

- ▶ Permiten modelar relaciones **no lineales** entre cada X_j y Y .
- ▶ No necesitamos decidir manualmente una transformación específica para cada predictor.
- ▶ Pueden producir mejores predicciones que un modelo estrictamente lineal.
- ▶ Mantienen una interpretación relativamente sencilla: podemos estudiar el efecto de cada X_j individualmente.

Ventajas de los GAMs

Los GAMs presentan varias ventajas importantes.

- ▶ Permiten modelar relaciones **no lineales** entre cada X_j y Y .
- ▶ No necesitamos decidir manualmente una transformación específica para cada predictor.
- ▶ Pueden producir mejores predicciones que un modelo estrictamente lineal.
- ▶ Mantienen una interpretación relativamente sencilla: podemos estudiar el efecto de cada X_j individualmente.
- ▶ La complejidad de cada función f_j puede resumirse, por ejemplo, mediante grados de libertad.

Limitación principal: la aditividad

La principal restricción de un GAM básico es su estructura aditiva:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p) + \varepsilon.$$

Esto supone que el efecto de X_1 no depende de X_2 .

Limitación principal: la aditividad

La principal restricción de un GAM básico es su estructura aditiva:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p) + \varepsilon.$$

Esto supone que el efecto de X_1 no depende de X_2 .

Pero en algunos problemas puede existir una interacción:

efecto de X_1 depende del valor de X_2 .

Problema

Si una interacción importante no se incluye en el modelo, el GAM puede no capturar correctamente la estructura de los datos.

¿Se pueden incluir interacciones?

Sí.

Podemos extender un GAM incluyendo términos de interacción.

Por ejemplo,

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + f_{12}(X_1, X_2) + \varepsilon.$$

Aquí,

$$f_{12}(X_1, X_2)$$

representa un efecto conjunto de las variables X_1 y X_2 .

Para construir estos términos pueden utilizarse, por ejemplo,

- ▶ suavizadores bidimensionales;
- ▶ splines en dos dimensiones;
- ▶ regresión local multivariada.

Costo

Al incluir interacciones aumenta la flexibilidad, pero también disminuye la simplicidad e interpretabilidad del modelo.

GAMs para problemas de clasificación

Los GAMs no se limitan a respuestas continuas.

Supongamos ahora que

$$Y \in \{0, 1\}.$$

En regresión logística tenemos

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p,$$

donde

$$p(X) = P(Y = 1 \mid X).$$

GAMs para problemas de clasificación

Los GAMs no se limitan a respuestas continuas.

Supongamos ahora que

$$Y \in \{0, 1\}.$$

En regresión logística tenemos

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p,$$

donde

$$p(X) = P(Y = 1 \mid X).$$

Un GAM permite reemplazar los efectos lineales por funciones flexibles.

El modelo se convierte en

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p)$$

Este modelo se conoce como un **GAM logístico**.

El modelo se convierte en

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p)$$

Este modelo se conoce como un **GAM logístico**.

La interpretación es similar a la regresión logística:

- ▶ seguimos modelando el *log-odds*;
- ▶ pero permitimos que cada predictor tenga un efecto no lineal.

Ejemplo de clasificación con *Wage*

Supongamos que queremos predecir si un individuo tiene

$$\text{wage} > 250.$$

Definimos

$$Y = \begin{cases} 1, & \text{si } \text{wage} > 250, \\ 0, & \text{en otro caso.} \end{cases}$$

Continuación de ejemplo de clasificación

Podemos construir el modelo

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 \text{ year} + f_2(\text{age}) + f_3(\text{education}),$$

donde

$$p(X) = P(\text{wage} > 250 \mid \text{year, age, education}).$$

En un GAM logístico, una función como

$$f_{\text{age}}(\text{age})$$

describe cómo cambia la contribución de la edad al

$$\log \left(\frac{p}{1-p} \right).$$

Interpretación en clasificación

Si

$$f_{\text{age}}(x) > 0,$$

esa edad contribuye a aumentar la probabilidad del evento, respecto al nivel de referencia del modelo.

Si

$$f_{\text{age}}(x) < 0,$$


contribuye a disminuirla.

Importante

La función suavizada no representa directamente una probabilidad, a menos que la transformemos mediante la función logística.

¿Dónde se encuentran los GAMs?

Podemos pensar en diferentes niveles de flexibilidad:



¿Dónde se encuentran los GAMs?

Los GAMs buscan un compromiso entre

- ▶ **flexibilidad predictiva**, e
- ▶ **interpretabilidad**.

Son más flexibles que una regresión lineal, pero mantienen una estructura mucho más interpretable que muchos modelos completamente no paramétricos.

Regresión no lineal: panorama general

Durante este bloque estudiamos diferentes formas de introducir no linealidad.

Método	Idea principal
Polinomios	agregar $X^2, X^3, \dots$
Step functions	dividir X en regiones
Splines	polinomios locales unidos suavemente
Smoothing splines	suavidad controlada por penalización
Regresión local	ajustar usando vecinos de x_0
GAMs	sumar efectos flexibles de varios predictores

Regresión no lineal: panorama general

Durante este bloque estudiamos diferentes formas de introducir no linealidad.

Método	Idea principal
Polinomios	agregar $X^2, X^3, \dots$
Step functions	dividir X en regiones
Splines	polinomios locales unidos suavemente
Smoothing splines	suavidad controlada por penalización
Regresión local	ajustar usando vecinos de x_0
GAMs	sumar efectos flexibles de varios predictores

Idea de los GAMs

Los GAMs permiten reutilizar muchos de los métodos anteriores como bloques de construcción dentro de un mismo modelo.

Resumiendo los GAMs

Un Modelo Aditivo Generalizado tiene la forma

$$g(E[Y \mid X]) = \beta_0 + \sum_{j=1}^p f_j(X_j),$$

donde g es una función de enlace.

Resumiendo los GAMs

Un Modelo Aditivo Generalizado tiene la forma

$$g(E[Y \mid X]) = \beta_0 + \sum_{j=1}^p f_j(X_j),$$

donde g es una función de enlace.

- ▶ En regresión continua, típicamente g es la identidad.
- ▶ En clasificación binaria, puede utilizarse el enlace logit.
- ▶ Cada f_j puede representar una relación no lineal.
- ▶ Las contribuciones se combinan aditivamente.
- ▶ La estructura mantiene una importante capacidad de interpretación.

Mensaje Central de los GAMs

Mensaje central

Un GAM permite que cada predictor tenga su propia forma, sin abandonar por completo la estructura interpretable de una regresión.