

EXTRA: REGRESIÓN SIMBÓLICA

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM
haydeeperuyero@unam.mx*



ENES
JURIQUILLA

La **regresión simbólica** (*Symbolic Regression*) busca encontrar una expresión matemática que describa la relación entre variables:

$$y = f(x_1, x_2, \dots, x_p).$$

Idea clave

A diferencia de la regresión tradicional, **no especificamos de antemano la forma de f** .

El algoritmo busca tanto:

- ▶ la **estructura de la ecuación**, como
- ▶ los **parámetros** que aparecen en ella.

¿Qué cambia respecto a la regresión tradicional?

En una regresión lineal proponemos una forma funcional:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2,$$

y buscamos los valores óptimos de

$$\beta_0, \beta_1, \beta_2.$$

¿Qué cambia respecto a la regresión tradicional?

En una regresión lineal proponemos una forma funcional:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2,$$

y buscamos los valores óptimos de

$$\beta_0, \beta_1, \beta_2.$$

En regresión simbólica, también se busca la **forma de la función**.

Por ejemplo, el algoritmo podría encontrar:

$$y = 2.3x_1 + \sqrt{x_2}, \quad \text{o} \quad y = \frac{x_1^2}{1 + x_2}.$$

¿Qué le proporcionamos al algoritmo?

En lugar de especificar una ecuación completa, podemos definir las **operaciones permitidas**:

$+$, $-$, $\times$, $/$

y funciones como

$\sqrt{x}$, $\log(x)$, $\exp(x)$, $\sin(x)$, $\cos(x)$.

¿Qué le proporcionamos al algoritmo?

En lugar de especificar una ecuación completa, podemos definir las **operaciones permitidas**:

$$+, \quad -, \quad \times, \quad /$$

y funciones como

$$\sqrt{x}, \quad \log(x), \quad \exp(x), \quad \sin(x), \quad \cos(x).$$

A partir de estas operaciones, el algoritmo construye y evalúa diferentes expresiones.

Importante

Cuanto más operaciones permitamos, **mayor será el espacio de expresiones posibles** y más difícil será la búsqueda.

Incluso con solamente dos variables podemos construir muchas expresiones:

$$x_1 + x_2, \quad x_1 x_2, \quad x_1^2 + x_2,$$

$$\frac{x_1}{1 + x_2^2}, \quad \sin(x_1)x_2, \quad \dots$$

Incluso con solamente dos variables podemos construir muchas expresiones:

$$x_1 + x_2, \quad x_1 x_2, \quad x_1^2 + x_2,$$

$$\frac{x_1}{1 + x_2^2}, \quad \sin(x_1)x_2, \quad \dots$$

Por tanto, la regresión simbólica puede verse como un problema de **búsqueda en un espacio de expresiones matemáticas.**

Precisión vs. complejidad

Supongamos que encontramos dos modelos:

$$f_1(x) = 2x + 1$$

y

$$f_2(x) = 1.97x + 0.031x^2 - 0.004x^3 + 0.12 \sin(2.3x) + 0.98.$$

Precisión vs. complejidad

Supongamos que encontramos dos modelos:

$$f_1(x) = 2x + 1$$

y

$$f_2(x) = 1.97x + 0.031x^2 - 0.004x^3 + 0.12 \sin(2.3x) + 0.98.$$

Si f_2 reduce ligeramente el error, ¿vale la pena aumentar tanto la complejidad?

Busca un equilibrio

Dos objetivos

La regresión simbólica suele buscar un equilibrio entre

precisión

y

simplicidad.

Esto permite obtener modelos con buen ajuste pero que sigan siendo **interpretables**.

¿Por qué puede ser útil?

La regresión simbólica puede producir modelos:

- ▶ **interpretables;**
- ▶ capaces de representar relaciones **no lineales;**
- ▶ que no requieren fijar completamente la forma funcional;
- ▶ potencialmente útiles para generar **hipótesis científicas.**

¿Por qué puede ser útil?

La regresión simbólica puede producir modelos:

- ▶ **interpretables;**
- ▶ capaces de representar relaciones **no lineales;**
- ▶ que no requieren fijar completamente la forma funcional;
- ▶ potencialmente útiles para generar **hipótesis científicas.**

Por ejemplo, a partir de los datos podríamos obtener:

$$\hat{y} = 3.8 + 0.6 \log(1 + x_1) - 0.2\sqrt{x_2}.$$

En lugar de obtener únicamente una predicción, obtenemos una **expresión matemática explícita.**

Una precaución importante

Supongamos que la regresión simbólica encuentra:

$$\hat{y} = 3.8 + 0.6 \log(1 + x_1) - 0.2\sqrt{x_2}.$$

¿Qué podemos concluir?

Una precaución importante

Supongamos que la regresión simbólica encuentra:

$$\hat{y} = 3.8 + 0.6 \log(1 + x_1) - 0.2\sqrt{x_2}.$$

¿Qué podemos concluir?

Cuidado con la interpretación

Una ecuación encontrada a partir de los datos:

- ▶ no implica una relación causal;
- ▶ no necesariamente representa una ley científica;
- ▶ puede depender fuertemente de los datos utilizados;
- ▶ debe evaluarse con datos no utilizados durante el ajuste.

La **interpretabilidad matemática** no sustituye a la **validación científica**.