

EVALUACIÓN Y COMPARACIÓN DE MODELOS

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM
haydeeperuyero@unam.mx*



ENES
JURIQUILLA

1 ¿Qué significa evaluar un modelo?

2 Métricas para regresión

3 Métricas para clasificación

4 Comparar Modelos

5 Selección y refit

6 Evaluación final

7 El flujo completo

8 Nested Cross-Validation

¿QUÉ SIGNIFICA EVALUAR UN MODELO?

¿Dónde estamos?

Hasta ahora hemos estudiado cómo:

- ▶ entrenar diferentes modelos;
- ▶ utilizar Cross-Validation;
- ▶ seleccionar hiperparámetros;
- ▶ utilizar Grid Search y Random Search.

Pero todavía queda una pregunta fundamental:

¿Cómo decidimos qué modelo utilizar?

En un mismo problema podemos tener varios algoritmos que producen predicciones razonables.

¿Qué significa evaluar un modelo?

Una evaluación adecuada debe responder al menos tres preguntas:

1. ¿Qué tipo de error nos interesa medir?
2. ¿Qué tan bien generaliza el modelo?
3. ¿Qué tan estable es su desempeño frente a diferentes particiones de los datos?

Idea clave

Evaluar un modelo no consiste solamente en calcular una métrica.

La métrica depende del problema

No existe una métrica universalmente adecuada para todos los problemas de aprendizaje automático.

La elección debe considerar:

- ▶ el tipo de variable respuesta;
- ▶ el objetivo científico o práctico;
- ▶ la distribución de las clases;
- ▶ el costo de diferentes tipos de error;
- ▶ la interpretación que deseamos dar al resultado.

Importante

Hablar del “mejor desempeño” solamente tiene sentido con respecto a una **métrica y un procedimiento de evaluación determinados**.

MÉTRICAS PARA REGRESIÓN

Supongamos que tenemos valores observados

$$y_1, y_2, \dots, y_n$$

y predicciones

$$\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n.$$

Para cada observación definimos el error

$$e_i = y_i - \hat{y}_i$$

A partir de estos errores podemos construir distintas métricas.

MAE, MSE, RMSE, R^2 .

Mean Absolute Error: MAE

El **Mean Absolute Error** se define como

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Mide el tamaño promedio de los errores en las **mismas unidades que la variable respuesta**.

Por ejemplo, si predecimos una concentración en mg/L:

$$\text{MAE} = 2.3$$

indica un error absoluto promedio de

$$2.3 \text{ mg/L.}$$

MAE: contribución de los errores

En MAE cada error contribuye mediante

$$|e_i|.$$

Por ejemplo:

$$e = 1 \quad \Rightarrow \quad |e| = 1,$$

$$e = 5 \quad \Rightarrow \quad |e| = 5.$$

Característica

La contribución aumenta **linealmente** con el tamaño del error.
Los errores muy grandes no reciben una penalización cuadrática.

Mean Squared Error: MSE

El **Mean Squared Error** se define como

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Cada error contribuye mediante e_i^2 .

Por ejemplo:

$$e = 1 \quad \Rightarrow \quad e^2 = 1 \quad \text{y} \quad e = 5 \quad \Rightarrow \quad e^2 = 25.$$

Consecuencia

Los errores grandes reciben una penalización considerablemente mayor.

Root Mean Squared Error: RMSE

El **Root Mean Squared Error** es

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

A diferencia del MSE, el RMSE se expresa en las **mismas unidades que la variable respuesta**.

$$\text{MSE} \xrightarrow{\sqrt{}} \text{RMSE}$$

MAE vs. RMSE

La diferencia fundamental está en cómo contribuyen los errores.

MAE

$$|e|$$

Penalización lineal.
Menor sensibilidad a errores muy grandes.

RMSE

$$e^2$$

Penalización cuadrática.
Mayor sensibilidad a errores grandes.

Por lo tanto

La elección entre MAE y RMSE también expresa **qué importancia queremos dar a los errores grandes.**

Coeficiente de determinación: R^2

El coeficiente de determinación se define como

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

El numerador representa el error cuadrático del modelo:

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

mientras que el denominador representa la variabilidad de la respuesta alrededor de su media:

$$\sum_{i=1}^n (y_i - \bar{y})^2.$$

Interpretación de R^2

Si $R^2 = 1$, las predicciones coinciden con las observaciones.

Si $R^2 = 0$, el desempeño corresponde, en este sentido, al predictor constante basado en la media.

Y sobre datos nuevos podemos obtener:

$$R^2 < 0$$

¿Qué significa?

De acuerdo con esta métrica, las predicciones son peores que utilizar como referencia una predicción constante basada en la media.

MÉTRICAS PARA CLASIFICACIÓN

Métricas para clasificación

Para clasificación binaria podemos comenzar con la **matriz de confusión**:

	Predicho positivo	Predicho negativo
Real positivo	TP	FN
Real negativo	FP	TN

donde:

- ▶ TP : verdaderos positivos;
- ▶ TN : verdaderos negativos;
- ▶ FP : falsos positivos;
- ▶ FN : falsos negativos.

La exactitud o **accuracy** es

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Representa la proporción total de observaciones correctamente clasificadas.

Puede ser informativa cuando:

- ▶ las clases están razonablemente balanceadas;
- ▶ los diferentes tipos de error tienen costos similares.

Accuracy puede ser engañosa

Supongamos que tenemos 1000 observaciones:

950 pertenecen a la clase 0,

50 pertenecen a la clase 1.

Un clasificador que siempre prediga $\hat{y} = 0$ obtendría

$$\text{Accuracy} = \frac{950}{1000} = \boxed{0.95}.$$

Accuracy puede ser engañosa

Supongamos que tenemos 1000 observaciones:

950 pertenecen a la clase 0,

50 pertenecen a la clase 1.

Un clasificador que siempre prediga $\hat{y} = 0$ obtendría

$$\text{Accuracy} = \frac{950}{1000} = \boxed{0.95}.$$

Pero...

No identificaría **ninguna** observación de la clase 1.

La **precision** se define como

$$\text{Precision} = \frac{TP}{TP + FP}$$

Responde aproximadamente a la pregunta:

De las observaciones que clasificamos como positivas,
¿qué proporción era realmente positiva?

El denominador contiene todas las observaciones que el modelo **predijo como positivas**.

El **recall**, también llamado sensibilidad, es

$$\text{Recall} = \frac{TP}{TP + FN}$$

Responde a la pregunta:

De todas las observaciones realmente positivas,
¿qué proporción identificamos?

El denominador contiene todas las observaciones **realmente positivas**.

Precision vs. Recall

Precision

Partimos de lo que el modelo **predijo positivo**.

$$\frac{TP}{TP + FP}$$

¿Cuántos de nuestros positivos eran correctos?

Recall

Partimos de lo que realmente **era positivo**.

$$\frac{TP}{TP + FN}$$

¿Cuántos positivos logramos encontrar?

El **F1-score** combina precision y recall mediante su media armónica:

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

El F1-score será alto solamente cuando

Precision y Recall

sean razonablemente altos.

Importante!

Idea clave

Accuracy, precision, recall y F1 responden **preguntas diferentes**.

COMPARAR MODELOS

Comparar varios modelos

Supongamos que queremos comparar M algoritmos:

$$A_1, A_2, \dots, A_M.$$

Para cada uno realizamos k -fold Cross-Validation utilizando la **misma métrica**.

Para el modelo A_j obtenemos:

$$s_{j1}, s_{j2}, \dots, s_{jk}.$$

Ya no tenemos un único valor de desempeño para cada modelo.

Tenemos una **distribución de resultados entre folds**.

Para el modelo A_j calculamos:

$$\bar{s}_j = \frac{1}{k} \sum_{\ell=1}^k s_{j\ell}$$

Este valor resume el desempeño promedio observado a través de las diferentes particiones.

Pero el promedio por sí solo no cuenta toda la historia.

¿Qué tan estable fue ese desempeño?

También podemos calcular

$$SD_j = \sqrt{\frac{1}{k-1} \sum_{\ell=1}^k (s_{j\ell} - \bar{s}_j)^2}$$

Así obtenemos dos tipos de información:

nivel de desempeño

+

estabilidad entre particiones

Media y variabilidad

Supongamos que obtenemos:

Modelo	Media	SD
A	0.87	0.08
B	0.86	0.02

El modelo A presenta una media ligeramente mayor, pero también una variabilidad considerablemente mayor entre folds.

Importante

Una pequeña diferencia entre medias de Cross-Validation no debe interpretarse automáticamente como evidencia de una diferencia importante entre los modelos.

Usar las mismas particiones

Si queremos comparar varios modelos, conviene evaluarlos sobre **las mismas particiones**.

Por ejemplo:

Fold 1

Fold 2 $\longrightarrow A_1$

Fold 3 $\longrightarrow A_2$

Fold 4 $\longrightarrow A_3$

Fold 5

De esta manera, en cada iteración todos los algoritmos son evaluados sobre las **mismas observaciones**.

Comparación coherente

Para comparar modelos necesitamos mantener un criterio común:

mismos datos + mismos folds + misma métrica

Si cada algoritmo se evalúa sobre particiones diferentes, parte de la diferencia observada podría deberse simplemente a:

qué observaciones quedaron en cada fold

y no necesariamente al algoritmo.

¿Qué estamos comparando realmente?

Supongamos que comparamos:

Random Forest

Valores por defecto.

Gradient Boosting

Después de una búsqueda
extensa de hiperparámetros.

¿Estamos comparando los dos algoritmos en condiciones equivalentes?

¿Qué estamos comparando realmente?

Supongamos que comparamos:

Random Forest

Valores por defecto.

Gradient Boosting

Después de una búsqueda
extensa de hiperparámetros.

¿Estamos comparando los dos algoritmos en condiciones equivalentes?

No exactamente.

Algoritmo + procedimiento de ajuste

Una estrategia más coherente consiste en definir para cada algoritmo un procedimiento razonable de ajuste:

$$A_1 + \Lambda_1, \quad A_2 + \Lambda_2, \quad A_3 + \Lambda_3,$$

donde Λ_j representa el espacio de hiperparámetros considerado para A_j .

Idea importante

En una aplicación real podemos estar comparando **procedimientos completos de modelado**, no solamente algoritmos con sus valores por defecto.

SELECCIÓN Y REFIT

Selección del modelo

Supongamos que después de Cross-Validation y optimización seleccionamos

$$(A^*, \lambda^*)$$

donde:

A^* = algoritmo seleccionado,

λ^* = hiperparámetros seleccionados.

Hasta este momento hemos utilizado solamente

$$\mathcal{D}_{\text{train}}.$$

Los modelos de CV no usaron todo el training set

Durante k -fold Cross-Validation, cada modelo se entrenó utilizando solamente

$$\frac{k-1}{k}$$

de los datos de entrenamiento.

Por ejemplo, con $k = 5$:

$$\frac{4}{5} = 80\%.$$

Una vez terminada la selección ya conocemos

$$(A^*, \lambda^*).$$

Ahora podemos aprovechar **todo el conjunto de entrenamiento**.

El **refit** consiste en volver a entrenar la configuración seleccionada utilizando todo

$$\mathcal{D}_{\text{train}}.$$

$$\mathcal{D}_{\text{train}} \rightarrow \boxed{\text{CV} + \text{búsqueda}} \rightarrow (A^*, \lambda^*)$$

$$\rightarrow \boxed{\text{entrenar nuevamente con todo } \mathcal{D}_{\text{train}}}$$

EVALUACIÓN FINAL

Evaluación final sobre el test set

Solamente después de completar:

- ▶ selección del algoritmo;
- ▶ selección de hiperparámetros;
- ▶ decisiones de preprocesamiento;
- ▶ selección de la métrica;

utilizamos

$$\boxed{\mathcal{D}_{\text{test}}}.$$

El test proporciona una estimación final sobre datos que no participaron en el desarrollo del modelo.

El test permanece fuera del desarrollo

Si $\hat{f}^*$ es el modelo final reajustado:

$$S_{\text{test}} = S \left(y_{\text{test}}, \hat{f}^*(X_{\text{test}}) \right)$$


Después de observar este resultado no debemos regresar repetidamente al proceso de optimización para mejorar el desempeño sobre el mismo test.

¿Por qué?


El conjunto de prueba comenzaría a funcionar como un nuevo conjunto de validación.

EL FLUJO COMPLETO

El flujo completo de selección



El flujo completo de selección



Idea clave

El test se encuentra **fuera del ciclo de desarrollo.**

¿Qué estamos validando?

Supongamos que antes del modelo realizamos:

imputación $\longrightarrow$ escalamiento $\longrightarrow$ selección de variables $\longrightarrow$ modelo.

Si estas operaciones aprenden información de los datos, forman parte del procedimiento de aprendizaje.

Idea clave

La unidad que debemos validar no es únicamente el algoritmo final. Debemos validar el **procedimiento completo que aprende de los datos**.

No todos los modelos requieren lo mismo

Modelos como

- ▶ árboles de decisión;
- ▶ Random Forest;
- ▶ Gradient Boosting;
- ▶ XGBoost;

no requieren, en general, estandarizar las variables para construir las divisiones de los árboles.

Importante

Un Pipeline no significa

“siempre escalar y después entrenar”.

Significa encapsular correctamente las operaciones que deben aprenderse de los datos antes de producir una predicción.

El desempeño predictivo no es el único criterio

Dos modelos pueden presentar resultados predictivos muy similares y, sin embargo, requerir recursos muy diferentes.

Podemos considerar también:

- ▶ tiempo de entrenamiento;
- ▶ tiempo de predicción;
- ▶ número de modelos ajustados durante la búsqueda;
- ▶ complejidad del modelo final.

La evaluación puede involucrar más de una dimensión.

Un compromiso entre propiedades

Supongamos que obtenemos:

Modelo	CV	SD	Tiempo
A	0.861	0.021	2.1 s
B	0.865	0.024	48.3 s


Esta tabla no determina automáticamente qué modelo debemos utilizar.

Sí muestra que existen compromisos entre:

desempeño, estabilidad, costo computacional.

La comparación puede ser multidimensional

La selección de un modelo puede involucrar:



Por ello, una diferencia pequeña en una métrica predictiva no necesariamente resume todas las diferencias relevantes entre dos procedimientos.

Necesitamos una referencia

Supongamos que obtenemos:

$$\text{RMSE} = 6.0.$$

¿Es un buen resultado?

El valor aislado puede ser difícil de interpretar.

Necesitamos una referencia sencilla contra la cual comparar el modelo:

baseline

Baseline en regresión

Una referencia elemental consiste en ignorar los predictores y predecir siempre una cantidad constante.

Por ejemplo:

$$\hat{y}_i = \bar{y}$$

para todas las observaciones.

Entonces podemos preguntar:

¿Nuestro modelo mejora realmente esta estrategia sencilla?

Baseline en clasificación

Una referencia sencilla puede consistir en predecir siempre la **clase más frecuente**.

Recordemos el ejemplo:

950 observaciones de clase 0, 50 de clase 1.

Predecir siempre clase 0 produce:

$$\text{Accuracy} = 0.95.$$

Esto nos recuerda que una métrica debe interpretarse en relación con:

el problema

+

una referencia adecuada.

Ejemplo conceptual

Queremos comparar:

- ▶ Regresión lineal;
- ▶ Árbol de decisión;
- ▶ Random Forest;
- ▶ Gradient Boosting.

Primero reservamos $\mathcal{D}_{\text{test}}$.

Sobre $\mathcal{D}_{\text{train}}$ definimos para todos $k = 5$ y utilizamos

RMSE

como métrica principal.

Resultados de Cross-Validation

Supongamos que obtenemos:

Modelo	CV RMSE	SD
Regresión lineal	8.3	0.7
Árbol	7.9	1.4
Random Forest	6.8	0.5
Gradient Boosting	6.6	0.6


Estos resultados forman parte del **proceso de comparación**.

Todavía no hemos utilizado el test.

Después de la comparación inicial

Podemos estudiar con mayor detalle algunos modelos mediante optimización de hiperparámetros.

Una vez terminado todo el procedimiento:



Importante

No calculamos el RMSE de test de todos los modelos para después elegir el menor.

¿Qué ocurre si probamos muchas configuraciones?

Supongamos que evaluamos mediante Cross-Validation:

$$\lambda_1, \lambda_2, \dots, \lambda_M.$$

Después seleccionamos:

$$\lambda^* = \arg \max_{\lambda} CV(\lambda).$$

Pero la estimación de Cross-Validation contiene cierta **variabilidad aleatoria**.

Al evaluar muchas configuraciones, tendemos a favorecer aquellas que obtuvieron resultados particularmente buenos durante el proceso de validación.

Por ello una **búsqueda más extensa** $\implies$ **mayor importancia de un test independiente**.

Importante

Cross-Validation reduce los problemas de una única partición, pero no convierte la estimación del desempeño en una cantidad exacta.

NESTED CROSS-VALIDATION

Nested Cross-Validation

Cuando el conjunto de datos es limitado y queremos estimar de manera más rigurosa el desempeño de **todo el procedimiento de selección**, podemos utilizar dos niveles de Cross-Validation.

CV externo [CV interno [optimización]]

Dos niveles de validación

CV interno

Se utiliza para:

tuning

Seleccionar hiperparámetros.

CV externo

Se utiliza para:

evaluación

Evaluar el procedimiento completo.

Costo

Nested Cross-Validation es computacionalmente más costosa y no será el enfoque principal de esta unidad.

Errores frecuentes al evaluar modelos

1. **Evaluar sobre los datos de entrenamiento.**

El modelo ya utilizó estas observaciones para aprender.

2. **Utilizar test para seleccionar hiperparámetros.**

El test deja de ser una evaluación independiente.

3. **Realizar preprocesamiento antes de Cross-Validation.**

Puede producirse fuga de información entre folds.

4. **Utilizar particiones distintas para comparar modelos.**

Parte de las diferencias puede deberse a las particiones.

Errores frecuentes al evaluar modelos

5. Comparar modelos con métricas diferentes.

Ya no estamos utilizando el mismo criterio.

6. Mirar solamente el promedio de CV.

La variabilidad entre folds también contiene información.

7. Ignorar la estructura de los datos.

Puede ser necesario utilizar Group k -fold u otra estrategia.

8. Elegir la métrica después de observar los resultados.

La métrica debe responder al objetivo del problema.


Checklist para una comparación reproducible

- ☐ ¿Separé el test antes de comenzar?
- ☐ ¿Definí una métrica apropiada?
- ☐ ¿La estrategia de CV respeta la estructura de los datos?
- ☐ ¿Los modelos utilizan los mismos folds?
- ☐ ¿El preprocesamiento está dentro del Pipeline?
- ☐ ¿El tuning utiliza sólo datos de entrenamiento?
- ☐ ¿Consideré media y variabilidad de CV?
- ☐ ¿Tengo una baseline razonable?
- ☐ ¿El test se utilizará solamente al final?

Ideas clave

1. La métrica debe responder al **objetivo del problema**.
2. En regresión, MAE, MSE, RMSE y R^2 miden aspectos diferentes.
3. En clasificación, accuracy, precision, recall y F1 responden preguntas diferentes.
4. Los modelos deben compararse utilizando **mismos datos, mismos folds y misma métrica**.
5. Cross-Validation permite estudiar **desempeño y estabilidad**.
6. Una vez seleccionado el modelo realizamos **refit**.
7. El test se utiliza solamente para la **evaluación final**.

Un flujo completo de aprendizaje automático



Idea final

Entrenamiento, validación, optimización y evaluación cumplen **funciones diferentes** dentro del procedimiento de aprendizaje automático.