Clasificador de Margen Máximo

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero
Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



ENES
JURIQUILLA

De la clasificación a las SVM

Las **máquinas de soporte vectorial** (SVM) son una familia de métodos supervisados especialmente importantes para problemas de **clasificación**.

La idea que desarrollaremos será esencialmente geométrica:

construir una frontera que permita separar observaciones pertenecientes a diferentes clases.

Pero seguiremos una construcción progresiva:

$$\text{Hiperplano} \longrightarrow \text{Hiperplano separador} \longrightarrow \text{Margen máximo}$$

$$\longrightarrow \text{Margen suave} \longrightarrow \text{Kernels} \longrightarrow \text{SVM}.$$

El problema de clasificación

Consideremos un problema de **clasificación binaria**.

Tenemos un conjunto de entrenamiento

$$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \ldots, (\mathbf{x}_n, y_n),$$

donde cada observación está descrita por p variables predictoras:

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

El problema de clasificación

Representaremos las dos clases mediante

$$y_i \in \{-1, +1\}.$$

Nuestro objetivo es construir una regla que, dada una nueva observación $\mathbf{x}^*$, permita asignarla a una de las dos clases.

¿Por qué usar -1 y $+1$?

Podríamos utilizar etiquetas como 0 y 1, pero para desarrollar las SVM resulta especialmente conveniente escribir

$$y_i \in \{-1, +1\}.$$

Por ejemplo,

$$y_i = \begin{cases} +1, & \text{si la observación pertenece a la clase 1,} \\ -1, & \text{si la observación pertenece a la clase 2.} \end{cases}$$

Esta elección permitirá escribir las condiciones correspondientes a las dos clases mediante **una sola expresión matemática**.

La idea geométrica

Supongamos, por el momento, que tenemos únicamente dos variables:

$$X_1, \qquad X_2.$$

Cada observación puede representarse como un punto

$$\mathbf{x}_i = (x_{i1}, x_{i2})$$

en el plano.

Pregunta

¿Podemos encontrar una **recta** que deje las observaciones de una clase de un lado y las observaciones de la otra clase del otro?

Esta idea sencilla será el punto de partida de las SVM.

Hiperplanos

En $\mathbb{R}^p$, un **hiperplano** es un subespacio afín de dimensión $p-1$.

Puede escribirse como

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p = 0.$$

Si definimos

$$\boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \qquad \mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix},$$

entonces podemos escribirlo de manera compacta como

$$\boxed{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0.}$$

¿Qué representan los parámetros?

Consideremos nuevamente el hiperplano

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0.$$

- $\mathbf{x}$ representa un punto del espacio de características.
- $\boldsymbol{\beta} = (\beta_1, \ldots, \beta_p)^T$ determina la **orientación** del hiperplano.
- β_0 determina su **desplazamiento** con respecto al origen.

Además, $\boldsymbol{\beta}$ es un vector **normal** al hiperplano.

Hiperplanos en distintas dimensiones

El término *hiperplano* generaliza objetos geométricos que ya conocemos.

Espacio	**Dimensión**	**Hiperplano**
$\mathbb{R}^2$	$p = 2$	recta
$\mathbb{R}^3$	$p = 3$	plano
$\mathbb{R}^p$	p	objeto de dimensión $p - 1$

Por ejemplo, en $\mathbb{R}^2$:

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 = 0.$$

Si $\beta_2 \neq 0$, obtenemos la ecuación de una recta:

$$x_2 = -\frac{\beta_0}{\beta_2} - \frac{\beta_1}{\beta_2} x_1,$$

Los dos lados de un hiperplano

Definamos

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

Entonces existen tres posibilidades:

$$\begin{aligned} f(\mathbf{x}) &= 0, \\ f(\mathbf{x}) &> 0, \\ f(\mathbf{x}) &< 0. \end{aligned}$$

- $f(\mathbf{x}) = 0$: el punto está **sobre el hiperplano**.
- $f(\mathbf{x}) > 0$: el punto está de un lado.
- $f(\mathbf{x}) < 0$: el punto está del otro lado.

Los dos lados de un hiperplano

Idea fundamental

Un hiperplano divide el espacio en **dos regiones**. Esta propiedad nos permitirá utilizarlo como frontera de clasificación.

Clasificación mediante un hiperplano

Utilicemos

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}$$

como nuestra **función de decisión**.

Podemos definir la regla

$$\widehat{y}(\mathbf{x}) = \begin{cases} +1, & f(\mathbf{x}) > 0, \\ -1, & f(\mathbf{x}) < 0. \end{cases}$$

Equivalentemente,

$$\boxed{\widehat{y}(\mathbf{x}) = \operatorname{sign}\left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}\right)}$$

Clasificación mediante un hiperplano

Por tanto,

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0$$

actúa como nuestra **frontera de decisión**.

Hiperplano separador

Supongamos ahora que las dos clases pueden separarse perfectamente mediante un hiperplano.

Queremos que

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i > 0$$

para las observaciones de una clase, y

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i < 0$$

para las observaciones de la otra.

Un hiperplano que cumple estas condiciones se denomina **hiperplano separador**.

Una sola condición para las dos clases

Recordemos que

$$y_i \in \{-1, +1\}.$$

Si $y_i = +1$, queremos

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i > 0.$$

Si $y_i = -1$, queremos

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i < 0.$$

En ambos casos:

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) > 0.$$

Una sola condición para las dos clases

Interpretación

El producto es positivo exactamente cuando el signo de la función de decisión coincide con la clase verdadera.

Veamos los dos casos

La condición

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) > 0$$

resume dos situaciones.

Si $y_i = +1$

$$(+1) \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) > 0$$

implica

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i > 0.$$

Si $y_i = -1$

$$(-1) \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) > 0$$

implica

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i < 0.$$

Esta notación es fundamental para formular el problema de optimización.

¿Existe un único hiperplano separador?

Supongamos que los datos son **linealmente separables**.

Puede existir un gran número de hiperplanos capaces de separar perfectamente las dos clases.

Todos ellos pueden satisfacer

$$\text{error de entrenamiento} = 0.$$

¿Existe un único hiperplano separador?

Supongamos que los datos son **linealmente separables**.

Puede existir un gran número de hiperplanos capaces de separar perfectamente las dos clases.

Todos ellos pueden satisfacer

$$\text{error de entrenamiento} = 0.$$

Pero esto no significa que todos sean igualmente convenientes.

Pregunta

Si muchos hiperplanos clasifican correctamente todas las observaciones de entrenamiento,

¿cuál deberíamos elegir?

No todos los separadores son iguales

Imaginemos varios hiperplanos que producen

$$\text{error de entrenamiento} = 0.$$

Algunos pueden pasar **muy cerca** de ciertas observaciones.

Otros pueden dejar una región mucho más amplia entre la frontera y las observaciones de ambas clases.

¿Podemos utilizar esta separación para elegir una frontera?

La respuesta nos lleva al concepto central de esta sección:

el margen.

La idea del margen

Supongamos que existen varios hiperplanos que separan perfectamente las dos clases.

Una posibilidad natural es elegir aquel que esté lo más alejado posible de las observaciones más cercanas.

Margen

El **margen** de un hiperplano separador es la distancia entre el hiperplano y la observación de entrenamiento más cercana.

Por tanto, buscamos el hiperplano que haga esta distancia **tan grande como sea posible**.

Elegir el hiperplano con margen máximo

Distancia de un punto a un hiperplano

Consideremos el hiperplano

$$H = \left\{ \mathbf{x} \in \mathbb{R}^p : \beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0 \right\}.$$

La distancia de una observación $\mathbf{x}_i$ al hiperplano es

$$\boxed{d(\mathbf{x}_i, H) = \frac{\left| \beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right|}{\|\boldsymbol{\beta}\|}.}$$

donde

$$\|\boldsymbol{\beta}\| = \sqrt{\beta_1^2 + \beta_2^2 + \cdots + \beta_p^2}.$$

El numerador mide qué tan lejos está el punto de satisfacer la ecuación del hiperplano.

¿De dónde sale la fórmula de distancia?

Sea $\mathbf{x}_0$ un punto cualquiera sobre el hiperplano. Entonces

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_0 = 0.$$

El vector

$$\mathbf{x}_i - \mathbf{x}_0$$

va desde un punto del hiperplano hasta $\mathbf{x}_i$.

Como $\boldsymbol{\beta}$ es normal al hiperplano, la distancia corresponde a la magnitud de la proyección de $\mathbf{x}_i - \mathbf{x}_0$ sobre la dirección

$$\frac{\boldsymbol{\beta}}{\|\boldsymbol{\beta}\|}.$$

¿De dónde sale la fórmula de distancia?

Por tanto,

$$d(\mathbf{x}_i, H) = \left| (\mathbf{x}_i - \mathbf{x}_0)^T \frac{\boldsymbol{\beta}}{\|\boldsymbol{\beta}\|} \right|.$$

Continuando,

$$d(\mathbf{x}_i, H) = \frac{\left| \boldsymbol{\beta}^T \mathbf{x}_i - \boldsymbol{\beta}^T \mathbf{x}_0 \right|}{\|\boldsymbol{\beta}\|}.$$

Como $\mathbf{x}_0$ pertenece al hiperplano,

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_0 = 0,$$

¿De dónde sale la fórmula de distancia?

de donde

$$\boldsymbol{\beta}^T \mathbf{x}_0 = -\beta_0.$$

Sustituyendo,

$$\boxed{d(\mathbf{x}_i, H) = \frac{\left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|\boldsymbol{\beta}\|}.}$$

El margen de un hiperplano

Para un hiperplano separador H, cada observación tiene una distancia

$$d(\mathbf{x}_i, H) = \frac{\left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|\boldsymbol{\beta}\|}.$$

Pero el margen está determinado por la observación **más cercana**.

Por tanto,

$$M(H) = \min_{i=1,\ldots,n} d(\mathbf{x}_i, H).$$

El margen de un hiperplano

Es decir,

$$\boxed{M(H) = \min_{i=1,\ldots,n} \frac{\left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|\boldsymbol{\beta}\|}.}$$

No importa qué tan lejos estén la mayoría de los puntos: el margen lo determinan los puntos más cercanos a la frontera.

¿Qué queremos maximizar?

Ahora podemos expresar matemáticamente nuestra idea.

Entre todos los hiperplanos que separan correctamente las clases, queremos encontrar aquel cuyo punto más cercano esté lo más lejos posible.

$$\max_{\beta_0,\boldsymbol{\beta}} \min_{i=1,\ldots,n} \frac{\left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|\boldsymbol{\beta}\|}.$$

sujeto a que todas las observaciones estén correctamente clasificadas:

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) > 0, \qquad i = 1, \ldots, n.$$

Esta es la idea fundamental del **clasificador de margen máximo**.

Un problema: la escala de los coeficientes

El hiperplano

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0$$

no tiene una representación única.

Por ejemplo, multiplicar todos los coeficientes por una constante $c > 0$ produce

$$c\beta_0 + c\boldsymbol{\beta}^T \mathbf{x} = 0,$$

que representa **exactamente el mismo hiperplano**.

Un problema: la escala de los coeficientes

Por ejemplo,

$$1 + 2x_1 - x_2 = 0$$

y

$$2 + 4x_1 - 2x_2 = 0$$

describen la misma recta.

Consecuencia

Los valores de β_0 y $\boldsymbol{\beta}$ dependen de la escala que elijamos para representar el hiperplano.

La distancia no depende de la escala

Aunque los coeficientes cambien, la distancia geométrica no cambia.

Si multiplicamos por $c > 0$,

$$\frac{\left|c\beta_0 + c\boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|c\boldsymbol{\beta}\|} = \frac{c\left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|}{c\|\boldsymbol{\beta}\|}.$$

Por tanto,

$$\frac{\left|c\beta_0 + c\boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|c\boldsymbol{\beta}\|} = \frac{\left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|}{\|\boldsymbol{\beta}\|}.$$

La geometría del problema es independiente de cómo escalemos los coeficientes.

Una primera normalización

Una manera de eliminar la ambigüedad de escala es imponer $\|\boldsymbol{\beta}\| = 1$.

Bajo esta condición,

$$d(\mathbf{x}_i, H) = \left|\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right|.$$

Además, como exigimos clasificación correcta,

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) > 0.$$

Entonces podemos incorporar el signo de la clase y escribir

$$d(\mathbf{x}_i, H) = y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right).$$

Esto simplifica considerablemente la formulación.

Formulación del margen máximo

Introduzcamos una variable M que represente el margen.

Queremos hacer M tan grande como sea posible:

$$\max_{\beta_0, \boldsymbol{\beta}, M} M.$$

sujeto a

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) \geq M, \qquad i = 1, \ldots, n,$$

y

$$\|\boldsymbol{\beta}\| = 1.$$

Formulación del margen máximo

Por tanto,

$$\begin{aligned} \max_{\beta_0, \boldsymbol{\beta}, M} \quad & M \\ \text{sujeto a} \quad & y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) \geq M, \\ & \|\boldsymbol{\beta}\| = 1. \end{aligned}$$

¿Qué significan las restricciones?

Consideremos

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) \geq M.$$

Como $\|\boldsymbol{\beta}\| = 1$, esta cantidad representa la distancia con signo correcto al hiperplano.

Por tanto, la restricción exige que la distancia de cada observación al hiperplano $\geq M$.

Interpretación

Buscamos el valor más grande de M tal que **todas** las observaciones permanezcan al menos a una distancia M de la frontera de decisión.

Las observaciones más cercanas serán las que impidan seguir aumentando M.

Las fronteras del margen

Sea

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

La frontera de decisión es

$$f(\mathbf{x}) = 0.$$

Bajo la normalización $\|\boldsymbol{\beta}\| = 1$, las dos fronteras que delimitan el margen son

$$f(\mathbf{x}) = M \text{ y } f(\mathbf{x}) = -M.$$

Las fronteras del margen

Por tanto, tenemos tres hiperplanos paralelos:

$$\boxed{\begin{aligned} f(\mathbf{x}) &= M, \\ f(\mathbf{x}) &= 0, \\ f(\mathbf{x}) &= -M. \end{aligned}}$$

¿Qué tan ancho es el margen?

La frontera de decisión es

$$f(\mathbf{x}) = 0.$$

Cada uno de los bordes del margen se encuentra a distancia M del hiperplano central.

Por tanto,

$$\text{distancia del hiperplano central al borde superior} = M,$$

y

$$\text{distancia del hiperplano central al borde inferior} = M.$$

¿Qué tan ancho es el margen?

Así, el ancho completo de la región entre ambos bordes es

$$\boxed{2M.}$$

Cuidado con la terminología

En este desarrollo llamamos M a la distancia desde la frontera de decisión hasta la observación más cercana. Por ello, el ancho total entre las dos fronteras del margen es $2M$.

Vectores de soporte

Al maximizar M, algunas observaciones quedarán exactamente sobre los bordes del margen.

Para ellas,

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) = M.$$

Estas observaciones se denominan

vectores de soporte.

Son los puntos que "sostienen" la posición del hiperplano óptimo.

Idea clave

La frontera de decisión depende principalmente de las observaciones más cercanas a ella, no de todas las observaciones por igual.

¿Por qué se llaman vectores de soporte?

Supongamos que una observación está muy lejos de la frontera:

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \gg M.$$

Mover ligeramente esa observación probablemente no cambiará el hiperplano de margen máximo.

En cambio, si una observación satisface

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) = M,$$

está exactamente en el borde del margen.

¿Por qué se llaman vectores de soporte?

Mover ese punto puede cambiar

$$M,$$

y, con ello, la posición u orientación de la frontera óptima.

Los vectores de soporte determinan la solución.

Otra forma de fijar la escala

La normalización $\|\boldsymbol{\beta}\| = 1$ es útil para entender la geometría, pero existe otra formulación especialmente conveniente para optimización.

Podemos escalar los coeficientes de manera que las observaciones más cercanas satisfagan

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) = 1.$$

Entonces todas las observaciones deben satisfacer

$$\boxed{y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 1.}$$

Ahora ya no imponemos $\|\boldsymbol{\beta}\| = 1$.

¿Cuál es ahora la distancia al margen?

Con la nueva escala, las fronteras del margen son

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 1$$

y

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = -1.$$

La frontera de decisión continúa siendo

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0.$$

¿Cuál es ahora la distancia al margen?

La distancia entre la frontera central y cualquiera de los bordes es

$$\frac{1}{\|\boldsymbol{\beta}\|}.$$

Por tanto,

$$\boxed{M = \frac{1}{\|\boldsymbol{\beta}\|}}$$

y el ancho total entre los dos bordes es

$$\boxed{\frac{2}{\|\boldsymbol{\beta}\|}.}$$

Maximizar el margen

Como

$$M = \frac{1}{\|\boldsymbol{\beta}\|},$$

maximizar el margen equivale a minimizar

$$\|\boldsymbol{\beta}\|.$$

Por conveniencia matemática, se utiliza

$$\frac{1}{2}\|\boldsymbol{\beta}\|^2.$$

Maximizar el margen

Así obtenemos el problema

$$\begin{aligned} \min_{\beta_0,\boldsymbol{\beta}} \quad & \frac{1}{2}\|\boldsymbol{\beta}\|^2 \\ \text{sujeto a} \quad & y_i\left(\beta_0 + \boldsymbol{\beta}^T\mathbf{x}_i\right) \geq 1, \\ & i = 1,\ldots,n. \end{aligned}$$

Esta es la formulación clásica del **clasificador de margen máximo**.

¿Por qué minimizar $\frac{1}{2}\|\boldsymbol{\beta}\|^2$?

Queremos maximizar

$$\frac{1}{\|\boldsymbol{\beta}\|}.$$

Esto equivale a minimizar

$$\|\boldsymbol{\beta}\|.$$

Como la función x^2 es creciente para $x \geq 0$, también equivale a minimizar

$$\|\boldsymbol{\beta}\|^2.$$

¿Por qué minimizar $\frac{1}{2}\|\beta\|^2$?

Finalmente, introducir el factor $\frac{1}{2}$ no cambia la solución:

$$\boxed{\min \frac{1}{2}\|\beta\|^2.}$$

La ventaja aparecerá al derivar:

$$\frac{\partial}{\partial \beta}\left(\frac{1}{2}\|\beta\|^2\right) = \beta.$$

Las tres fronteras

Con la normalización anterior tenemos:

$$\underbrace{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0}_{\text{frontera de decisión}},$$

mientras que los bordes del margen son

$$\underbrace{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 1}_{\text{borde de la clase } +1}$$

y

$$\underbrace{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = -1}_{\text{borde de la clase } -1}.$$

Las tres son paralelas porque comparten el mismo vector normal $\boldsymbol{\beta}$.

Clasificador de margen máximo

Podemos resumir el procedimiento:

1. Encontramos un hiperplano que separa perfectamente las dos clases.

2. Entre todos los hiperplanos separadores, buscamos aquel que maximiza la distancia a las observaciones más cercanas.

3. Las observaciones que quedan sobre los bordes del margen son los **vectores de soporte**.

4. Una nueva observación $\mathbf{x}^*$ se clasifica mediante

$$\widehat{y}(\mathbf{x}^*) = \text{sign}\left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}^*\right).$$

¿Qué estamos suponiendo?

Hasta ahora hemos supuesto que existe un hiperplano que satisface

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) \geq 1$$

para **todas** las observaciones.

Esto significa que los datos deben ser p**erfectamente separables mediante un hiperplano**.

Pero en datos reales esta condición puede ser demasiado fuerte.

Problema

¿Qué ocurre si las clases se superponen y no existe ningún hiperplano capaz de clasificarlas perfectamente?

Limitación 1: datos no separables

Si las clases se superponen, no existe ningún $(\beta_0, \boldsymbol{\beta})$ que pueda satisfacer simultáneamente

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 1$$

para todas las observaciones.

En ese caso, el problema de optimización del clasificador de margen máximo **no tiene una solución factible**.

Necesitamos permitir algunas violaciones de las restricciones.

Limitación 2: sensibilidad a observaciones individuales

Incluso cuando las clases son perfectamente separables, puede aparecer otro problema.

Una sola observación situada cerca de la clase contraria puede convertirse en vector de soporte y reducir considerablemente el margen.

Como los vectores de soporte determinan la frontera,

pequeño cambio en un punto $\Longrightarrow$ cambio importante en la frontera.

Así, insistir en clasificar perfectamente todas las observaciones puede producir una frontera demasiado sensible a los datos de entrenamiento.

¿Realmente queremos separación perfecta?

El clasificador de margen máximo exige

cero errores de entrenamiento.

Pero nuestro verdadero objetivo no es necesariamente clasificar perfectamente los datos que ya conocemos.

Queremos obtener una regla que funcione bien sobre **nuevas observaciones**.

Por ello, puede ser conveniente aceptar:

- observaciones dentro del margen,
- e incluso algunas observaciones mal clasificadas,

si esto permite construir una frontera más estable.

Esto nos lleva al margen suave.

¿Cómo implementaremos este clasificador?

Hemos construido matemáticamente el clasificador de margen máximo:

$$\begin{aligned} \min_{\beta_0, \boldsymbol{\beta}} \quad & \frac{1}{2}\|\boldsymbol{\beta}\|^2 \\ \text{sujeto a} \quad & y_i(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i) \geq 1. \end{aligned}$$

En la práctica utilizaremos una herramienta de Python llamada `SVC`.

Esta herramienta implementa un clasificador más general, pero podemos configurarla para aproximar el clasificador de margen máximo cuando los datos son separables.

¿Cómo implementaremos este clasificador?

Por ahora

Utilizaremos una frontera lineal y una configuración que favorezca la separación perfecta.
Los detalles de esta configuración se estudiarán en la siguiente sección.