Clasificadores de soporte vectorial

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



ENES
JURIQUILLA

Del margen máximo al margen suave

En el clasificador de margen máximo exigíamos

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 1, \qquad i = 1, \ldots, n.$$

Es decir:

- todas las observaciones deben estar correctamente clasificadas;
- ninguna observación puede encontrarse dentro del margen.

A este tipo de margen se le denomina

margen duro (hard margin).

Del margen máximo al margen suave

En el clasificador de margen máximo exigíamos

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 1, \qquad i = 1, \ldots, n.$$

Es decir:

- todas las observaciones deben estar correctamente clasificadas;
- ninguna observación puede encontrarse dentro del margen.

A este tipo de margen se le denomina

margen duro (hard margin).

Pero esta condición puede ser demasiado restrictiva.

¿Qué queremos cambiar?

En lugar de exigir una separación perfecta, permitiremos que algunas observaciones:

- se encuentren **dentro del margen**;
- se encuentren exactamente sobre la **frontera de decisión**;
- o incluso se encuentren en el **lado incorrecto de la frontera**.

A cambio de permitir estas violaciones podemos obtener un margen más amplio y una frontera menos sensible a observaciones particulares.

margen suave (soft margin)

La idea del margen suave

Ahora existen dos objetivos que compiten entre sí:

queremos un margen amplio

pero también

queremos pocas violaciones del margen.

No podemos optimizar ambos objetivos independientemente.

Idea clave

El clasificador de soporte vectorial busca un **compromiso** entre el ancho del margen y las violaciones permitidas.

La idea del margen suave

Esta es nuevamente una manifestación del compromiso entre

ajuste y regularización.

¿Por qué permitir errores puede ayudar?

Supongamos que tenemos dos grupos bien diferenciados, pero una observación aparece cerca de la clase contraria.

El clasificador de margen máximo debe acomodar esa observación:

clasificación perfecta $\Longrightarrow$ margen posiblemente muy pequeño.

El margen suave puede aceptar una violación:

pequeño error en entrenamiento $\Longrightarrow$ margen potencialmente mayor.

Generalización

Un modelo que clasifica perfectamente el conjunto de entrenamiento no necesariamente es el que mejor clasificará nuevas observaciones.

Variables de holgura

Para permitir violaciones introducimos, para cada observación i,

$$\boxed{\epsilon_i \geq 0,}$$

denominada **variable de holgura** (*slack variable*).

La restricción del margen duro

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 1$$

se reemplaza por

$$\boxed{y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 1 - \epsilon_i.}$$

ϵ_i mide cuánto permitimos que la observación i **viole el margen**.

$\epsilon_i = 0$: no hay violación

Si

$$\epsilon_i = 0,$$

la restricción es

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) \geq 1.$$

Por tanto, la observación está:

- correctamente clasificada;
- sobre el borde del margen o fuera de él.

$$\boxed{\epsilon_i = 0 \quad \Longrightarrow \quad \text{no viola el margen.}}$$

$0 < \epsilon_i < 1$: dentro del margen

Supongamos ahora que $0 < \epsilon_i < 1$.

Entonces

$$0 < 1 - \epsilon_i < 1.$$

La restricción permite

$$0 < y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) < 1.$$

El producto sigue siendo positivo, así que la observación está **correctamente clasificada**.

Pero ya no alcanza el borde del margen.

$$\boxed{0 < \epsilon_i < 1 \quad \Longrightarrow \quad \text{correcta, pero dentro del margen.}}$$

$\epsilon_i = 1$: frontera de decisión

Si

$$\epsilon_i = 1,$$

la restricción se convierte en

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq 0.$$

En el caso límite,

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) = 0.$$

Como $y_i \neq 0$,

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i = 0.$$

$\epsilon_i = 1$: frontera de decisión

Por tanto,

$$\boxed{\epsilon_i = 1}$$

puede corresponder a una observación situada exactamente sobre la **frontera de decisión**.

$\epsilon_i > 1$: clasificación incorrecta

Finalmente, si

$$\epsilon_i > 1,$$

entonces

$$1 - \epsilon_i < 0.$$

Ahora la restricción permite que

$$y_i \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i \right) < 0.$$

$\epsilon_i > 1$: clasificación incorrecta

Pero recordemos que

$$y_i f(\mathbf{x}_i) < 0$$

significa que el signo de la función de decisión es contrario a la clase verdadera.

Por tanto,

$$\boxed{\epsilon_i > 1 \quad \Longrightarrow \quad \text{la observación puede estar mal clasificada.}}$$

Interpretación de las variables de holgura

Podemos resumir los diferentes casos:

Valor de ϵ_i	**Interpretación**
$\epsilon_i = 0$	Sobre el margen o fuera de él
$0 < \epsilon_i < 1$	Dentro del margen, correctamente clasificada
$\epsilon_i = 1$	Puede encontrarse sobre la frontera de decisión
$\epsilon_i > 1$	Puede estar mal clasificada

Idea

ϵ_i cuantifica cuánto debemos "perdonar" a la observación i para que la restricción pueda cumplirse.

Un detalle importante sobre ϵ_i

La condición

$$\epsilon_i > 1$$

permite que una observación esté mal clasificada, pero no significa que **toda** observación con $\epsilon_i > 1$ necesariamente deba estar mal clasificada si elegimos una holgura mayor de la mínima necesaria.

En la solución óptima, como las holguras son penalizadas, no existe incentivo para hacerlas innecesariamente grandes.

Por eso, en la interpretación habitual de la solución:

$$\epsilon_i > 1$$

está asociado con observaciones que cruzan la frontera de decisión.

¿Podemos permitir cualquier violación?

Si permitiéramos valores arbitrariamente grandes de ϵ_i, podríamos construir un margen enorme simplemente ignorando las observaciones difíciles.

Necesitamos controlar la cantidad total de violaciones.

Una posibilidad es imponer

$$\sum_{i=1}^{n} \epsilon_i \leq C,$$

donde $C \geq 0$ es un parámetro elegido por el usuario.

Ahora tenemos un "presupuesto" total de violaciones.

Formulación con un presupuesto de violaciones

Una formulación del problema de margen suave es

$$
\begin{aligned}
\max_{\beta_0,\boldsymbol{\beta},M,\boldsymbol{\epsilon}} \quad & M \\
\text{sujeto a} \quad & \|\boldsymbol{\beta}\| = 1, \\
& y_i\left(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i\right) \geq M(1-\epsilon_i), \\
& \epsilon_i \geq 0, \qquad i = 1,\ldots,n, \\
& \sum_{i=1}^{n} \epsilon_i \leq C.
\end{aligned}
$$

El objetivo sigue siendo maximizar el margen, pero ahora permitimos que algunas observaciones violen sus bordes.

Interpretación de C: primera formulación

En

$$\sum_{i=1}^{n} \epsilon_i \leq C,$$

C representa un **presupuesto de violaciones**.

Si

$$C = 0,$$

entonces necesariamente

$$\epsilon_1 = \cdots = \epsilon_n = 0.$$

Regresamos al margen duro, siempre que los datos sean separables.

Interpretación de C: primera formulación

En esta formulación:

$$\boxed{C \text{ pequeño} \Longrightarrow \text{pocas violaciones permitidas}}$$

y

$$\boxed{C \text{ grande} \Longrightarrow \text{más violaciones permitidas.}}$$

Cuidado: existen dos convenciones para C

Muy importante

La letra C no se utiliza de la misma manera en todas las formulaciones del clasificador de soporte vectorial.

En la formulación anterior,

$$\sum_{i=1}^{n} \epsilon_i \leq C,$$

C representa un **presupuesto**:

$$C \uparrow \quad \Longrightarrow \quad \text{más violaciones permitidas.}$$

Sin embargo, el software suele utilizar una formulación diferente, en la cual C aparece como una **penalización**.

Formulación mediante penalización

La formulación utilizada habitualmente puede escribirse como

$$\begin{aligned} \min_{\beta_0,\boldsymbol{\beta},\boldsymbol{\epsilon}} \quad & \frac{1}{2}\|\boldsymbol{\beta}\|^2 + C\sum_{i=1}^{n}\epsilon_i \\ \text{sujeto a} \quad & y_i\left(\beta_0 + \boldsymbol{\beta}^T\mathbf{x}_i\right) \geq 1-\epsilon_i, \\ & \epsilon_i \geq 0, \qquad i = 1,\ldots,n. \end{aligned}$$

Ahora podemos ver directamente dos fuerzas que compiten entre sí.

Dos fuerzas en el modelo

Consideremos el objetivo

$$\frac{1}{2}\|\boldsymbol{\beta}\|^2 + C\sum_{i=1}^{n}\epsilon_i.$$

El primer término,

$$\frac{1}{2}\|\boldsymbol{\beta}\|^2,$$

favorece un margen amplio, porque

$$\|\boldsymbol{\beta}\| \downarrow \implies \frac{1}{\|\boldsymbol{\beta}\|} \uparrow .$$

Dos fuerzas en el modelo

El segundo,

$$C \sum_{i=1}^{n} \epsilon_i,$$

penaliza las violaciones.

Esquemáticamente:

$$\boxed{\text{ancho del margen} + C \times \text{violaciones.}}$$

¿Qué ocurre si C es grande?

En la formulación de penalización,

$$\frac{1}{2}\|\beta\|^2 + C\sum_{i=1}^{n}\epsilon_i,$$

si C es grande, cada violación resulta costosa.

Por tanto,

$$C \text{ grande} \Longrightarrow \begin{cases} \text{poca tolerancia a violaciones,} \\ \text{margen potencialmente más estrecho,} \\ \text{ajuste más rígido a entrenamiento.} \end{cases}$$

El modelo intenta evitar valores positivos de ϵ_i, incluso si para ello debe reducir el margen.

¿Qué ocurre si C es pequeño?

Si C es pequeño, las violaciones tienen un costo menor.

Entonces el modelo puede aceptar algunos valores de $\epsilon_i > 0$ si esto permite reducir $\|\boldsymbol{\beta}\|$ y, por tanto, aumentar el margen.

Así,

$$C \text{ pequeño} \Longrightarrow \begin{cases} \text{mayor tolerancia a violaciones,} \\ \text{margen potencialmente más amplio,} \\ \text{mayor regularización.} \end{cases}$$

El C que utilizaremos en la práctica

En `scikit-learn`, por ejemplo,

`SVC(C=...)`

utiliza la convención de **penalización**.

Por tanto, debemos recordar:

$$\boxed{C \downarrow \implies \text{más regularización}}$$

y

$$\boxed{C \uparrow \implies \text{menos regularización.}}$$

El C que utilizaremos en la práctica

No confundir

Esto es lo contrario de la interpretación de C cuando lo utilizamos como presupuesto en

$$\sum_i \epsilon_i \leq C.$$

¿Existe un valor correcto de C?

No existe un valor de C que sea universalmente óptimo.

Un C adecuado depende de:

- los datos;
- la escala de las variables;
- el grado de separación de las clases;
- la presencia de observaciones difíciles o atípicas.

Por tanto,

C es un hiperparámetro.

No debemos elegirlo buscando cuál produce el menor error sobre el conjunto de prueba.

Lo seleccionaremos mediante **validación cruzada**.

Vectores de soporte con margen suave

En el margen máximo, los vectores de soporte eran las observaciones que tocaban los bordes del margen.

Con margen suave, la idea se amplía.

Son relevantes las observaciones que se encuentran:

- exactamente sobre el margen;
- dentro del margen;
- o del lado incorrecto de la frontera.

Estas observaciones son las que determinan el clasificador.

Idea clave

El modelo depende principalmente de las observaciones **difíciles de clasificar**, cercanas a la frontera o que violan el margen.

¿Y los puntos muy alejados?

Supongamos que una observación está correctamente clasificada y muy lejos del margen.

Modificar ligeramente su posición no cambia las restricciones activas que determinan la solución.

Por tanto, esa observación no afecta directamente la posición de la frontera.

En cambio, las observaciones que se encuentran sobre o dentro del margen sí pueden modificar:

$$\boldsymbol{\beta}, \qquad \beta_0, \qquad \text{y el ancho del margen.}$$

De ahí nuevamente el nombre:

vectores de soporte.

El efecto de C sobre los vectores de soporte

En la formulación de penalización, típicamente C pequeño permite más violaciones y favorece un margen más amplio.

Como consecuencia, más observaciones pueden quedar sobre o dentro del margen.

Por ello, en general esperamos:

$$C \text{ pequeño} \Longrightarrow \text{más vectores de soporte.}$$

En cambio,

$$C \text{ grande} \Longrightarrow \text{menos vectores de soporte.}$$

Cuidado

Esta es una tendencia general, no una regla absoluta para cualquier conjunto de datos.

Margen duro vs. margen suave

	Margen duro	**Margen suave**
Separación	Debe ser perfecta	Permite violaciones
Datos no separables	Problema	Puede manejarlos
Margen	Máximo sin errores	Compromiso margen–violaciones
Sensibilidad	Puede ser alta	Puede ser menor
Holguras	No	$\epsilon_i \geq 0$

Pero la frontera sigue siendo lineal

Hemos realizado un cambio importante:

$$\text{margen duro} \quad \longrightarrow \quad \text{margen suave.}$$

Ahora podemos manejar observaciones que se traslapan y permitir ciertas violaciones.

Pero la frontera sigue siendo lineal

Hemos realizado un cambio importante:

$$\text{margen duro} \quad \longrightarrow \quad \text{margen suave.}$$

Ahora podemos manejar observaciones que se traslapan y permitir ciertas violaciones.

Sin embargo, nuestra frontera continúa siendo

$$\boxed{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0.}$$

En $\mathbb{R}^2$ sigue siendo una recta.

En $\mathbb{R}^3$ sigue siendo un plano.

En $\mathbb{R}^p$ sigue siendo un hiperplano.

Una nueva limitación

Imaginemos ahora datos con esta estructura:

- una clase concentrada aproximadamente en el centro;
- otra clase distribuida formando un anillo alrededor.

No importa cuánto ajustemos C:

ninguna recta puede separar adecuadamente las clases.

El margen suave resuelve el problema de las **violaciones**, pero no cambia la forma de la frontera.

Nueva pregunta

¿Cómo podemos construir fronteras de decisión **no lineales**?

Hacia las máquinas de soporte vectorial

Una posibilidad sería crear nuevas variables, por ejemplo

$$x_1^2, \qquad x_2^2, \qquad x_1 x_2,$$

y trabajar en un espacio de características más rico.

Una frontera que sea lineal en ese nuevo espacio puede corresponder a una frontera **no lineal** en el espacio original.

Hacia las máquinas de soporte vectorial

Esto nos llevará a una de las ideas centrales de las SVM:

los kernels.

Y con ellos pasaremos de

clasificador de soporte vectorial

a

máquina de soporte vectorial.