Máquinas de Soporte Vectorial

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



De un clasificador lineal a una SVM

Hasta ahora hemos construido dos métodos:

1. **Clasificador de margen máximo:** frontera lineal y separación perfecta.
2. **Clasificador de soporte vectorial:** frontera lineal, pero con margen suave.

Ambos tienen una característica en común:

$$\boxed{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0}$$

sigue siendo un hiperplano.

Limitación

¿Qué ocurre cuando la verdadera frontera entre las clases es **no lineal**?

Fronteras de decisión no lineales

Consideremos dos variables predictoras,

$$X_1, \qquad X_2.$$

Supongamos que una clase se concentra aproximadamente en el centro y la otra forma un anillo alrededor.

No existe una recta

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 = 0$$

que permita separar adecuadamente ambas clases.

Modificar C puede cambiar el ancho del margen y las violaciones,

pero la frontera continúa siendo una recta.

Una idea que ya conocemos

Este problema es parecido a algo que ya encontramos en regresión.

Si una relación no es lineal, en lugar de utilizar únicamente X, podemos incorporar transformaciones como

$$X^2, \qquad X^3, \qquad \ldots$$

Por ejemplo,

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon.$$

Aunque el modelo es lineal en los coeficientes

$$\beta_0, \beta_1, \beta_2, \beta_3,$$

puede representar una relación no lineal entre X y Y.

Ampliar el espacio de características

Podemos aplicar la misma idea a clasificación.

Supongamos que originalmente tenemos

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}.$$

Podríamos reemplazarla por

$$\phi(\mathbf{x}) = \begin{pmatrix} x_1 \\ x_2 \\ x_1^2 \\ x_2^2 \\ x_1 x_2 \end{pmatrix}.$$

Ampliar el espacio de características

Hemos pasado de

$$\mathbb{R}^2$$

a un espacio de características de mayor dimensión.

Lineal en un espacio, no lineal en otro

En el espacio transformado podríamos ajustar una frontera lineal:

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 = 0.$$

Esta expresión es lineal respecto a las **características transformadas**

$$x_1, \quad x_2, \quad x_1^2, \quad x_2^2, \quad x_1 x_2.$$

Pero, vista en el espacio original (x_1, x_2), define una frontera

no lineal.

Esta observación será fundamental para construir las SVM.

La transformación ϕ

Podemos expresar esta idea de forma general mediante una transformación

$$\phi : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

con

$$\mathbf{x} \longmapsto \phi(\mathbf{x}).$$

En lugar de buscar una frontera lineal en el espacio original, $\mathbf{x}$, buscamos una frontera lineal en $\phi(\mathbf{x})$.

Idea clave

Una frontera lineal en el espacio transformado puede corresponder a una frontera no lineal en el espacio original.

Un ejemplo geométrico

Supongamos, para simplificar, que tenemos dos variables:

$$\mathbf{x} = (x_1, x_2)^T.$$

Consideremos la transformación

$$\phi(\mathbf{x}) = \begin{pmatrix} x_1 \\ x_2 \\ x_1^2 + x_2^2 \end{pmatrix}.$$

En el espacio original tenemos puntos en $\mathbb{R}^2$. Después de la transformación, cada punto se encuentra en $\mathbb{R}^3$.

Una estructura circular difícil de separar en $\mathbb{R}^2$ puede resultar mucho más sencilla de separar mediante un plano en $\mathbb{R}^3$.

Entonces, ¿por qué necesitamos kernels?

Podríamos construir explícitamente todas las nuevas características:

$$x_1^2, \quad x_2^2, \quad x_1 x_2, \quad x_1^3, \quad x_1^2 x_2, \quad x_1 x_2^2, \quad \ldots$$

Pero el número de características puede crecer rápidamente.

Si tenemos:

- muchos predictores;
- transformaciones de grado alto;
- interacciones entre variables;

el espacio transformado puede ser de dimensión muy grande.

Problema

¿Podemos aprovechar un espacio de características rico **sin construir explícitamente todas esas variables**?

Un paso aparentemente extraño

Para responder la pregunta anterior necesitamos observar cómo puede escribirse el clasificador de soporte vectorial.

Hasta ahora hemos utilizado

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

Pero la solución también puede expresarse en términos de las observaciones de entrenamiento:

$$f(\mathbf{x}) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle.$$

donde $\langle \mathbf{x}, \mathbf{x}_i \rangle = \mathbf{x}^T \mathbf{x}_i$ es el producto interno.

Una nueva forma de pensar la predicción

Antes pensábamos en la función de decisión como

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

Ahora podemos pensarla como

$$f(\mathbf{x}) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle.$$

Esto cambia nuestra interpretación:

la predicción puede construirse a partir de **comparaciones entre la nueva observación y las observaciones de entrenamiento**.

La cantidad $\langle \mathbf{x}, \mathbf{x}_i \rangle$ mide una forma de similitud entre ambas observaciones.

¿Dónde están los vectores de soporte?

Tenemos

$$f(\mathbf{x}) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle.$$

Pero para las observaciones que **no** son vectores de soporte, $\alpha_i = 0$.

Por tanto, desaparecen de la suma.

Si S es el conjunto de índices de los vectores de soporte,

$$f(\mathbf{x}) = \beta_0 + \sum_{i \in S} \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle.$$

La predicción depende directamente sólo de los **vectores de soporte**.

Una interpretación del nombre

Los vectores de soporte no sólo determinan geométricamente la posición del margen.

También son las observaciones que aparecen directamente en

$$f(\mathbf{x}) = \beta_0 + \sum_{i \in S} \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle.$$

Las observaciones alejadas del margen tienen

$$\alpha_i = 0$$

y no participan directamente en la expresión final.

Idea clave

Los vectores de soporte son las observaciones que "sostienen" la función de decisión.

¿Qué ocurre en el espacio transformado?

Supongamos ahora que trabajamos con

$$\phi(\mathbf{x})$$

en lugar de $\mathbf{x}$.

La función de decisión involucraría productos internos de la forma

$$\langle \phi(\mathbf{x}), \phi(\mathbf{x}_i) \rangle \, .$$

En principio podríamos:

1. calcular $\phi(\mathbf{x})$;
2. calcular $\phi(\mathbf{x}_i)$;
3. calcular su producto interno.

¿Qué ocurre en el espacio transformado?

Pero quizá exista una manera de obtener directamente

$$\langle \phi(\mathbf{x}), \phi(\mathbf{x}_i) \rangle$$

sin construir explícitamente ϕ.

De productos internos a kernels

La observación anterior es la clave.

Reemplazamos el producto interno $\langle \mathbf{x}_i, \mathbf{x}_{i'} \rangle$ por una función más general

$$\boxed{K(\mathbf{x}_i, \mathbf{x}_{i'}).}$$

Kernel

Un **kernel** es una función

$$K(\mathbf{x}_i, \mathbf{x}_{i'})$$

que cuantifica la similitud entre dos observaciones y puede utilizarse en lugar del producto interno dentro de la construcción del clasificador de soporte vectorial.

La función de decisión de una SVM

Al introducir un kernel, la función de decisión toma la forma

$$\boxed{f(\mathbf{x}) = \beta_0 + \sum_{i \in S} \alpha_i K(\mathbf{x}, \mathbf{x}_i).}$$

La predicción continúa determinada por el signo:

$$\boxed{\widehat{y}(\mathbf{x}) = \operatorname{sign}\left(f(\mathbf{x})\right).}$$

Pero ahora la similitud entre $\mathbf{x}$ y los vectores de soporte no tiene que ser simplemente

$$\mathbf{x}^T \mathbf{x}_i.$$

Podemos utilizar funciones de similitud mucho más flexibles.

¿Qué hace realmente un kernel?

Conceptualmente, podemos imaginar una transformación $\phi(\mathbf{x})$ hacia un espacio de características posiblemente mucho mayor:

$$\mathbf{x} \longmapsto \phi(\mathbf{x}).$$

En ese espacio calcularíamos

$$\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_{i'}) \rangle \, .$$

Un kernel permite obtener directamente esa cantidad:

$$\boxed{K(\mathbf{x}_i, \mathbf{x}_{i'}) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_{i'}) \rangle \, .}$$

sin calcular explícitamente las transformaciones.

El truco del kernel

Sin kernels, seguiríamos el procedimiento

$$\mathbf{x}_i, \mathbf{x}_{i'} \longrightarrow \phi(\mathbf{x}_i), \phi(\mathbf{x}_{i'}) \longrightarrow \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_{i'}) \rangle \, .$$

El kernel permite hacer directamente

$$\boxed{\mathbf{x}_i, \mathbf{x}_{i'} \longrightarrow K(\mathbf{x}_i, \mathbf{x}_{i'}).}$$

A esta idea se le conoce como

truco del kernel (kernel trick).

¿Por qué es un "truco"?

El modelo se comporta como si hubiera transformado

$$\mathbf{x} \longmapsto \phi(\mathbf{x})$$

y después hubiera trabajado en ese espacio de mayor dimensión.

Pero no necesitamos construir explícitamente todas las componentes de $\phi(\mathbf{x})$.

Idea clave

El kernel permite trabajar **implícitamente** en un espacio de características de mayor dimensión.

Esto permite construir fronteras muy flexibles sin generar explícitamente una enorme cantidad de nuevas variables.

Kernel lineal

El kernel más sencillo es

$$K(\mathbf{x}_i, \mathbf{x}_{i'}) = \langle \mathbf{x}_i, \mathbf{x}_{i'} \rangle .$$

Equivalentemente,

$$K(\mathbf{x}_i, \mathbf{x}_{i'}) = \sum_{j=1}^{p} x_{ij} x_{i'j}.$$

Aquí no introducimos una transformación no lineal. Por tanto,

$$\text{kernel lineal} \Longrightarrow \text{frontera lineal.}$$

Es esencialmente el clasificador de soporte vectorial lineal que ya construimos. Cuantifica similaridad de pares de observaciones usando correlación de Pearson.

Kernel polinomial

Una alternativa es el **kernel polinomial**.

Una forma común es

$$K(\mathbf{x}_i, \mathbf{x}_{i'}) = (1 + \langle \mathbf{x}_i, \mathbf{x}_{i'} \rangle)^d,$$

donde d es el grado del polinomio.

Si $d = 1$, obtenemos esencialmente una frontera lineal.

Pero si $d > 1$, el modelo puede construir fronteras no lineales.

¿Qué está escondiendo el kernel polinomial?

Consideremos dos observaciones

$$\mathbf{x} = (x_1, x_2)^T, \qquad \mathbf{z} = (z_1, z_2)^T.$$

Para un kernel polinomial de grado 2,

$$K(\mathbf{x}, \mathbf{z}) = \left(1 + \mathbf{x}^T \mathbf{z}\right)^2.$$

Como

$$\mathbf{x}^T \mathbf{z} = x_1 z_1 + x_2 z_2,$$

tenemos

$$K(\mathbf{x}, \mathbf{z}) = (1 + x_1 z_1 + x_2 z_2)^2.$$

Desarrollando el kernel polinomial

Tenemos

$$(1 + x_1 z_1 + x_2 z_2)^2.$$

Al desarrollar:

$$K(\mathbf{x}, \mathbf{z}) = 1 + 2x_1 z_1 + 2x_2 z_2 + x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2.$$

Aquí aparecen implícitamente términos asociados con

$$1, \qquad x_1, \qquad x_2, \qquad x_1^2, \qquad x_1 x_2, \qquad x_2^2.$$

Es decir, el kernel está trabajando con un espacio de características más rico.

La transformación escondida

Podemos definir

$$\phi(\mathbf{x}) = \begin{pmatrix} 1 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \end{pmatrix}.$$

La transformación escondida

De manera análoga,

$$\phi(\mathbf{z}) = \begin{pmatrix} 1 \\ \sqrt{2}z_1 \\ \sqrt{2}z_2 \\ z_1^2 \\ \sqrt{2}z_1 z_2 \\ z_2^2 \end{pmatrix}.$$

La transformación escondida

Entonces

$$\phi(\mathbf{x})^T \phi(\mathbf{z}) = (1 + \mathbf{x}^T \mathbf{z})^2.$$

Por tanto,

$$K(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z}).$$

¿Dónde está la ventaja?

Podríamos construir explícitamente

$$\phi(\mathbf{x}) = \begin{pmatrix} 1 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \end{pmatrix}$$

y después calcular el producto interno.

Pero el kernel nos permite calcular simplemente

$$\boxed{K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^T\mathbf{z})^2.}$$

¿Dónde está la ventaja?

En este ejemplo sólo evitamos construir seis componentes.

Pero con muchos predictores y grados mayores, el número de características explícitas puede crecer considerablemente.

Ahí aparece la verdadera utilidad del truco del kernel.

¿Qué controla el grado d?

En el kernel

$$K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^T \mathbf{z})^d,$$

el parámetro d controla la complejidad de las interacciones polinomiales que pueden aparecer.

En términos generales:

$$d \text{ pequeño} \quad \Longrightarrow \quad \text{fronteras menos flexibles,}$$

mientras que

$$d \text{ grande} \quad \Longrightarrow \quad \text{fronteras potencialmente más complejas.}$$

Hasta ahora

Ya tenemos tres ideas fundamentales:

Margen suave	Transformación ϕ
$\Downarrow$	$\Downarrow$
permite violaciones	mayor flexibilidad

y

Kernel

$\Downarrow$

trabajo implícito en el espacio transformado

Cuando el clasificador de soporte vectorial se combina con un kernel no lineal, el clasificador resultante es conocido como **máquina de soporte vectorial**.

Kernel radial

Otro kernel especialmente importante es el **kernel radial**, también conocido como kernel RBF (*Radial Basis Function*).

Se define como

$$\boxed{K(\mathbf{x}_i, \mathbf{x}_{i'}) = \exp\left(-\gamma \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2\right),}$$

donde

$$\gamma > 0.$$

Utilizando la distancia euclidiana,

$$\boxed{K(\mathbf{x}_i, \mathbf{x}_{i'}) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_{i'}\|^2\right).}$$

¿Qué mide el kernel radial?

Consideremos

$$K(\mathbf{x}, \mathbf{z}) = \exp\left(-\gamma \|\mathbf{x} - \mathbf{z}\|^2\right).$$

La cantidad

$$\|\mathbf{x} - \mathbf{z}\|^2$$

mide qué tan alejadas están las dos observaciones. Por tanto, el kernel RBF transforma una **distancia** en una medida de **similitud**.

distancia pequeña $\Longrightarrow$ similitud grande

distancia grande $\Longrightarrow$ similitud pequeña

Dos observaciones muy cercanas

Si $\mathbf{x}$ y $\mathbf{z}$ están muy cerca,

$$\|\mathbf{x} - \mathbf{z}\|^2 \approx 0.$$

Entonces

$$-\gamma\|\mathbf{x} - \mathbf{z}\|^2 \approx 0,$$

y por tanto

$$K(\mathbf{x}, \mathbf{z}) \approx e^0.$$

Dos observaciones muy cercanas

Así,

$$K(\mathbf{x}, \mathbf{z}) \approx 1.$$

Dos observaciones muy cercanas tienen una similitud RBF cercana a 1.

Dos observaciones muy alejadas

Si $\mathbf{x}$ y $\mathbf{z}$ están muy alejadas,

$$\|\mathbf{x} - \mathbf{z}\|^2$$

será grande.

Entonces

$$-\gamma\|\mathbf{x} - \mathbf{z}\|^2$$

será un número negativo de gran magnitud y

$$\exp\left(-\gamma\|\mathbf{x} - \mathbf{z}\|^2\right) \approx 0.$$

Dos observaciones muy alejadas

Por tanto,

$$\boxed{K(\mathbf{x}, \mathbf{z}) \approx 0.}$$

El kernel radial puede interpretarse como una medida de **similitud local**.

Valores posibles del kernel RBF

Como

$$\|\mathbf{x} - \mathbf{z}\|^2 \geq 0$$

y $\gamma > 0$, tenemos

$$-\gamma\|\mathbf{x} - \mathbf{z}\|^2 \leq 0.$$

Por tanto,

$$0 < \exp\left(-\gamma\|\mathbf{x} - \mathbf{z}\|^2\right) \leq 1.$$

Valores posibles del kernel RBF

Así,

$$\boxed{0 < K(\mathbf{x}, \mathbf{z}) \leq 1.}$$

Además,

$$K(\mathbf{x}, \mathbf{x}) = 1.$$

Una observación tiene similitud máxima consigo misma.

¿Qué significa esto para una predicción?

Recordemos la función de decisión de una SVM:

$$f(\mathbf{x}) = \beta_0 + \sum_{i \in S} \alpha_i K(\mathbf{x}, \mathbf{x}_i).$$

Con un kernel RBF,

$$f(\mathbf{x}) = \beta_0 + \sum_{i \in S} \alpha_i \exp\left(-\gamma \|\mathbf{x} - \mathbf{x}_i\|^2\right).$$

Por tanto, para clasificar una nueva observación $\mathbf{x}$, el modelo compara su posición con la de los **vectores de soporte**.

Una interpretación local

Consideremos un vector de soporte $\mathbf{x}_i$.

Si la nueva observación $\mathbf{x}$ está cerca de él,

$$K(\mathbf{x}, \mathbf{x}_i) \approx 1,$$

por lo que ese vector de soporte puede tener una contribución importante en $f(\mathbf{x})$.

Si $\mathbf{x}$ está muy lejos, $K(\mathbf{x}, \mathbf{x}_i) \approx 0$, y su contribución será pequeña.

Idea clave

Con el kernel RBF, los vectores de soporte ejercen una influencia principalmente **local**.

El papel de γ

En

$$K(\mathbf{x}, \mathbf{z}) = \exp\left(-\gamma \|\mathbf{x} - \mathbf{z}\|^2\right),$$

el parámetro γ controla qué tan rápidamente disminuye la similitud cuando aumenta la distancia.

Por tanto, γ determina la **escala de influencia** de cada observación.

γ pequeño $\Longrightarrow$ influencia más amplia

γ grande $\Longrightarrow$ influencia más local

γ pequeño

Si γ es pequeño,

$$-\gamma\|\mathbf{x}-\mathbf{z}\|^2$$

cambia lentamente cuando aumenta la distancia.

Por tanto, incluso observaciones relativamente alejadas pueden tener $K(\mathbf{x},\mathbf{z})$ considerablemente mayor que cero.

En términos geométricos:

$$\boxed{\gamma \text{ pequeño} \Longrightarrow \text{regiones de influencia amplias.}}$$

Esto suele producir fronteras de decisión más suaves y menos locales.

γ grande

Si γ es grande,

$$\exp\left(-\gamma\|\mathbf{x}-\mathbf{z}\|^2\right)$$

disminuye rápidamente al aumentar la distancia.

Por tanto, un vector de soporte puede influir fuertemente sólo sobre una región pequeña a su alrededor.

$$\boxed{\gamma \text{ grande} \Longrightarrow \text{influencia muy local.}}$$

Esto permite construir fronteras mucho más irregulares y flexibles.

Una forma de visualizar γ

Para una distancia fija d,

$$K(d) = e^{-\gamma d^2}.$$

Consideremos, por ejemplo,

$$d = 1.$$

Entonces:

γ	$K(d)$
0.1	$e^{-0.1} \approx 0.905$
1	$e^{-1} \approx 0.368$
10	$e^{-10} \approx 0.000045$

Una forma de visualizar γ

La distancia entre los puntos es exactamente la misma.

Lo que cambia es cuánto consideramos que esa distancia reduce su similitud.

Flexibilidad y γ

Podemos pensar esquemáticamente:

$$\gamma \downarrow \implies \text{efectos más globales} \implies \text{frontera más suave,}$$

mientras que

$$\gamma \uparrow \implies \text{efectos más locales} \implies \text{frontera más compleja.}$$

Importante

Una frontera más compleja no es necesariamente una frontera mejor. Valores muy grandes de γ pueden hacer que el modelo se adapte demasiado a observaciones particulares.

¿Por qué pueden aparecer “islas”?

Con un valor grande de γ, la influencia de cada vector de soporte es muy local.

Supongamos que una observación de una clase aparece rodeada principalmente por observaciones de la otra clase.

La SVM puede construir una pequeña región de decisión alrededor de esa observación.

Así pueden aparecer fronteras con pequeñas

“islas” de clasificación.

Estas regiones no son un error del algoritmo: son consecuencia de la alta flexibilidad que permite un γ grande.

Dos hiperparámetros diferentes

Con un kernel RBF aparecen dos hiperparámetros especialmente importantes:

$$\boxed{C} \qquad \text{y} \qquad \boxed{\gamma}.$$

Pero controlan aspectos diferentes.

- C controla cuánto penalizamos las **violaciones del margen**.
- γ controla el alcance de la **influencia local** de las observaciones.

Por tanto, no debemos interpretar C y γ como si fueran dos versiones del mismo parámetro.

Interacción entre C y γ

Los efectos de C y γ no deben estudiarse completamente por separado.

Por ejemplo, C grande penaliza fuertemente las violaciones, mientras que γ grande permite respuestas muy locales.

La combinación

$$\boxed{C \text{ grande} \quad + \quad \gamma \text{ grande}}$$

puede producir una frontera extremadamente adaptada a los datos de entrenamiento.

C grande y γ grande

Si ambos parámetros son grandes:

- las violaciones son costosas;
- cada observación puede ejercer una influencia muy local;
- la frontera puede doblarse para acomodar observaciones individuales.

Esto puede producir:

muy buen ajuste en entrenamiento

pero

peor generalización.

C grande y γ grande

Posible consecuencia

Una frontera muy sinuosa, con pequeñas regiones alrededor de puntos individuales, puede ser una señal de sobreajuste.

C pequeño y γ pequeño

Consideremos ahora la situación opuesta.

Un C pequeño permite más violaciones y favorece mayor regularización.

Un γ pequeño hace que la influencia de las observaciones sea más amplia.

La combinación

$$\boxed{C \text{ pequeño} \quad + \quad \gamma \text{ pequeño}}$$

tiende a producir una frontera más suave y regularizada.

Si la regularización es excesiva, el modelo puede ser demasiado simple para capturar la estructura de los datos.

Los cuatro escenarios

De manera esquemática:

	γ pequeño	γ grande
C pequeño	suave y regularizado	local, pero tolerante
C grande	global, pero rígido	muy flexible y local

Importante

Estas son tendencias generales.
El comportamiento exacto depende de los datos, por lo que C y γ deben seleccionarse utilizando datos de entrenamiento y validación.

¿Cómo elegimos C y γ?

No elegimos C y γ observando cuál combinación funciona mejor sobre el conjunto de prueba.

Podemos considerar una rejilla como

$$C \in \{0.01, 0.1, 1, 10, 100\},$$

$$\gamma \in \{0.001, 0.01, 0.1, 1, 10\}.$$

y evaluar las diferentes combinaciones mediante **validación cruzada**.

El conjunto de prueba se reserva para una evaluación final del modelo seleccionado.

Importancia del escalamiento

Las SVM son sensibles a la escala de las variables predictoras.

Esto es particularmente claro para el kernel RBF:

$$K(\mathbf{x}, \mathbf{z}) = \exp\left(-\gamma \|\mathbf{x} - \mathbf{z}\|^2\right).$$

Recordemos que

$$\|\mathbf{x} - \mathbf{z}\|^2 = \sum_{j=1}^{p} (x_j - z_j)^2.$$

Por tanto, la escala de cada predictor afecta directamente la distancia entre las observaciones.

Un problema de escalas

Supongamos que tenemos dos variables:

$$X_1 \in [0, 1]$$

y

$$X_2 \in [0, 10000].$$

La distancia contiene

$$(x_1 - z_1)^2 + (x_2 - z_2)^2.$$

Las diferencias en X_2 pueden ser miles de veces mayores que las diferencias en X_1.

Un problema de escalas

Entonces,

$$\boxed{X_2 \text{ dominará la distancia euclidiana.}}$$

Esto puede ocurrir incluso si X_1 contiene información importante para la clasificación.

Estandarización

Una solución habitual es estandarizar cada predictor:

$$Z_j = \frac{X_j - \overline{X}_j}{s_j}.$$

Después de esta transformación, cada variable tiene aproximadamente

$$\text{media} = 0$$

y

$$\text{desviación estándar} = 1.$$

Así evitamos que una variable domine las distancias simplemente porque está medida en una escala numéricamente mayor.

Cuidado con la fuga de información

Los parámetros de la estandarización,

$$\overline{X}_j \qquad \text{y} \qquad s_j,$$

deben estimarse utilizando únicamente los **datos de entrenamiento**.

No debemos utilizar el conjunto completo antes de separar entrenamiento y prueba.

En validación cruzada, el escalamiento también debe volver a estimarse dentro de cada partición de entrenamiento.

En la práctica

Por esta razón utilizaremos un `Pipeline` que contenga tanto el escalamiento como la SVM.

Tres kernels importantes

Hasta ahora hemos estudiado:

Kernel	**Expresión**
Lineal	$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z}$
Polinomial	$K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^T \mathbf{z})^d$
RBF	$K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2)$

Cada elección define una manera diferente de comparar observaciones y, por tanto, una familia diferente de fronteras de decisión.

Kernel lineal vs. polinomial vs. RBF

Kernel lineal: Mantiene una frontera lineal.

$$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z}$$

Kernel polinomial: Introduce interacciones polinomiales.

$$K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^T \mathbf{z})^d$$

Kernel RBF: Introduce una noción de similitud local y permite fronteras altamente flexibles.

$$K(\mathbf{x}, \mathbf{z}) = e^{-\gamma \|\mathbf{x} - \mathbf{z}\|^2}$$

¿Cuándo tenemos realmente una SVM?

Conviene distinguir claramente los tres modelos.

Clasificador de margen máximo

Frontera lineal, margen máximo y separación perfecta.

Clasificador de soporte vectorial

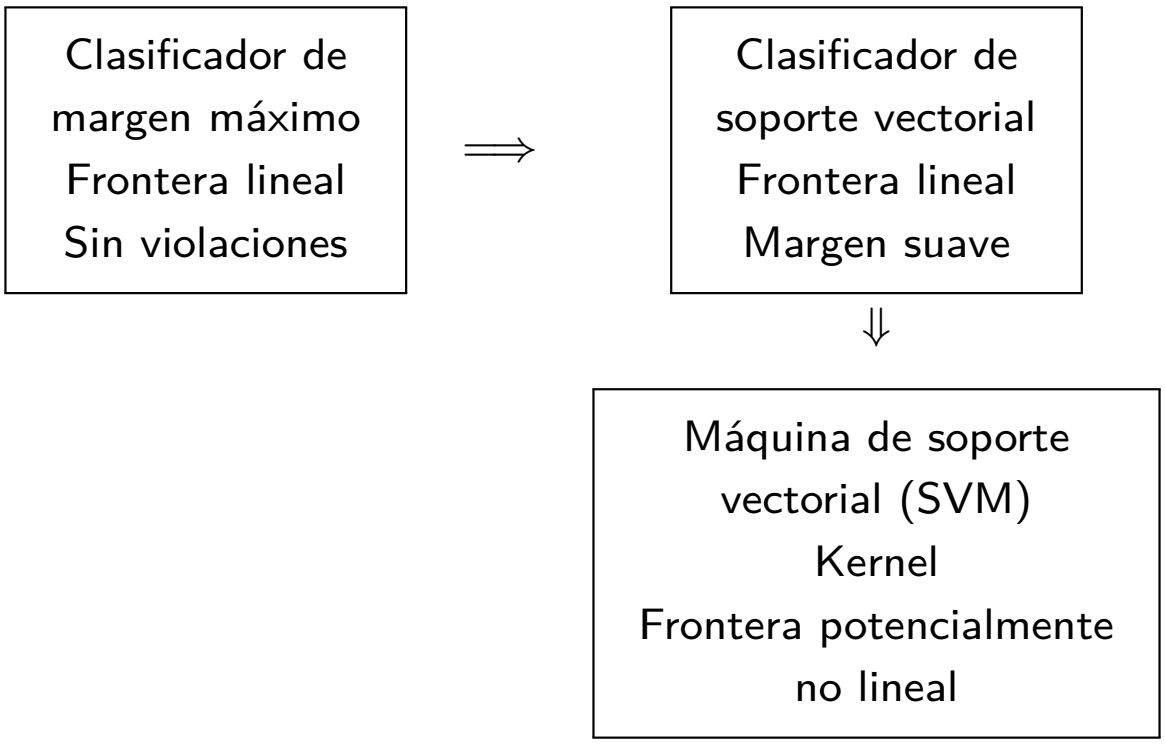
Frontera lineal, pero con margen suave y violaciones permitidas.

Máquina de soporte vectorial

Extiende el clasificador de soporte vectorial utilizando un **kernel no lineal**, permitiendo fronteras no lineales.

La progresión completa

Lo que hemos visto se resume en:



El paso esencial

Desde el punto de vista matemático, el paso esencial consiste en reemplazar $\langle \mathbf{x}_i, \mathbf{x}_{i'} \rangle$ por $K(\mathbf{x}_i, \mathbf{x}_{i'})$.

Esto permite trabajar implícitamente en espacios de características más ricos.

Y la función de decisión queda expresada como

$$f(\mathbf{x}) = \beta_0 + \sum_{i \in S} \alpha_i K(\mathbf{x}, \mathbf{x}_i).$$

Los vectores de soporte continúan siendo los protagonistas.

Hasta ahora: clasificación binaria

Todo nuestro desarrollo ha supuesto

$$Y \in \{-1, +1\}.$$

Esto nos permitió utilizar expresiones como

$$y_i f(\mathbf{x}_i) > 0$$

y construir una frontera que distingue entre dos clases.

Hasta ahora: clasificación binaria

Pero muchos problemas reales tienen

$$K > 2$$

clases.

Por ejemplo,

$$Y \in \{1, 2, 3\}.$$

Siguiente pregunta

¿Cómo podemos utilizar SVM cuando tenemos **más de dos clases**?