Máquinas de Soporte Vectorial con más de dos clases

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero
Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



Hasta ahora: dos clases

Toda nuestra construcción de SVM ha partido de

$$y_i \in \{-1, +1\}.$$

La regla de clasificación era

$$\widehat{y}(\mathbf{x}) = \operatorname{sign}\left(f(\mathbf{x})\right).$$

Por tanto, la función de decisión separaba el espacio en dos regiones:

$$f(\mathbf{x}) > 0 \qquad \text{y} \qquad f(\mathbf{x}) < 0.$$

Problema

¿Qué hacemos si tenemos más de dos clases?

Clasificación multiclase

Supongamos ahora que tenemos $K > 2$ clases posibles:

$$Y \in \{1, 2, \ldots, K\}.$$

Una SVM binaria sólo puede resolver directamente problemas del tipo

clase A vs. clase B.

Una estrategia natural consiste en transformar el problema multiclase en varios problemas de clasificación binaria.

Dos estrategias comunes son:

- One-versus-One (OvO).
- One-versus-Rest (OvR).

One-versus-One

En la estrategia **One-versus-One** (OvO) construimos un clasificador para **cada par de clases**.

Si tenemos tres clases, A, B, C, entrenamos:

$$A \text{ vs. } B,$$

$$A \text{ vs. } C,$$

$$B \text{ vs. } C.$$

Cada clasificador utiliza únicamente las observaciones pertenecientes a las dos clases que está comparando.

¿Cuántos clasificadores necesita OvO?

Si tenemos K clases, necesitamos construir un clasificador para cada par de clases. El número de pares posibles es

$$\binom{K}{2}.$$

Por tanto,

$$N_{\text{OvO}} = \binom{K}{2} = \frac{K(K-1)}{2}.$$

Por ejemplo, si $K = 3$, entonces

$$N_{\text{OvO}} = \frac{3(2)}{2} = 3.$$

El número de clasificadores crece rápidamente

Por ejemplo:

K	N_{OvO}
3	3
4	6
5	10
10	45
20	190

El número de clasificadores crece aproximadamente de forma cuadrática con el número de clases.

Sin embargo, cada clasificador individual utiliza sólo las observaciones de **dos clases**.

¿Cómo clasifica OvO una nueva observación?

Supongamos nuevamente tres clases:

$$A, \qquad B, \qquad C.$$

Para una nueva observación $\mathbf{x}^*$ evaluamos:

$$A \text{ vs. } B, \qquad A \text{ vs. } C, \qquad B \text{ vs. } C.$$

Cada clasificador elige una de sus dos clases.

Podemos interpretar cada resultado como un **voto**.

La clase que recibe más votos se utiliza como predicción final.

$$\widehat{y}(\mathbf{x}^*) = \text{clase con mayor apoyo en las comparaciones.}$$

Ejemplo de votación OvO

Supongamos que para una nueva observación obtenemos:

Clasificador	**Resultado**
A vs. B	A
A vs. C	C
B vs. C	C

Entonces los votos son:

$$A : 1, \qquad B : 0, \qquad C : 2.$$

Por tanto, $\widehat{y} = C$.

La clasificación multiclase se construye combinando varias decisiones binarias.

One-versus-Rest

Otra estrategia es **One-versus-Rest** (OvR), también llamada **One-versus-All**. Para cada clase construimos un problema binario:

una clase vs. todas las demás.

Por ejemplo, con tres clases A, B y C:

$$A \text{ vs. } \{B, C\},$$

$$B \text{ vs. } \{A, C\},$$

$$C \text{ vs. } \{A, B\}.$$

Etiquetas en One-versus-Rest

Consideremos el clasificador correspondiente a la clase A.

Para entrenarlo podemos crear nuevas etiquetas:

$$y_i^{(A)} = \begin{cases} +1, & y_i = A, \\ -1, & y_i \neq A. \end{cases}$$

Entonces entrenamos una SVM binaria para distinguir

$$A$$

de

todas las demás clases.

Repetimos el procedimiento para cada una de las K clases.

¿Cuántos clasificadores necesita OvR?

En One-versus-Rest construimos un clasificador por cada clase.

Por tanto, $N_{\mathrm{OvR}} = K$. Por ejemplo:

K	N_{OvR}	N_{OvO}
3	3	3
4	4	6
5	5	10
10	10	45
20	20	190

OvR requiere menos clasificadores cuando K aumenta.

Funciones de decisión en OvR

En OvR obtenemos una función de decisión para cada clase:

$$f_1(\mathbf{x}), \quad f_2(\mathbf{x}), \quad \ldots, \quad f_K(\mathbf{x}).$$

Cada una mide qué tan favorable es la decisión hacia su clase correspondiente frente al resto.

Para una nueva observación $\mathbf{x}^*$ podemos comparar estos valores y asignar la clase con mayor función de decisión:

$$\widehat{y}(\mathbf{x}^*) = \underset{k=1,\ldots,K}{\arg\max}\ f_k(\mathbf{x}^*).$$

Ejemplo de One-versus-Rest

Supongamos que para una observación obtenemos:

$$f_A(\mathbf{x}^*) = 0.4,$$

$$f_B(\mathbf{x}^*) = -0.8,$$

$$f_C(\mathbf{x}^*) = 1.2.$$

Como $1.2 = \max\{0.4, -0.8, 1.2\}$, la predicción es

$$\boxed{\widehat{y} = C.}$$

No necesitamos interpretar estos valores como probabilidades.

Lo que utilizamos es su valor relativo para construir la decisión.

OvO vs. OvR

	OvO	**OvR**
Problemas	Cada par de clases	Cada clase contra el resto
Número	$\frac{K(K-1)}{2}$	K
Datos por modelo	Sólo dos clases	Todas las observaciones
Decisión	Combinar comparaciones	Comparar funciones de decisión

Ambas estrategias permiten construir un clasificador multiclase a partir de clasificadores binarios.

¿Cuál estrategia utiliza `SVC`?

En `scikit-learn`, la clase

`SVC`

utiliza internamente una estrategia

One-versus-One.

Por tanto, si tenemos K clases, internamente se entrenan

$$\frac{K(K-1)}{2}$$

clasificadores binarios.

Una distinción importante en SVC

En `scikit-learn`, SVC siempre entrena internamente clasificadores **One-versus-One**.

Sin embargo, podemos elegir cómo se presentan las puntuaciones de decisión:

- `decision_function_shape="ovo"`: devuelve una puntuación por cada par de clases.
- `decision_function_shape="ovr"`: combina las comparaciones OvO para devolver una puntuación por clase.

No confundir

`decision_function_shape="ovr"` no significa que se entrenen clasificadores OvR.
Para entrenar realmente con esa estrategia podemos utilizar `OneVsRestClassifier`.

OvO y los kernels

La extensión multiclase es independiente de la elección del kernel.

Por ejemplo, cada clasificador binario de OvO puede utilizar

$$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z},$$

o bien

$$K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^T \mathbf{z})^d,$$

o

$$K(\mathbf{x}, \mathbf{z}) = e^{-\gamma \|\mathbf{x} - \mathbf{z}\|^2}.$$

Por tanto, podemos tener una SVM multiclase con kernel lineal, polinomial o RBF.

Los hiperparámetros siguen siendo importantes

Pasar de clasificación binaria a multiclase no elimina los hiperparámetros del modelo.

Por ejemplo, con un kernel RBF seguimos teniendo que seleccionar

$$C \qquad \text{y} \qquad \gamma.$$

Con un kernel polinomial podemos tener

$$C, \qquad d, \qquad \gamma, \qquad \text{entre otros.}$$

Estos hiperparámetros deben seleccionarse utilizando los **datos de entrenamiento**, por ejemplo mediante validación cruzada.

Un problema multiclase completo

En la práctica, nuestro flujo puede ser:

Datos $\longrightarrow$ Separación train/test $\longrightarrow$ Pipeline(Estandarizar)

$\downarrow$

Evaluación en prueba $\longleftarrow$ Modelo final $\longleftarrow$ Selección con CV

¿Por qué no elegir el modelo con el conjunto de prueba?

Supongamos que probamos muchos valores de

$$C, \qquad \gamma, \qquad d$$

y elegimos aquellos que producen el mejor resultado en el conjunto de prueba.

Entonces el conjunto de prueba ha participado indirectamente en la construcción del modelo.

Ya no constituye una evaluación verdaderamente independiente.

Regla

La selección del modelo se realiza con entrenamiento y validación. El conjunto de prueba se reserva para la evaluación final.

Hasta ahora

Hemos extendido progresivamente una idea geométrica sencilla:

Hiperplano separador

$\Downarrow$

Margen máximo

$\Downarrow$

Margen suave

$\Downarrow$

Kernels

$\Downarrow$

Clasificación multiclase

Pero queda una pregunta importante:

¿cómo se relacionan las SVM con la regresión logística?