Relación con la regresión logística

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero
Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



ENES
JURIQUILLA

SVM y regresión logística: ¿qué tienen en común?

Las máquinas de soporte vectorial surgieron a mediados de los años noventa y despertaron gran interés en la comunidad de aprendizaje estadístico.

Su enfoque parecía muy diferente de los métodos clásicos de clasificación, como la regresión logística:

- Buscar un **hiperplano** que separe las clases con el mayor margen posible.
- Permitir ciertas **violaciones del margen** para obtener clasificadores más flexibles.
- Utilizar **kernels** para construir fronteras de decisión no lineales.

SVM y regresión logística: ¿qué tienen en común?

Una conexión interesante

A pesar de estas diferencias aparentes, las SVM y la regresión logística están estrechamente relacionadas.
La diferencia fundamental está en **cómo se construye la frontera de decisión**.

SVM y regresión logística

A primera vista, la regresión logística y las SVM parecen métodos muy diferentes.

Sin embargo, en el caso lineal ambos parten de una función

$$\boxed{f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.}$$

La diferencia fundamental no está necesariamente en la forma de $f(\mathbf{x})$, sino en

cómo se estiman sus parámetros.

Recordatorio: regresión logística

Para clasificación binaria, la regresión logística modela

$$P(Y = 1 \mid \mathbf{x}) = p(\mathbf{x}).$$

Se supone que el logaritmo de las razones de probabilidades es lineal:

$$\log\left(\frac{p(\mathbf{x})}{1 - p(\mathbf{x})}\right) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

Recordatorio: regresión logística

Si definimos

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x},$$

entonces

$$\boxed{p(\mathbf{x}) = \frac{e^{f(\mathbf{x})}}{1 + e^{f(\mathbf{x})}}.}$$

La frontera en regresión logística

Una regla común consiste en clasificar como clase positiva cuando

$$p(\mathbf{x}) > 0.5.$$

Pero $p(\mathbf{x}) = 0.5$ si y sólo si $f(\mathbf{x}) = 0$.

Por tanto, la frontera de decisión es

$$\boxed{\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0.}$$

Esta expresión es también la forma de la frontera de una SVM lineal.

Una primera similitud

Para una regresión logística lineal:

$$f_{\text{Log}}(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

Para una SVM lineal:

$$f_{\text{SVM}}(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

En ambos casos podemos tener una frontera

$$f(\mathbf{x}) = 0.$$

Pero cuidado

Que ambas fronteras tengan la misma **forma matemática** no significa que los dos métodos estimen los mismos coeficientes ni produzcan la misma frontera.

Entonces, ¿dónde está la diferencia?

Los dos métodos utilizan criterios diferentes para estimar

$$\beta_0, \boldsymbol{\beta}.$$

La regresión logística utiliza una función de pérdida asociada con el modelo probabilístico.

La SVM utiliza una pérdida asociada con el margen.

Podemos entender esta diferencia utilizando nuevamente etiquetas

$$y_i \in \{-1, +1\}.$$

Margen funcional

Definamos

$$f(\mathbf{x}_i) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i.$$

Para una observación con etiqueta $y_i \in \{-1, +1\}$, definimos el **margen funcional**

$$\boxed{m_i = y_i f(\mathbf{x}_i).}$$

Si $m_i > 0$, la observación está correctamente clasificada.

Si $m_i < 0$, está mal clasificada.

El tamaño del margen funcional

No sólo importa el signo de

$$m_i = y_i f(\mathbf{x}_i).$$

También podemos considerar su magnitud.

$$m_i \gg 0$$

significa que la observación está correctamente clasificada y se encuentra con gran confianza funcional del lado correcto.

Mientras que

$$m_i \approx 0$$

indica una observación cercana a la frontera.

Pérdida logística

Utilizando etiquetas $y_i \in \{-1, +1\}$, la pérdida logística para una observación puede escribirse como

$$\boxed{L_{\log}(m_i) = \log\left(1 + e^{-m_i}\right).}$$

donde

$$m_i = y_i f(\mathbf{x}_i).$$

Cuando m_i aumenta, $L_{\log}(m_i)$ disminuye.

Por tanto, una observación correctamente clasificada recibe una pérdida menor cuanto más claramente se encuentra del lado correcto.

¿Qué ocurre con la pérdida logística?

Consideremos

$$L_{\log}(m) = \log(1 + e^{-m}).$$

Si $m < 0$, la observación está mal clasificada y la pérdida es grande.

Si $m = 0$, entonces

$$L_{\log}(0) = \log 2.$$

Si $m \gg 0$, la pérdida se acerca a cero:

$$L_{\log}(m) \longrightarrow 0.$$

Pero para cualquier valor finito de m, $L_{\log}(m) > 0$.

Pérdida hinge

El clasificador de soporte vectorial está asociado con la **pérdida hinge**:

$$\boxed{L_{\text{hinge}}(m_i) = \max(0, 1 - m_i).}$$

Recordemos que

$$m_i = y_i f(\mathbf{x}_i).$$

La pérdida depende de la posición de la observación con respecto al margen.

Tres casos para la pérdida hinge

Consideremos

$$L_{\text{hinge}}(m) = \max(0, 1 - m).$$

Tenemos:

$$L_{\text{hinge}}(m) = \begin{cases} 0, & m \geq 1, \\ 1 - m, & m < 1. \end{cases}$$

Por tanto:

- si $m \geq 1$, no hay pérdida;
- si $0 < m < 1$, está bien clasificada pero dentro del margen;
- si $m < 0$, está mal clasificada.

Pérdida hinge y variables de holgura

Recordemos la restricción del margen suave:

$$y_i f(\mathbf{x}_i) \geq 1 - \epsilon_i.$$

Equivalentemente,

$$\epsilon_i \geq 1 - y_i f(\mathbf{x}_i).$$

Como además $\epsilon_i \geq 0$, el valor mínimo posible de la holgura es

$$\boxed{\epsilon_i = \max\left(0, 1 - y_i f(\mathbf{x}_i)\right).}$$

Pero esta expresión es precisamente

$$\boxed{\epsilon_i = L_{\text{hinge}}(m_i).}$$

La SVM como minimización de una pérdida

La formulación

$$\min \left[\frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^{n} \epsilon_i \right]$$

puede escribirse como

$$\boxed{\min_{\beta_0, \boldsymbol{\beta}} \left[\frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^{n} \max\left(0, 1 - y_i f(\mathbf{x}_i)\right) \right].}$$

Así podemos interpretar una SVM como la combinación de:

regularización + pérdida hinge.

Logistic loss vs. hinge loss

Tenemos dos funciones:

$$L_{\log}(m) = \log(1 + e^{-m}),$$

y

$$L_{\text{hinge}}(m) = \max(0, 1 - m).$$

Ambas penalizan fuertemente valores negativos de m:

$$m < 0 \quad \Longrightarrow \quad \text{clasificación incorrecta.}$$

Pero existe una diferencia fundamental para observaciones correctamente clasificadas.

La diferencia fundamental

Para la pérdida hinge,

$$m \geq 1 \quad \Longrightarrow \quad L_{\text{hinge}}(m) = 0.$$

Una vez que una observación está correctamente clasificada y fuera del margen, mejorar todavía más su margen no reduce la pérdida.

En cambio,

$$L_{\log}(m) = \log(1 + e^{-m})$$

permanece positiva para cualquier m finito.

La pérdida logística disminuye suavemente; la hinge llega exactamente a cero.

¿Qué observaciones importan en una SVM?

Para una observación con $m_i > 1$, tenemos

$$L_{\text{hinge}}(m_i) = 0.$$

Por tanto, esa observación no contribuye a la parte de pérdida del objetivo.

Las observaciones relevantes son aquellas con $m_i \leq 1$, es decir, las que están:

- sobre el margen;
- dentro del margen;
- o mal clasificadas.

Esto conecta directamente con los **vectores de soporte**.

¿Y en regresión logística?

En regresión logística,

$$L_{\log}(m_i) = \log(1 + e^{-m_i})$$

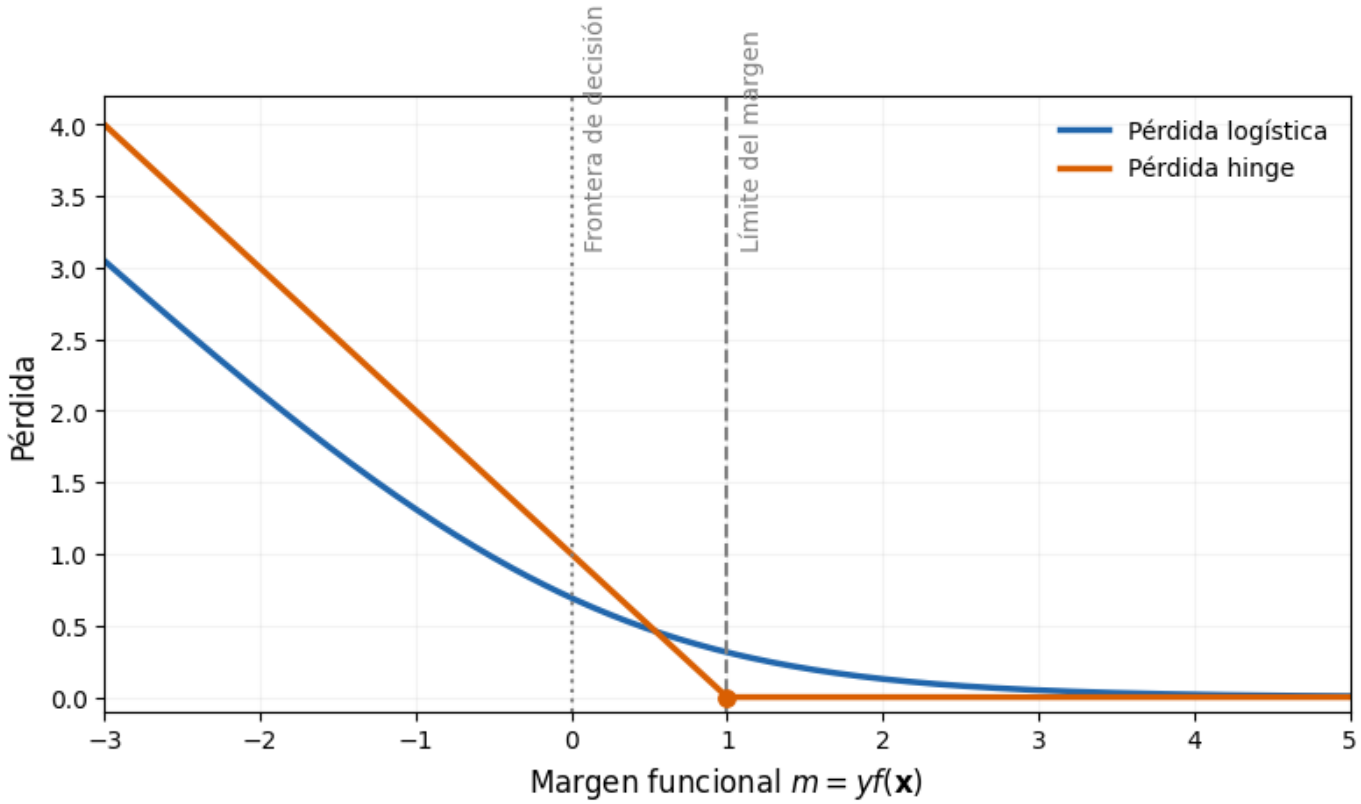
no se vuelve exactamente cero para un margen finito.

Por tanto, incluso una observación correctamente clasificada y alejada de la frontera puede seguir contribuyendo al criterio de optimización, aunque su contribución sea muy pequeña.

Esto contrasta con la SVM:

$$\boxed{m_i > 1 \Longrightarrow L_{\text{hinge}}(m_i) = 0.}$$

Comparación de las funciones de pérdida



- En $m = 0$ se encuentra la frontera de decisión.
- Para $m \geq 1$, la pérdida **hinge** es cero, mientras que la pérdida logística continúa disminuyendo.

¿Qué nos dice la gráfica?

La comparación muestra que ambas pérdidas:

- penalizan observaciones mal clasificadas;
- disminuyen cuando aumenta el margen funcional.

Pero la pérdida hinge presenta un punto especial $m = 1$. A partir de ahí,

$$L_{\text{hinge}}(m) = 0.$$

Consecuencia

La SVM concentra el ajuste en las observaciones cercanas a la frontera, mientras que las observaciones suficientemente alejadas dejan de contribuir a la pérdida.

Regularización en ambos modelos

Los dos métodos también pueden incorporar regularización.

Una forma esquemática de la regresión logística regularizada es

$$\boxed{\sum_{i=1}^{n} L_{\log}(m_i) + \lambda \|\boldsymbol{\beta}\|_2^2.}$$

Para una SVM podemos escribir

$$\boxed{\frac{1}{2}\|\boldsymbol{\beta}\|^2 + C\sum_{i=1}^{n} L_{\text{hinge}}(m_i).}$$

Ambos equilibran:

ajuste a los datos vs. complejidad del modelo.

El parámetro C en `scikit-learn`

En `scikit-learn`, tanto `SVC` como `LogisticRegression` utilizan un parámetro llamado

$$C.$$

En ambos casos, de manera general:

$$\boxed{C \text{ pequeño} \Longrightarrow \text{regularización más fuerte},}$$

mientras que

$$\boxed{C \text{ grande} \Longrightarrow \text{regularización más débil}.}$$

Esto hace que la interfaz de ambos métodos resulte similar.

Pero el mismo C no significa lo mismo

Aunque ambos modelos tengan un parámetro llamado C, $C_{\text{SVM}} = 1$ y $C_{\text{Logística}} = 1$ no representan necesariamente la misma intensidad efectiva de regularización.

Las funciones objetivo son diferentes:

hinge loss vs. logistic loss.

Importante

No debemos comparar directamente los valores numéricos de C entre modelos diferentes.

Una diferencia importante: probabilidades

La regresión logística modela directamente

$$\boxed{P(Y = 1 \mid \mathbf{x}).}$$

Por tanto, además de producir una clasificación, proporciona probabilidades estimadas:

$$\widehat{p}(\mathbf{x}) = \frac{e^{f(\mathbf{x})}}{1 + e^{f(\mathbf{x})}}.$$

Esto puede ser importante cuando no sólo queremos saber **qué clase**, sino también cuantificar la probabilidad estimada asociada a la predicción.

La función de decisión de una SVM no es una probabilidad

Una SVM produce una función de decisión $f(\mathbf{x})$.

Su signo determina la clasificación:

$$f(\mathbf{x}) > 0 \quad \Longrightarrow \quad \widehat{y} = +1,$$

$$f(\mathbf{x}) < 0 \quad \Longrightarrow \quad \widehat{y} = -1.$$

Pero

$$\boxed{f(\mathbf{x}) \neq P(Y = 1 \mid \mathbf{x}).}$$

Un valor como $f(\mathbf{x}) = 2.3$ no significa una probabilidad de 2.3 ni puede interpretarse directamente como una probabilidad.

¿Puede una SVM producir probabilidades?

Sí, pero no de manera directa a partir de la formulación original de la SVM.

En implementaciones como `SVC` es posible solicitar estimaciones probabilísticas.

Sin embargo, éstas requieren un procedimiento adicional de **calibración**.

Por tanto, debemos distinguir:

$$\boxed{\text{función de decisión} \neq \text{probabilidad estimada.}}$$

Esta diferencia es importante al interpretar las salidas de ambos modelos.

Otra diferencia: no linealidad

Una regresión logística básica utiliza

$$f(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}.$$

Podemos introducir no linealidad mediante:

$$x_j^2, \quad x_j^3, \quad \text{splines}, \quad \text{interacciones}, \ldots$$

Las SVM ofrecen otra vía mediante kernels $K(\mathbf{x}, \mathbf{z})$. Por ejemplo,

$$K(\mathbf{x}, \mathbf{z}) = e^{-\gamma \|\mathbf{x}-\mathbf{z}\|^2}.$$

Así, una SVM puede construir fronteras no lineales sin generar explícitamente todas las nuevas características.

SVM vs. regresión logística

	Regresión logística	**SVM**
Caso lineal	$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}$	$\beta_0 + \boldsymbol{\beta}^T \mathbf{x}$
Pérdida	Logística	Hinge
Probabilidades	Directamente	No directamente
Observaciones lejanas	Contribución pequeña	Pueden tener pérdida cero
No linealidad	Transformaciones explícitas	Kernels

¿Cuál es mejor?

No existe una respuesta universal.

La elección depende del problema y de nuestros objetivos.

- Si necesitamos probabilidades interpretables, la regresión logística tiene una ventaja natural.
- Si buscamos una frontera flexible y las clases presentan estructura no lineal, una SVM con kernel puede ser útil.
- En algunos conjuntos de datos ambos métodos pueden tener desempeños muy similares.

La decisión debe basarse en evaluación y validación, no únicamente en el nombre del algoritmo.

Una observación importante

Un modelo más flexible no necesariamente es mejor.

Por ejemplo, una SVM con kernel RBF puede construir una frontera mucho más compleja que una regresión logística lineal.

Pero si la estructura verdadera del problema es aproximadamente lineal, esa flexibilidad adicional puede ser innecesaria.

$$\boxed{\text{mayor complejidad} \not\Longrightarrow \text{mejor generalización.}}$$

Por eso comparamos modelos utilizando datos que no participaron directamente en su ajuste.