Introducción al Aprendizaje No Supervisado

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero
Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx

ENES JURIQUILLA

Un ejemplo biológico

Imaginemos n muestras de un tejido celular y p tipos de células medidos en cada una.

- **Supervisado:** predecir el tipo de tejido a partir de la cantidad de células.
- **No supervisado:** explorar si algunas muestras presentan perfiles semejantes, sin introducir etiquetas de tejido.

Cuidado

Si posteriormente coloreamos los resultados por tejido, usamos esa información para *interpretar* los patrones, no necesariamente para construirlos.

Un ejemplo biológico

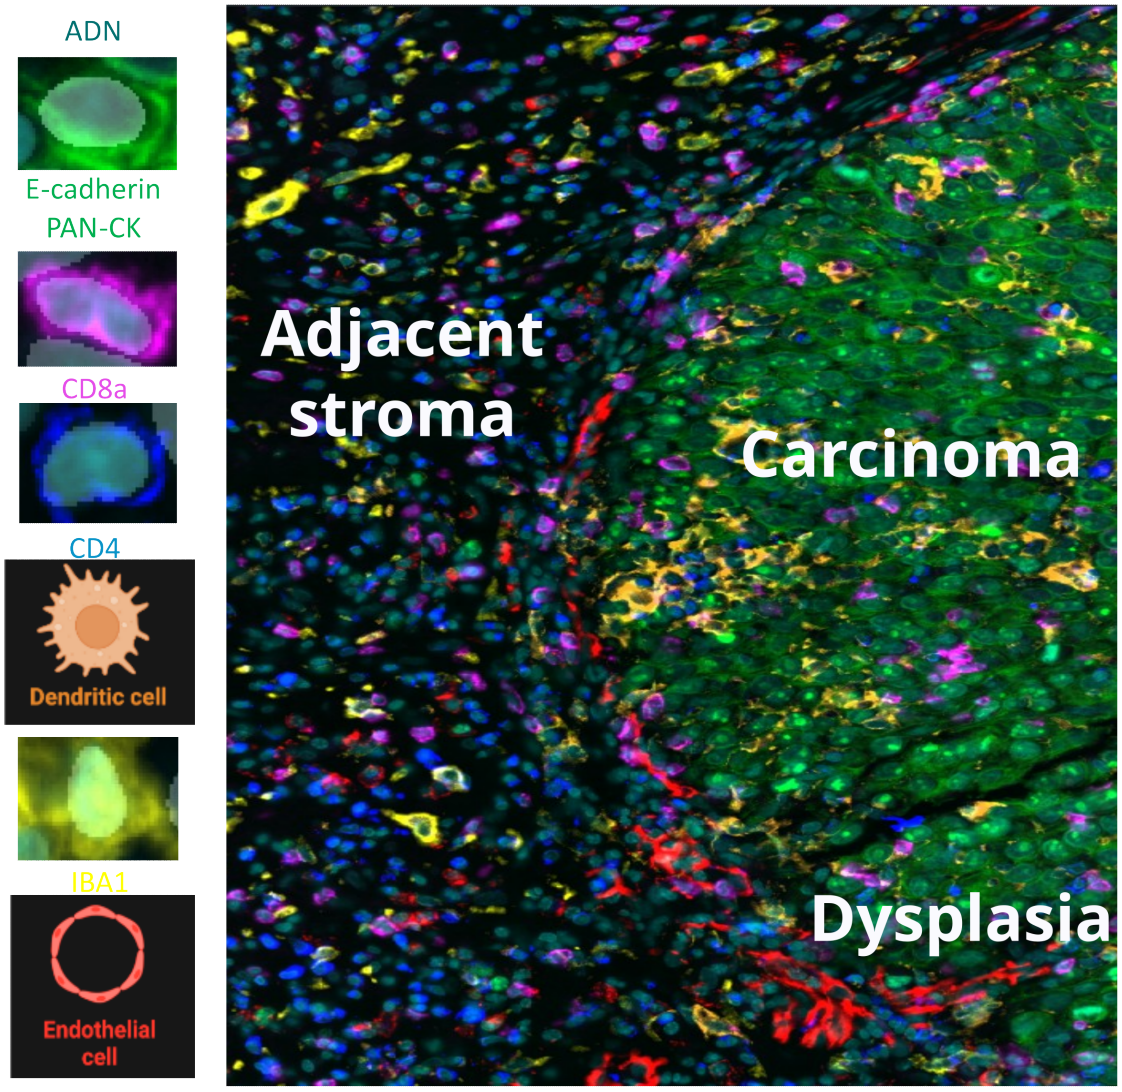
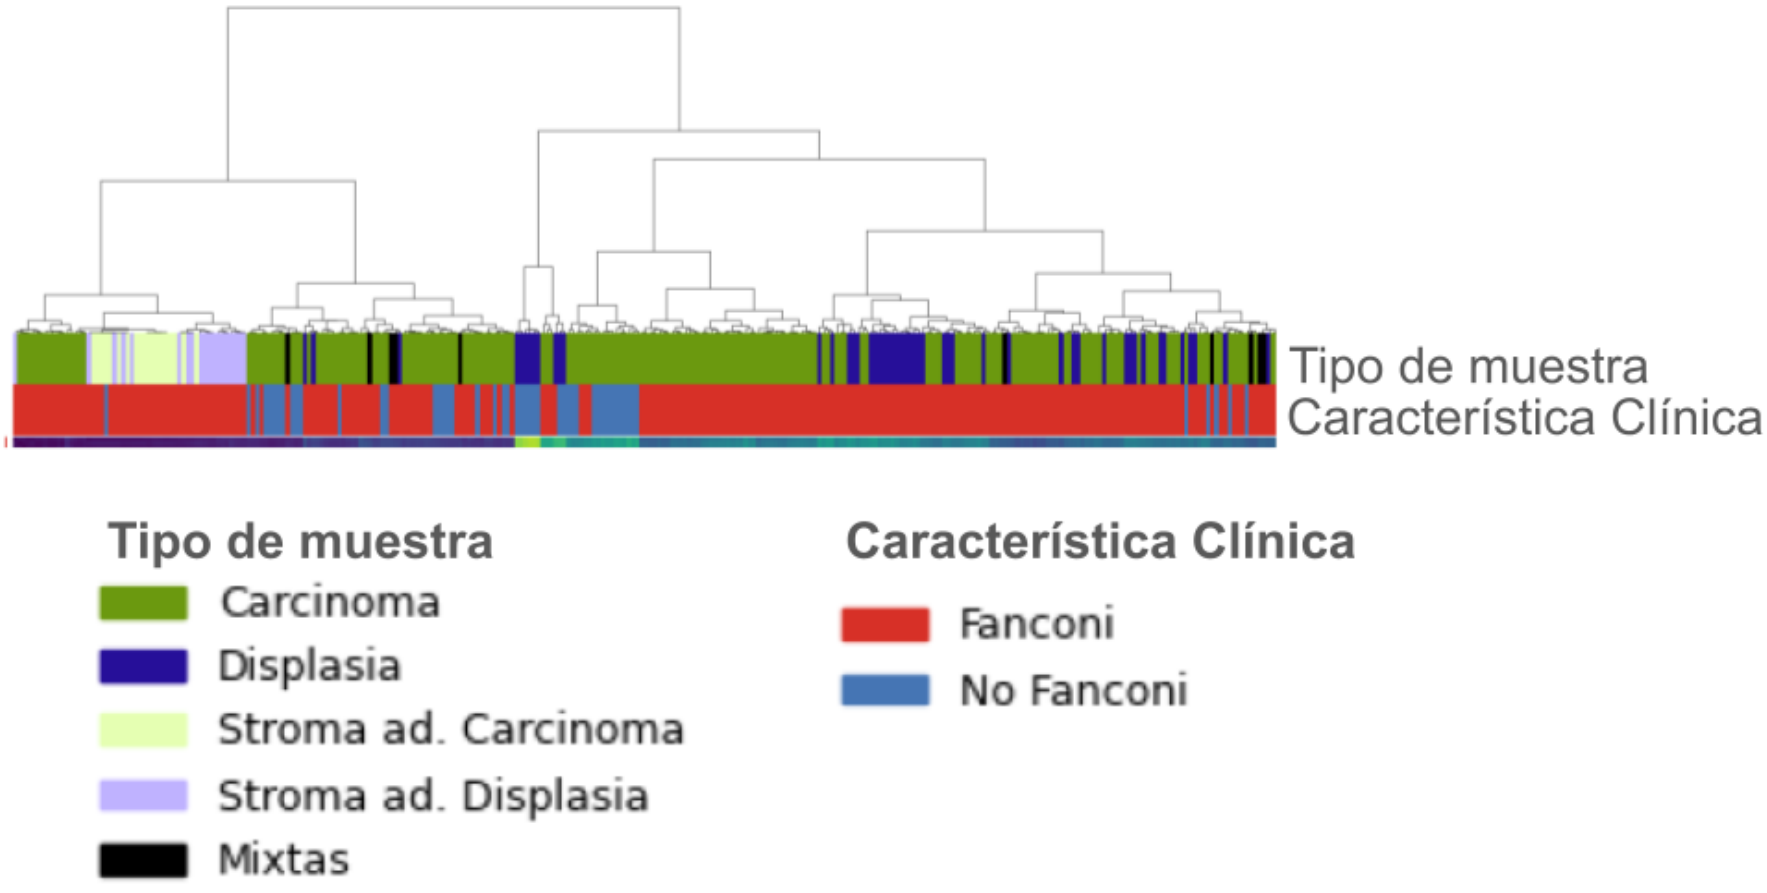


Figure 1: Ejemplo de imágenes por *t*-CycIF

Solo células tumorales muestran una agrupación por tipo de tejido



Dos grandes objetivos

Reducción de dimensionalidad

Representar observaciones mediante pocas coordenadas que conserven alguna estructura de interés.

$$\mathbf{x}_i \in \mathbb{R}^p \longmapsto \mathbf{z}_i \in \mathbb{R}^q, \quad q < p.$$

Ejemplos: PCA, t-SNE y UMAP.

Agrupamiento (clustering)

Construir una partición o estructura de grupos a partir de una medida de similitud.

$$\{\mathbf{x}_1, \ldots, \mathbf{x}_n\} \longmapsto \{C_1, \ldots, C_K\}.$$

Ejemplos: K-medias, jerárquico y DBSCAN.

¿Qué significa una estructura?

- **Proximidad:** observaciones cercanas según una distancia.
- **Variación:** direcciones en las que los datos cambian más.
- **Densidad:** regiones con concentración de observaciones.
- **Jerarquía:** agrupamientos anidados a diferentes escalas.

Idea fundamental

Distintos métodos responden preguntas distintas. No hay una única definición universal de “grupo” o de “estructura”.

La matriz de datos

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

- Cada **fila** $\mathbf{x}_i = (x_{i1}, \ldots, x_{ip})$ es una observación.
- Cada **columna** corresponde a una característica.
- n: número de observaciones; p: número de características.

Ejemplo: mediciones de pingüinos

Muestra	Pico largo (mm)	Pico profundo (mm)	Aleta (mm)	Masa (g)
A	39	18	181	3750
B	46	15	215	5000
C	50	19	196	3900

- ¿Qué variables describen tamaño corporal?
- ¿Qué variables podrían estar correlacionadas?
- ¿Sería razonable usar la especie como variable de entrada para explorar grupos sin supervisión?

¿Qué significa que dos observaciones se parezcan?

En aprendizaje no supervisado necesitamos comparar observaciones para identificar patrones, vecinos y posibles grupos.

$$\mathbf{x}_i = (x_{i1}, \ldots, x_{ip}), \qquad \mathbf{x}_j = (x_{j1}, \ldots, x_{jp}).$$

Similitud

Una **similitud** $s(\mathbf{x}_i, \mathbf{x}_j)$ cuantifica cuánto se parecen dos observaciones. Habitualmente, **valores mayores** indican mayor semejanza.

Disimilitud

Una **disimilitud** $\delta(\mathbf{x}_i, \mathbf{x}_j)$ cuantifica cuánto difieren dos observaciones. Habitualmente, **valores menores** indican mayor semejanza.

Pregunta: ¿qué significa “parecerse” cuando medimos longitud, masa y temperatura?

Similitud y disimilitud: ¿cómo se interpretan?

Similitud	**Disimilitud**
Mide semejanza	Mide diferencia
Mayor valor: más parecidas	Menor valor: más parecidas
Ejemplos: correlación, Jaccard	Ejemplos: distancias, diferencias cuadráticas

Supongamos tres observaciones A, B y C:

$$s(A, B) = 0.9, \qquad s(A, C) = 0.2.$$

Según esta medida, A y B son más similares.

$$\delta(A, B) = 1, \qquad \delta(A, C) = 5.$$

Según esta disimilitud, A y B también son más parecidas.

¿Toda disimilitud es una distancia?

Una **métrica** es una disimilitud que satisface ciertas propiedades matemáticas. Para $\mathbf{x}, \mathbf{y}, \mathbf{z}$:

1. **No negatividad:** $d(\mathbf{x}, \mathbf{y}) \geq 0$.
2. **Identidad:** $d(\mathbf{x}, \mathbf{y}) = 0 \iff \mathbf{x} = \mathbf{y}$.
3. **Simetría:** $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$.
4. **Desigualdad triangular:**

$$d(\mathbf{x}, \mathbf{z}) \leq d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z}).$$

Distinción fundamental

Toda distancia es una disimilitud, pero **no toda disimilitud es una distancia**.

Contraejemplo: una disimilitud que no es métrica

Consideremos, para $x, y \in \mathbb{R}$,

$$\delta(x, y) = (x - y)^2.$$

Es no negativa, simétrica y vale cero exactamente cuando $x = y$.
¿Cumple la desigualdad triangular? Tomemos $x = 0$, $y = 1$, $z = 2$:

$$\delta(0, 2) = 4, \qquad \delta(0, 1) + \delta(1, 2) = 1 + 1 = 2.$$

Por tanto,

$$\boxed{4 \not\leq 2}.$$

¿Cómo elegimos una medida de semejanza?

No existe una medida universal: depende de las variables y de qué entendemos por "parecerse".

- **Distancia euclidiana:** separación geométrica entre vectores numéricos.
- **Distancia Manhattan:**(métrica del taxista) suma de diferencias absolutas por coordenada.
- **Correlación:** semejanza en patrones de variación, no necesariamente en magnitudes.
- **Índice de Jaccard:** coincidencia relativa entre conjuntos o características binarias.

Idea fundamental

Dos observaciones pueden resultar cercanas según una medida y lejanas según otra. La elección afecta a los vecinos y a los agrupamientos.

Matriz de disimilitudes

Para n observaciones podemos calcular la disimilitud entre cada par:

$$D = \begin{pmatrix} 0 & \delta_{12} & \cdots & \delta_{1n} \\ \delta_{21} & 0 & \cdots & \delta_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \delta_{n1} & \delta_{n2} & \cdots & 0 \end{pmatrix}, \qquad \delta_{ij} = \delta(\mathbf{x}_i, \mathbf{x}_j).$$

Si la disimilitud es simétrica, $\delta_{ij} = \delta_{ji}$ y $D = D^\top$.

¿Para qué sirve?

Resume las diferencias entre todos los pares de observaciones. Es especialmente importante en el **agrupamiento jerárquico**.

Observación: aquí estamos suponiendo que $\delta(\mathbf{x}_i, \mathbf{x}_i) = 0$.

La similitud depende de la representación

Para comparar $\mathbf{x}_i$ y $\mathbf{x}_j$ necesitamos elegir cómo medir su diferencia.

Distancia euclidiana

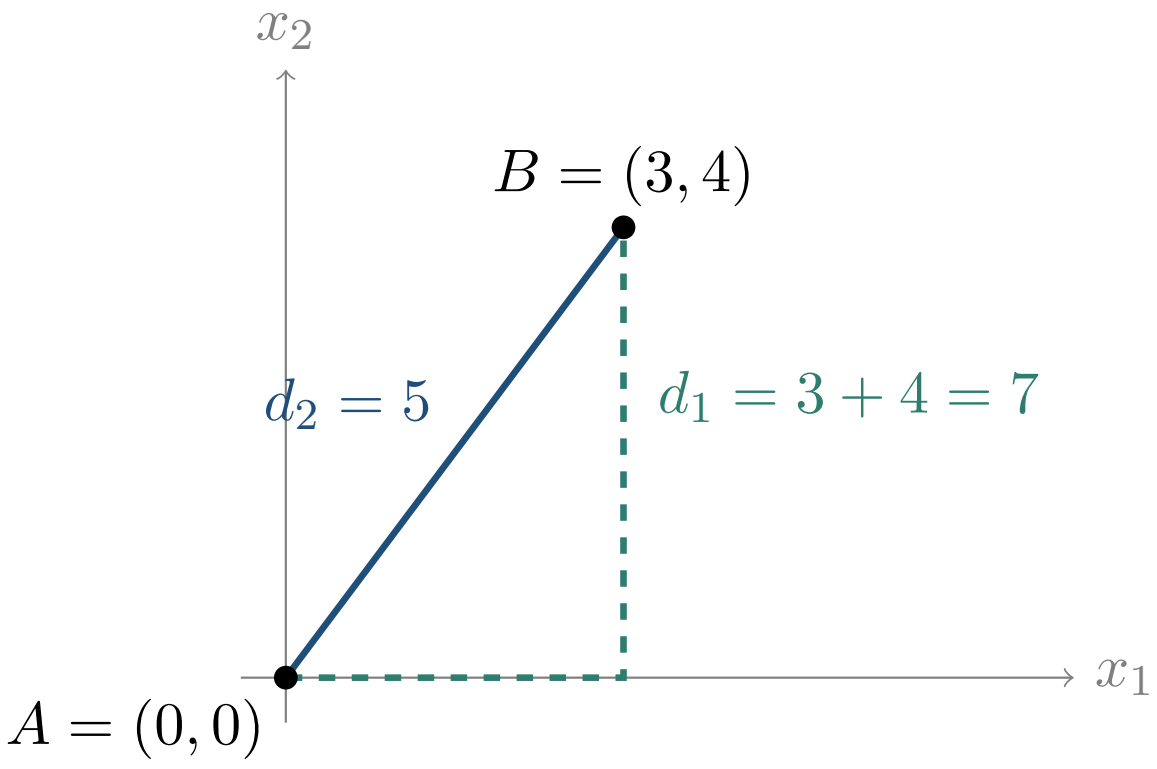
$$d_2(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{k=1}^{p} (x_{ik} - x_{jk})^2}.$$

Distancia Manhattan

$$d_1(\mathbf{x}_i, \mathbf{x}_j) = \sum_{k=1}^{p} |x_{ik} - x_{jk}|.$$

Ambas son distancias válidas, pero no siempre producen el mismo orden de vecinos.

Interpretación geométrica de las distancias



Euclidiana: distancia en línea recta. **Manhattan:** suma de desplazamientos por coordenada.

Ejemplo: el vecino más cercano puede cambiar

Sean $A = (0, 0)$, $B = (3, 4)$ y $C = (6, 0)$.

$$d_2(A, B) = \sqrt{3^2 + 4^2} = 5, \quad d_2(A, C) = 6,$$
$$d_1(A, B) = 3 + 4 = 7, \qquad d_1(A, C) = 6.$$

Conclusión

Con distancia euclidiana, B es más cercano a A. Con Manhattan, C es más cercano.

¿Qué consecuencias puede tener esto al construir grupos?

¿Qué pasa si las variables tienen distintas unidades?

Supongamos dos variables: longitud de aleta (mm) y masa (g).

$$A = (190, 3500), \qquad B = (200, 4500).$$

$$d_2(A, B) = \sqrt{(200 - 190)^2 + (4500 - 3500)^2} \approx 1000.05.$$

Problema

La diferencia de masa domina el cálculo numérico de la distancia. Cambiar de gramos a kilogramos puede modificar radicalmente la comparación.

Pregunta: ¿queremos que la importancia de una variable dependa de su unidad?

Centrar y estandarizar

Para la variable j, su media y desviación estándar muestral son

$$\bar{x}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \qquad s_j = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)^2}.$$

Estandarización

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Después, cada columna transformada tiene media 0 y desviación estándar muestral 1 (si $s_j > 0$).

Centrar no es lo mismo que escalar

Centrar

$$x_{ij}^{(c)} = x_{ij} - \bar{x}_j.$$

Elimina diferencias de localización; conserva las unidades y la dispersión original.

Estandarizar

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Además de centrar, reescala la variabilidad de cada característica.

Importante: estandarizar no siempre es lo correcto; puede quitar diferencias de escala que sí sean científicamente relevantes.

Ejemplo numérico de estandarización

Consideremos una variable con valores $2, 4, 6$.

$$\bar{x} = 4, \qquad s = \sqrt{\frac{(2-4)^2 + (4-4)^2 + (6-4)^2}{3-1}} = 2.$$

Los valores estandarizados son

$$z_1 = -1, \qquad z_2 = 0, \qquad z_3 = 1.$$

Interpretación

z_i expresa cuántas desviaciones estándar se encuentra una observación por encima o por debajo de la media.

¿Cuándo conviene estandarizar?

- Cuando las variables tienen unidades diferentes.
- Cuando sus escalas numéricas difieren mucho.
- Cuando se desea que ninguna variable domine *solo* por su escala.

Pero cuidado

- Una variable casi constante puede amplificar ruido al dividir entre un s_j muy pequeño.
- Los valores atípicos pueden afectar la media y la desviación estándar.
- La elección del escalamiento forma parte del análisis, no es un trámite automático.

Correlación y redundancia de información

Dos variables pueden medir aspectos relacionados del mismo fenómeno Por ejemplo, la correlación de Pearson:

$$r_{jk} = \frac{\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{(n-1)s_j s_k}.$$

- $r_{jk} \approx 1$: relación lineal positiva fuerte.
- $r_{jk} \approx -1$: relación lineal negativa fuerte.
- $r_{jk} \approx 0$: poca asociación *lineal*, no necesariamente independencia.

Datos faltantes, atípicos y variables inapropiadas

Antes de intentar abordar un método de reducción de dimensión o clustering, nos preguntamos:

1. ¿Existen observaciones con valores faltantes?
2. ¿Hay mediciones atípicas o errores de captura?
3. ¿Tenemos variables constantes o casi constantes?
4. ¿Hay identificadores, etiquetas o variables categóricas mezcladas con las medidas numéricas?
5. ¿Las observaciones son comparables entre sí?

Advertencia

Eliminar filas incompletas es una opción sencilla, pero puede introducir sesgos si la ausencia de datos no es aleatoria.

La dimensión también importa

- En dimensión alta, visualizar directamente es imposible.
- Las distancias pueden perder capacidad para distinguir vecinos, dependiendo de la distribución de los datos.
- Muchas variables pueden ser redundantes o irrelevantes.
- La estructura que vemos en dos dimensiones no necesariamente refleja toda la geometría original.

Vamos a intentar responder lo siguiente

¿Podemos representar p variables con dos o tres dimensiones? ¿Qué información se conserva? ¿Cómo afecta esto a los agrupamientos?

Actividad breve: decidir cómo preparar los datos

Tenemos 120 muestras con masa (g), longitud (mm), temperatura (°C), un identificador y una categoría conocida.

1. ¿Qué columnas incluirías en una matriz para calcular distancias euclidianas?
2. ¿Estandarizarías las mediciones? ¿Por qué?
3. ¿Qué harías con dos muestras que tienen valores faltantes?
4. ¿Para qué usarías la categoría conocida, si el objetivo es explorar grupos?

Actividad breve: decidir cómo preparar los datos

Tenemos 120 muestras con masa (g), longitud (mm), temperatura (°C), un identificador y una categoría conocida.

1. ¿Qué columnas incluirías en una matriz para calcular distancias euclidianas?
2. ¿Estandarizarías las mediciones? ¿Por qué?
3. ¿Qué harías con dos muestras que tienen valores faltantes?
4. ¿Para qué usarías la categoría conocida, si el objetivo es explorar grupos?

No existe una respuesta automática: las decisiones deben responder a la pregunta científica.

Resumiendo

1. Sin etiquetas de respuesta podemos explorar relaciones y patrones.
2. Una estructura depende de la representación y de la medida de similitud.
3. Las escalas cambian las distancias y, potencialmente, los grupos.
4. Preparar los datos requiere decisiones estadísticas justificadas.
5. Las técnicas de reducción de dimensión y agrupamientos estudian aspectos diferentes y complementarios.

Para reflexionar: si dos procedimientos de preparación producen agrupamientos distintos, ¿cómo decidir cuál es más apropiado?