Análisis de Componentes Principales (PCA)

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero

Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



ENES
JURIQUILLA

Motivación: muchas variables, información compartida

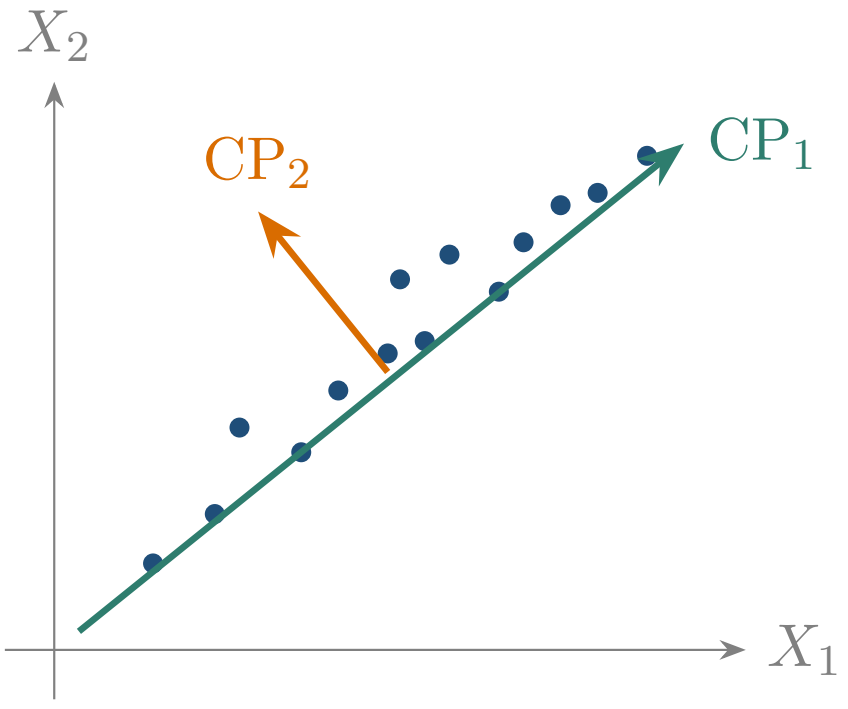
Imaginemos que medimos en cada pingüino la longitud y profundidad del pico, la longitud de la aleta y la masa corporal.

- Tenemos $p = 4$ variables, posiblemente relacionadas entre sí.
- Algunas combinaciones pueden resumir patrones de tamaño o forma.
- Queremos **explorar la estructura sin utilizar la especie como respuesta**.

Pregunta central

¿Podemos representar cada observación mediante dos o tres nuevas variables que conserven gran parte de la variabilidad de los datos?

Idea geométrica: cambiar los ejes



- Los ejes originales son las variables medidas.
- Los nuevos ejes siguen direcciones de variación de la nube.
- La primera dirección recoge la mayor dispersión posible.
- La segunda es perpendicular a la primera.

Esquema ilustrativo; PCA utiliza los datos centrados para definir las direcciones.

Dos perspectivas complementarias

Algebraica

Las componentes principales son **combinaciones lineales** de las p variables originales:

$$Y_k = a_{k1}X_1 + \cdots + a_{kp}X_p = \boldsymbol{a}_k^\top \mathbf{X}.$$

Geométrica

Estas combinaciones definen un **nuevo sistema de ejes ortogonales** orientado según las direcciones de mayor variabilidad.

Importante

PCA no selecciona necesariamente variables originales: **construye variables nuevas** a partir de ellas.

Del fenómeno a las variables aleatorias

Supongamos que estudiamos un fenómeno mediante p variables cuantitativas:

$$X_1, X_2, \ldots, X_p.$$

Podemos reunirlas en un **vector aleatorio**:

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p.$$

Ejemplo

Ejemplo: mediciones de pingüinos

Podríamos considerar cuatro variables:

- X_1: longitud del pico.
- X_2: profundidad del pico.
- X_3: longitud de la aleta.
- X_4: masa corporal.

En este caso, $p = 4$.

Idea: las variables pueden estar relacionadas y compartir parte de la información que contienen.

Media y matriz de covarianzas poblacionales

Sea $\mathbf{X} = (X_1, \ldots, X_p)^\top$.

Su **vector de medias** es

$$\boldsymbol{\mu} = E(\mathbf{X}) = \begin{pmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{pmatrix}.$$

Media y matriz de covarianzas poblacionales

La **matriz de covarianzas poblacional** es

$$\Sigma = \mathrm{Cov}(\mathbf{X}) = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{pmatrix}.$$

- $\sigma_{jj} = \mathrm{Var}(X_j)$: varianza de la variable j.
- $\sigma_{jk} = \mathrm{Cov}(X_j, X_k)$: covarianza entre las variables j y k.

Propiedades de la matriz de covarianzas

La matriz de covarianzas Σ tiene dos propiedades fundamentales.

1. **Es simétrica:** Como

$$\mathrm{Cov}(X_j, X_k) = \mathrm{Cov}(X_k, X_j),$$

se cumple que

$$\boxed{\Sigma^\top = \Sigma.}$$

2. **Es semidefinida positiva** Para cualquier vector $\mathbf{a} \in \mathbb{R}^p$,

$$\boxed{\mathbf{a}^\top \Sigma \mathbf{a} = \mathrm{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.}$$

Es decir, la varianza de una combinación lineal de variables nunca puede ser negativa.

Consecuencia: los autovalores de Σ son reales y no negativos.

De la población a una muestra de datos

En la práctica, generalmente no conocemos $\boldsymbol{\mu}$ ni Σ.

Disponemos de una muestra de n observaciones, cada una con p variables medidas.

Organizamos los datos en una matriz:

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

¿Qué representa cada elemento?

- Cada **fila**: una observación.
- Cada **columna**: una variable.
- x_{ij}: valor de la variable j en la observación i.

Notación

$\mathbf{X}$ representa un vector aleatorio; X representa la matriz de datos observados.

El puente entre población y muestra

En el enfoque poblacional trabajamos con la matriz de covarianzas:

$$\Sigma = \mathrm{Cov}(\mathbf{X}).$$

En la práctica, utilizamos su estimación muestral:

$$\boxed{S = \frac{1}{n-1} X_c^\top X_c}$$

¿Por qué esta expresión calcula covarianzas?

El elemento (j, k) de la matriz S es

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

Esta es precisamente la covarianza muestral entre las variables j y k.

¿Por qué centramos las variables?

Para cada variable j, restamos su media:

$$x_{ij}^{(c)} = x_{ij} - \bar{x}_j.$$

- El origen se traslada al centro de la nube de observaciones.
- Las direcciones describen variabilidad **alrededor de la media**.
- Centrar no cambia las distancias euclidianas entre pares de observaciones.

Atención

Centrar y estandarizar no son lo mismo: la estandarización también divide entre una desviación estándar.

Combinación lineal: ¿qué representa?

Para un vector $\boldsymbol{a} = (a_1, \ldots, a_p)^\top$ definimos

$$Y = \boldsymbol{a}^\top \mathbf{X} = a_1 X_1 + \cdots + a_p X_p.$$

- Los a_j son **coeficientes** o pesos de la combinación.
- Y es una nueva variable aleatoria, no una observación individual.
- Para la observación i, su valor es $y_i = \boldsymbol{a}^\top \mathbf{x}_i$ (o $\boldsymbol{a}^\top(\mathbf{x}_i - \bar{\mathbf{x}})$ en datos centrados).

Ejemplo: $Y = 0.6X_1 + 0.8X_2$ combina dos mediciones en una sola coordenada.

Media y varianza de una combinación lineal

Si $Y = \boldsymbol{a}^\top \mathbf{X}$, entonces

$$\mathbb{E}(Y) = \boldsymbol{a}^\top \boldsymbol{\mu},$$

$$\boxed{\mathrm{Var}(Y) = \boldsymbol{a}^\top \boldsymbol{\Sigma} \boldsymbol{a}.}$$

Para dos combinaciones $Y_j = \boldsymbol{a}_j^\top \mathbf{X}$ y $Y_k = \boldsymbol{a}_k^\top \mathbf{X}$:

$$\boxed{\mathrm{Cov}(Y_j, Y_k) = \boldsymbol{a}_j^\top \boldsymbol{\Sigma} \boldsymbol{a}_k.}$$

Consecuencia

La matriz de covarianzas determina qué combinaciones lineales varían más y cuáles resultan incorrelacionadas.

La primera componente principal

Buscamos la combinación lineal de mayor varianza:

$$Y_1 = \boldsymbol{a}_1^\top \mathbf{X}.$$

El problema es

$$\boxed{\max_{\boldsymbol{a}_1} \ \boldsymbol{a}_1^\top \boldsymbol{\Sigma} \boldsymbol{a}_1 \quad \text{sujeto a} \quad \boldsymbol{a}_1^\top \boldsymbol{a}_1 = 1.}$$

- La restricción $\|\boldsymbol{a}_1\| = 1$ fija la longitud del vector de pesos.
- Sin esa restricción, multiplicar $\boldsymbol{a}_1$ por una constante grande aumentaría la varianza arbitrariamente.

¿Por qué necesitamos la restricción?

Si $Y = \boldsymbol{a}^\top \mathbf{X}$ y $c \in \mathbb{R}$, entonces

$$\operatorname{Var}(cY) = c^2 \operatorname{Var}(Y).$$

Si no imponemos ninguna restricción, podemos hacer $|c| \to \infty$ y obtener varianza ilimitada.

Normalización

Exigimos $\boldsymbol{a}^\top \boldsymbol{a} = 1$. Así comparamos **direcciones**, no tamaños arbitrarios de los coeficientes.

Multiplicadores de Lagrange: planteamiento

Para maximizar $\boldsymbol{a}^\top \boldsymbol{\Sigma} \boldsymbol{a}$ con $\boldsymbol{a}^\top \boldsymbol{a} = 1$, usamos los multiplicadores de Lagrange

Método de multiplicadores de Lagrange

Para maximizar una función diferenciable $f(x_1, \ldots, x_p)$, sujeta a $g(x_1, \ldots, x_p) = 0$, buscamos un valor λ tal que

$$\frac{\partial f}{\partial x_i} - \lambda \frac{\partial g}{\partial x_i} = 0, \qquad i = 1, \ldots, p,$$

junto con la restricción $g(x_1, \ldots, x_p) = 0$.

Aplicando el método a PCA

$$L(\mathbf{a}_1) = \mathbf{a}_1^\top \Sigma \mathbf{a}_1 - \lambda(\mathbf{a}_1^\top \mathbf{a}_1 - 1).$$

Como Σ es simétrica, al derivar respecto a $\mathbf{a}_1$:

$$\frac{\partial L}{\partial \mathbf{a}_1} = 2\Sigma \mathbf{a}_1 - 2\lambda \mathbf{a}_1.$$

Igualando a cero:

$$2\Sigma \mathbf{a}_1 - 2\lambda \mathbf{a}_1 = 0.$$

Por lo tanto,

$$\boxed{(\Sigma - \lambda I)\mathbf{a}_1 = 0.}$$

Aparecen los autovalores y autovectores

Reorganizando la condición anterior:

$$\boxed{\boldsymbol{\Sigma a} = \lambda \boldsymbol{a}} \qquad \Longleftrightarrow \qquad (\boldsymbol{\Sigma} - \lambda I)\boldsymbol{a} = 0.$$

Es decir, $\boldsymbol{a}$ debe ser un **autovector** de $\boldsymbol{\Sigma}$ y λ su **autovalor**.
Además, multiplicando por $\boldsymbol{a}^\top$:

$$\boldsymbol{a}^\top \boldsymbol{\Sigma a} = \lambda \boldsymbol{a}^\top \boldsymbol{a} = \lambda.$$

Interpretación

Para un autovector unitario, el autovalor asociado es exactamente la varianza de la componente.

¿Cuál autovector elegimos primero?

Sean los autovalores de $\boldsymbol{\Sigma}$ ordenados como

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$$

y sus autovectores unitarios $\boldsymbol{a}_1, \ldots, \boldsymbol{a}_p$.

Primera componente

$$\boxed{Y_1 = \boldsymbol{a}_1^\top \mathbf{X}, \qquad \mathrm{Var}(Y_1) = \lambda_1.}$$

El primer eje principal es el asociado al **mayor autovalor**.

Si hay autovalores repetidos, las direcciones individuales dentro del subespacio correspondiente pueden no ser únicas.

La segunda componente: nueva información

Buscamos una segunda combinación $Y_2 = \boldsymbol{a}_2^\top \mathbf{X}$ que maximice la varianza y no repita la dirección anterior:

$$\max_{\boldsymbol{a}_2} \ \boldsymbol{a}_2^\top \boldsymbol{\Sigma} \boldsymbol{a}_2$$

$$\text{sujeto a} \quad \boldsymbol{a}_2^\top \boldsymbol{a}_2 = 1, \qquad \mathrm{Cov}(Y_1, Y_2) = 0.$$

Dado que $\boldsymbol{\Sigma}\boldsymbol{a}_1 = \lambda_1 \boldsymbol{a}_1$,

$$\mathrm{Cov}(Y_1, Y_2) = \boldsymbol{a}_1^\top \boldsymbol{\Sigma} \boldsymbol{a}_2 = \lambda_1 \boldsymbol{a}_1^\top \boldsymbol{a}_2.$$

Para $\lambda_1 > 0$, la condición de incorrelación implica ortogonalidad: $\boldsymbol{a}_1^\top \boldsymbol{a}_2 = 0$.

La segunda componente: solución

Con la restricción de ortogonalidad, el segundo eje de máxima varianza es un autovector correspondiente a λ_2:

$$\boxed{Y_2 = \boldsymbol{a}_2^\top \mathbf{X}, \qquad \mathrm{Var}(Y_2) = \lambda_2.}$$

Además,

$$\boldsymbol{a}_1^\top \boldsymbol{a}_2 = 0, \qquad \mathrm{Cov}(Y_1, Y_2) = 0.$$

No confundir

Incorrelación no implica, en general, **independencia**. PCA garantiza covarianza cero entre componentes, no independencia estadística.

Generalización a la componente k

La k-ésima componente principal es

$$Y_k = \boldsymbol{a}_k^\top \mathbf{X}$$

y maximiza $\mathrm{Var}(Y_k)$ sujeto a

$$\boldsymbol{a}_k^\top \boldsymbol{a}_k = 1, \qquad \mathrm{Cov}(Y_k, Y_j) = 0 \quad (j < k).$$

Las componentes satisfacen

$$\mathrm{Var}(Y_k) = \lambda_k, \qquad \mathrm{Cov}(Y_j, Y_k) = 0 \quad (j \neq k).$$

Idea: cada nueva componente recoge la mayor variación disponible en una dirección ortogonal a las anteriores.

Descomposición espectral

Agrupamos los autovectores en una matriz ortogonal

$$A = \begin{pmatrix} \boldsymbol{a}_1 & \boldsymbol{a}_2 & \cdots & \boldsymbol{a}_p \end{pmatrix}, \qquad A^\top A = I.$$

Definimos $\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_p)$. Entonces

$$\boxed{\boldsymbol{\Sigma} = A \Lambda A^\top.}$$

- Las columnas de A indican las direcciones principales.
- Los valores de Λ indican la varianza en cada dirección.

La rotación en forma matricial

Si centramos el vector aleatorio, $\mathbf{X}_c = \mathbf{X} - \boldsymbol{\mu}$, las componentes se escriben como

$$\boxed{\mathbf{Y} = A^\top \mathbf{X}_c.}$$

Su matriz de covarianzas es

$$\mathrm{Cov}(\mathbf{Y}) = A^\top \boldsymbol{\Sigma} A = \Lambda.$$

Resultado fundamental

En las nuevas coordenadas, la matriz de covarianzas es **diagonal**: las componentes principales están incorrelacionadas.

Ejemplo numérico: dos variables

Supongamos que la matriz de covarianzas es

$$\boldsymbol{\Sigma} = \begin{pmatrix} 4 & 3 \\ 3 & 4 \end{pmatrix}.$$

Sus autovalores son

$$\lambda_1 = 7, \qquad \lambda_2 = 1,$$

con autovectores unitarios

$$\boldsymbol{a}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad \boldsymbol{a}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

Podemos verificar que $\boldsymbol{\Sigma}\boldsymbol{a}_1 = 7\boldsymbol{a}_1$ y $\boldsymbol{\Sigma}\boldsymbol{a}_2 = \boldsymbol{a}_2$.

Ejemplo numérico: interpretación

Las componentes son

$$Y_1 = \frac{X_1 - \mu_1 + X_2 - \mu_2}{\sqrt{2}}, \qquad Y_2 = \frac{X_1 - \mu_1 - (X_2 - \mu_2)}{\sqrt{2}}.$$

- Y_1 recoge variaciones conjuntas en la misma dirección.
- Y_2 recoge diferencias entre las dos variables.

$$\mathrm{Var}(Y_1) = 7, \qquad \mathrm{Var}(Y_2) = 1.$$

Pregunta

¿Cuál componente conservarías si solo pudieras representar cada observación con un número?

¿Cuánta varianza tenemos en total?

La varianza total de las variables originales es

$$\operatorname{tr}(\boldsymbol{\Sigma}) = \sum_{j=1}^{p} \operatorname{Var}(X_j).$$

Por la descomposición espectral,

$$\boxed{\sum_{j=1}^{p} \operatorname{Var}(X_j) = \sum_{k=1}^{p} \lambda_k = \sum_{k=1}^{p} \operatorname{Var}(Y_k).}$$

Conservar toda la información lineal

Si retenemos las p componentes, la transformación es una rotación/reflexión ortogonal y no pierde varianza total.

Proporción de varianza explicada (PVE)

La fracción de la varianza total que explica la componente k es

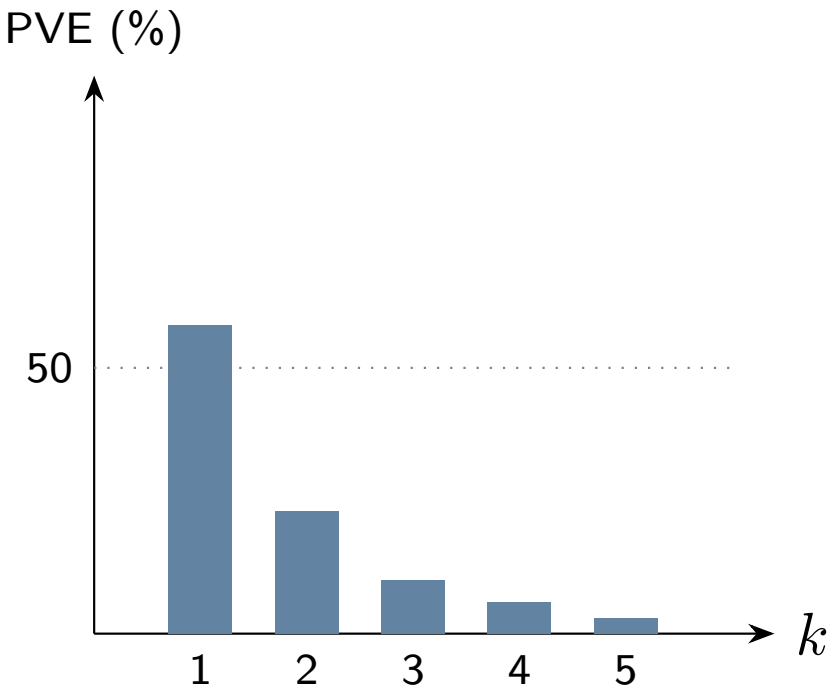
$$\boxed{\mathrm{PVE}_k = \frac{\lambda_k}{\lambda_1 + \cdots + \lambda_p}.}$$

La varianza acumulada explicada por las primeras q componentes es

$$\boxed{\mathrm{PVE}_{\mathrm{acum}}(q) = \frac{\sum_{k=1}^{q} \lambda_k}{\sum_{k=1}^{p} \lambda_k}.}$$

Ejemplo anterior: $\mathrm{PVE}_1 = 7/8 = 87.5\%$ y $\mathrm{PVE}_2 = 1/8 = 12.5\%$.

Elegir cuántas componentes conservar



- Examinar la varianza explicada y la acumulada.
- Buscar un "codo" en el gráfico de sedimentación.
- Considerar la interpretación y el propósito del análisis.

Precaución

No existe un umbral universal (80%, 90%, etc.) que garantice que las componentes conservadas sean suficientes para cualquier objetivo.

Puntuaciones y direcciones: dos objetos distintos

Sea $X_c \in \mathbb{R}^{n \times p}$ la matriz centrada y $A_q \in \mathbb{R}^{p \times q}$ los primeros q autovectores.

$$\boxed{T_q = X_c A_q \in \mathbb{R}^{n \times q}.}$$

- **Cargas o coeficientes** (*loadings*): entradas de los autovectores en A_q; describen las direcciones.
- **Puntuaciones** (*scores*): filas de T_q; son las coordenadas de las observaciones en los nuevos ejes.

Distinción

Una componente principal es una variable nueva; una puntuación es su valor para una observación concreta.

¿Cómo interpretamos los coeficientes?

Si $\mathbf{a}_1 = (0.50, 0.55, 0.45, 0.49)^\top$, la primera componente combina las cuatro variables con coeficientes positivos.

- Un coeficiente grande en valor absoluto indica un mayor peso en la combinación lineal.
- El signo indica cómo participa cada variable en la componente. Sin embargo, el **signo global del autovector es arbitrario**.
- La interpretación de los coeficientes depende de las unidades y escalas de las variables originales.

Importante

Los coeficientes deben interpretarse considerando si las variables fueron únicamente centradas o también estandarizadas.

Correlación entre variables y componentes

Para PCA sobre covarianzas, con $Y_k = \boldsymbol{a}_k^\top (\mathbf{X} - \boldsymbol{\mu})$, se cumple

$$\mathrm{Cov}(X_j, Y_k) = \lambda_k a_{jk}.$$

Por tanto,

$$\boxed{\mathrm{Corr}(X_j, Y_k) = \frac{a_{jk}\sqrt{\lambda_k}}{\sigma_j}.}$$

Cuidado al interpretar

El coeficiente a_{jk} y la correlación $\mathrm{Corr}(X_j, Y_k)$ **no son exactamente lo mismo**. Una correlación alta es una asociación marginal con la componente, no una prueba de importancia causal.

¿PCA con covarianzas o con correlaciones?

Matriz de covarianzas S

Se centra cada variable y se conserva su escala original.

- Variables en unidades comparables.
- Importa preservar diferencias de variabilidad.

Matriz de correlaciones R

Se centra y estandariza cada variable.

- Variables en unidades o escalas distintas.
- Cada variable aporta varianza inicial igual a 1.

Ejemplo: masa corporal en gramos frente a longitud de aleta en milímetros.

Estandarización: definición

Para una variable poblacional X_j con desviación estándar $\sigma_j > 0$:

$$Z_j = \frac{X_j - \mu_j}{\sigma_j}.$$

En forma matricial, si $D = \operatorname{diag}(\sigma_1, \ldots, \sigma_p)$,

$$\boxed{\mathbf{Z} = D^{-1}(\mathbf{X} - \boldsymbol{\mu}).}$$

Entonces

$$\mathbb{E}(\mathbf{Z}) = \mathbf{0}, \qquad \operatorname{Cov}(\mathbf{Z}) = D^{-1}\boldsymbol{\Sigma}D^{-1} = R.$$

PCA sobre variables estandarizadas

Si $R\mathbf{b}_k = \eta_k \mathbf{b}_k$ y $\|\mathbf{b}_k\| = 1$, las componentes son

$$\boxed{W_k = \mathbf{b}_k^\top \mathbf{Z}.}$$

Sus varianzas son $\mathrm{Var}(W_k) = \eta_k$.

- Los autovalores y autovectores de R **pueden ser diferentes** de los de $\boldsymbol{\Sigma}$.
- No estamos simplemente cambiando la unidad de presentación: puede cambiar la orientación de los ejes principales.

Varianza total al usar correlaciones

Como cada variable estandarizada tiene varianza 1,

$$\operatorname{tr}(R) = \sum_{j=1}^{p} \operatorname{Var}(Z_j) = p.$$

Por tanto,

$$\eta_1 + \cdots + \eta_p = p, \qquad \boxed{\mathrm{PVE}_k = \frac{\eta_k}{p}.}$$

Ejemplo

Si $p = 4$ y los autovalores son $2.8, 0.8, 0.3, 0.1$, las dos primeras componentes explican $(2.8 + 0.8)/4 = 90\%$.

Ejemplo: por qué importa la escala

Supongamos dos variables independientes con

$$\boldsymbol{\Sigma} = \begin{pmatrix} 10000 & 0 \\ 0 & 1 \end{pmatrix}.$$

- PCA con covarianzas: la primera dirección coincide con X_1 y explica $10000/10001$ de la varianza.
- Tras estandarizar, $R = I$: ambas variables tienen la misma varianza y **no hay una primera dirección única**.

Mensaje

La escala puede determinar qué estructura se considera "importante". Estandarizar es una decisión sustantiva, no un paso automático.

Proyección y reducción de dimensionalidad

Si conservamos solo $q < p$ componentes,

$$T_q = X_c A_q.$$

Cada fila de T_q representa una observación en $\mathbb{R}^q$.

Objetivo

Conservar las direcciones que acumulan mayor varianza para visualizar, resumir o construir una representación de menor dimensión.

Pero: alta varianza no significa necesariamente alta capacidad para separar categorías conocidas.

Reconstrucción aproximada

A partir de las primeras q componentes, reconstruimos las observaciones centradas como

$$\boxed{\widehat{X}_c = T_q A_q^\top = X_c A_q A_q^\top.}$$

Y recuperamos las medias:

$$\widehat{X} = \widehat{X}_c + \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

- Con $q = p$ se recuperan exactamente los datos centrados.
- Con $q < p$ existe una pérdida de información.

PCA y la descomposición en valores singulares

Para la matriz de datos centrados,

$$X_c = U\,D\,V^\top \qquad \text{(SVD)}.$$

Entonces

$$S = \frac{1}{n-1} X_c^\top X_c = V \frac{D^2}{n-1} V^\top.$$

- Las columnas de V son direcciones principales.
- Los autovalores son $\widehat{\lambda}_k = d_k^2/(n-1)$.
- Las puntuaciones son $T = X_c V = UD$.

¿Cuántas componentes conservar? Scree plot

Una herramienta para seleccionar el número de componentes es la **gráfica de sedimentación** o *scree plot*.

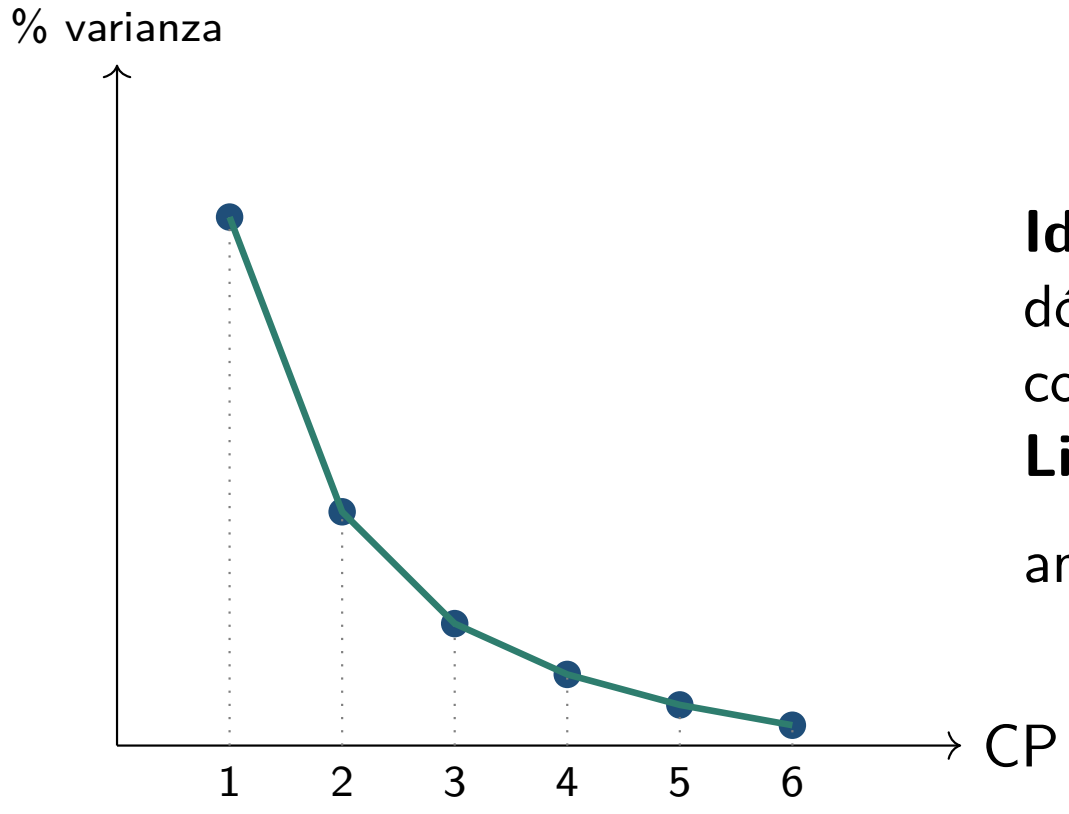
- Representa los autovalores η_k, o los porcentajes de varianza explicada, frente al número de componente.
- Permite identificar cuáles componentes aportan mayor variabilidad.
- Se busca, cuando existe, un cambio notable de pendiente conocido como **criterio del codo**.

Interpretación

Después del codo, las componentes adicionales aportan cantidades relativamente pequeñas de varianza.

Precaución: no siempre existe un codo claro y este criterio no garantiza que las componentes seleccionadas sean suficientes.

Gráfica de sedimentación: scree plot



Idea del "codo": buscar dónde la ganancia adicional comienza a disminuir.
Limitación: el codo puede ser ambiguo o no existir.

Criterios para seleccionar componentes

No existe un número universal de componentes que debamos conservar.

Podemos considerar distintos criterios:

1. **Varianza acumulada:** conservar las primeras q componentes que expliquen una proporción deseada de la varianza total.

2. **Scree plot:** identificar un posible cambio de pendiente.

3. **Interpretabilidad:** analizar si las componentes representan patrones relevantes de las variables originales.

4. **Objetivo del análisis:** considerar si buscamos visualizar, comprimir información o utilizar las componentes en otro modelo.

No hay una regla

Importante

Conservar el 80% o 90% de la varianza puede ser un criterio orientativo, pero no garantiza que conservemos toda la información relevante.

¿Cómo se visualizan los resultados?

Gráfica de puntuaciones

Cada punto es una **observación**, colocada según sus valores de CP1 y CP2.

Permite explorar proximidad, tendencias y observaciones atípicas.

Gráfica de cargas

Cada vector o coordenada representa una **variable original** en relación con las componentes.

Ayuda a interpretar qué variables contribuyen a las direcciones.

Advertencia

Un biplot combina ambas representaciones, pero su interpretación depende del escalamiento elegido.

Visualización de las observaciones: scores

Después de aplicar PCA, cada observación tiene nuevas coordenadas sobre los ejes principales.

Si conservamos dos componentes, la observación i queda representada por (t_{i1}, t_{i2}).

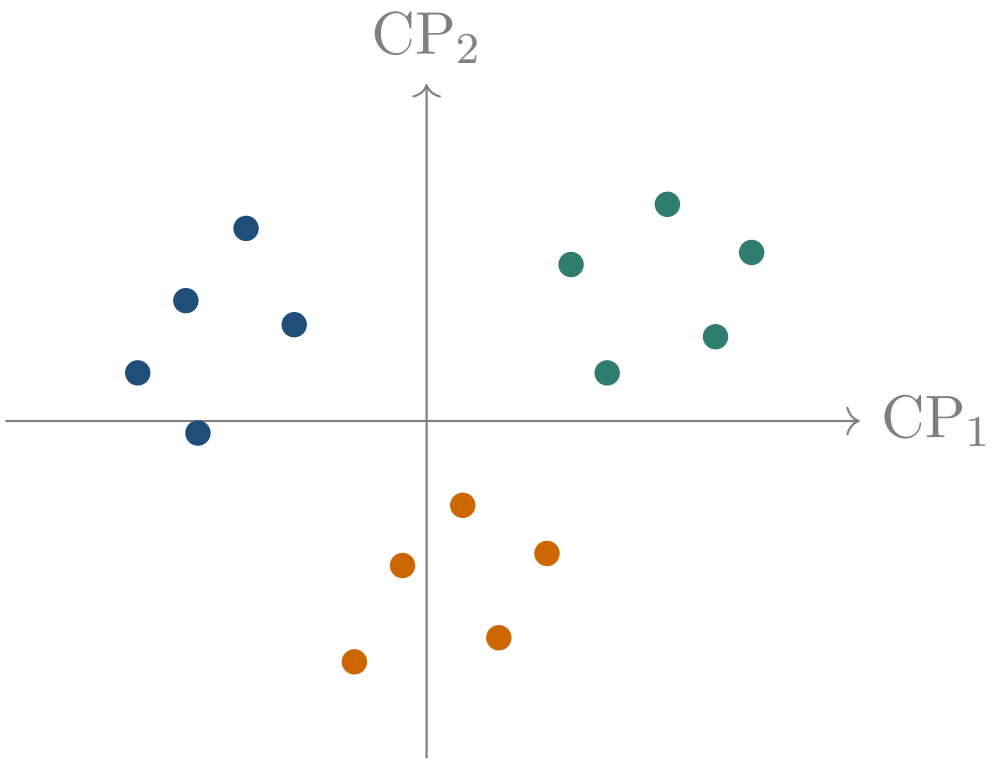
Gráfico de puntuaciones

Un *score plot* representa las observaciones utilizando sus puntuaciones en las componentes principales seleccionadas.

- Cada punto representa una observación.
- Los ejes corresponden a componentes principales.
- Podemos identificar patrones, tendencias, observaciones atípicas y posibles agrupamientos.

Precaución: dos observaciones cercanas en el gráfico pueden diferir en componentes que no estamos representando.

¿Cómo se ve un gráfico de scores?



Cada punto es una **observación**, ubicada según sus scores en las dos primeras componentes. Podemos

examinar tendencias, dispersión, atípicos y posibles agrupamientos.

Biplot: observaciones y variables

Un **biplot** permite representar simultáneamente las observaciones y las variables originales en un espacio de componentes principales.

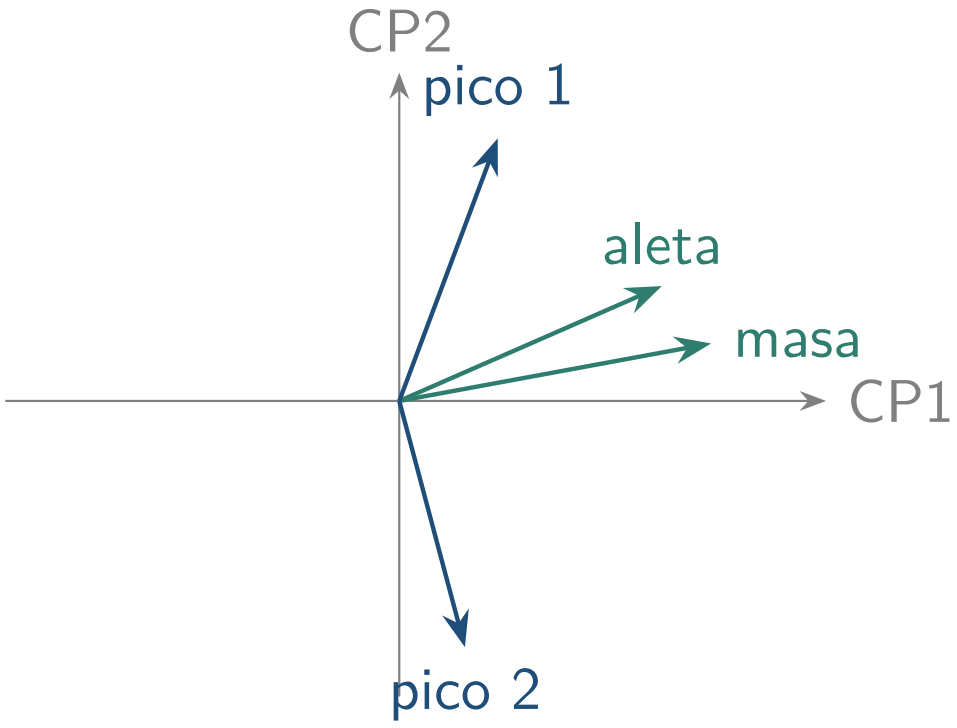
- **Puntos:** representan las observaciones mediante sus puntuaciones (*scores*).
- **Flechas:** representan las variables originales mediante coordenadas asociadas a las componentes principales.

¿Qué podemos interpretar?

- La distribución de las observaciones.
- Las variables asociadas a las componentes.
- Las relaciones aproximadas entre variables.
- Las variables relacionadas con ciertas direcciones de variación de los datos.

Nota: la interpretación geométrica depende del escalamiento utilizado para representar puntos y flechas.

¿Cómo se ve un gráfico de cargas?



Cada flecha representa una **variable** mediante dos coordenadas asociadas a las componentes. La

interpretación depende de si se grafican coeficientes v_{jk} o correlaciones $\mathrm{Corr}(X_j, Y_k)$.

¿Cómo interpretamos las flechas de un biplot?

Cuando las flechas representan correlaciones entre las variables originales estandarizadas y las componentes principales:

- **Direcciones similares:** sugieren una correlación positiva entre las variables.
- **Direcciones opuestas:** sugieren una correlación negativa.
- **Direcciones aproximadamente perpendiculares:** sugieren poca correlación lineal.
- **Longitud de las flechas:** indica qué tan bien se representa una variable en el plano seleccionado.

Precaución

Estas interpretaciones son aproximadas y dependen de qué tan bien estén representadas las variables en las componentes seleccionadas.

Limitaciones de PCA

Aunque PCA es una herramienta útil para reducir dimensionalidad, tiene algunas limitaciones.

- Es un método **lineal**: puede no representar adecuadamente estructuras no lineales.
- Es sensible a **valores atípicos**, que pueden modificar las direcciones principales.
- Sus resultados dependen del **centrado y la estandarización**.
- Maximizar la varianza no garantiza conservar la información más relevante para un problema particular.
- Las componentes son incorrelacionadas, pero no necesariamente independientes.
- Las puntuaciones deben interpretarse junto con las cargas y la varianza explicada.

Limitaciones y decisiones metodológicas

PCA no es un método de agrupamiento

PCA encuentra direcciones de máxima varianza, pero no asigna observaciones a grupos.

Puede utilizarse para visualizar agrupamientos, aunque la mayor variabilidad no necesariamente coincide con la mejor separación entre grupos.

Ejercicio de comprensión: sin hacer cuentas largas

Supongamos que tres variables estandarizadas producen autovalores

$$\eta_1 = 2.1, \qquad \eta_2 = 0.7, \qquad \eta_3 = 0.2.$$

1. ¿Cuánta varianza total existe antes de aplicar PCA?
2. ¿Qué porcentaje explica la primera componente?
3. ¿Qué porcentaje acumulan las primeras dos?
4. ¿Es correcto afirmar que conservar dos componentes siempre es suficiente? Justifica.

Solución

1. **Varianza total:**

$$\eta_1 + \eta_2 + \eta_3 = 2.1 + 0.7 + 0.2 = \boxed{3}.$$

2. **Varianza explicada por la primera CP:**

$$\frac{2.1}{3} \times 100 = \boxed{70\%}.$$

3. **Varianza acumulada por las primeras dos CP:**

$$\frac{2.1 + 0.7}{3} \times 100 = \boxed{93.33\%}.$$

4. **¿Siempre es suficiente conservar dos CP?**

   No necesariamente. Depende del objetivo del análisis y de cuánta información estemos dispuestos a perder.

   En este ejemplo, conservar dos componentes permite retener el 93.33% de la varianza total.

Resumen de PCA

1. Partir de la matriz de datos X.
2. Centrar o estandarizar las variables.
3. Calcular la matriz de covarianzas S o de correlaciones R.
4. Obtener los autovalores y autovectores.
5. Proyectar los datos sobre las primeras q componentes:

$$T_q = X_c A_q.$$

PCA

PCA construye ejes ortogonales que maximizan sucesivamente la varianza. Los autovectores definen las direcciones; los autovalores cuantifican su variabilidad; las puntuaciones ubican las observaciones.