Reducción de dimensionalidad no lineal: t-SNE y UMAP

Temas Selectos de Aprendizaje de Máquina
Semestre 2027-1

Adriana Haydeé Contreras Peruyero
Escuela Nacional de Estudios Superiores Unidad Juriquilla, UNAM
haydeeperuyero@unam.mx



Más allá de PCA: reducción no lineal

Hasta ahora hemos estudiado PCA, que construye nuevas variables mediante combinaciones lineales de las variables originales. Sin

embargo, los datos pueden presentar estructuras que no se describen adecuadamente mediante proyecciones lineales.

Pregunta

¿Qué ocurre si las observaciones se distribuyen sobre una estructura curva o una superficie de menor dimensión?

- PCA busca direcciones de máxima varianza.
- Los métodos no lineales pueden representar relaciones más complejas entre observaciones.
- Dos métodos importantes son **t-SNE** y **UMAP**.

Estructura local y global de los datos

Al reducir la dimensionalidad, podemos intentar preservar diferentes características de los datos.

Estructura local

Describe las relaciones entre observaciones cercanas, es decir, sus vecindades.

Estructura global

Describe relaciones a mayor escala, como la disposición relativa de regiones o grupos de observaciones.

- Preservar ambas estructuras simultáneamente puede ser difícil.
- Distintos métodos priorizan diferentes aspectos de los datos.

Idea: una representación en dos dimensiones no necesariamente conserva todas las relaciones del espacio original.

t-SNE: intuición

t-SNE significa *t-distributed Stochastic Neighbor Embedding*. Es un método de reducción de dimensionalidad no lineal, utilizado principalmente para visualizar datos en dos o tres dimensiones.

Idea principal

Construir una representación donde las observaciones que son vecinas en el espacio original tiendan a permanecer cercanas.

- Representa relaciones de vecindad mediante probabilidades.
- Busca que dichas relaciones sean similares en el espacio reducido.
- Prioriza la preservación de la estructura local.

t-SNE: comparación de similitudes

t-SNE construye dos distribuciones de similitud:

- p_{ij}: similitud entre las observaciones i y j en el espacio original.
- q_{ij}: similitud entre sus representaciones en el espacio reducido.

El método busca minimizar la divergencia de Kullback–Leibler:

$$\boxed{C = \sum_{i \neq j} p_{ij} \log \left(\frac{p_{ij}}{q_{ij}} \right)}$$

t-SNE: interpretación

Interpretación

La optimización intenta que las observaciones consideradas muy similares en el espacio original también lo sean en la representación reducida.

La distribución t utilizada en el espacio reducido ayuda a evitar que demasiadas observaciones se concentren en una región pequeña.

UMAP: intuición

UMAP significa *Uniform Manifold Approximation and Projection*. Es un método no lineal que construye una representación de menor dimensión a partir de relaciones de vecindad.

Idea principal

Representar las relaciones entre observaciones mediante una estructura de vecinos y buscar una representación reducida que conserve dichas relaciones.

- Construye una representación ponderada de las vecindades.
- Optimiza las posiciones de los puntos en el espacio reducido.
- Puede preservar parte de la estructura global, aunque no garantiza conservarla.

UMAP: construcción de la representación

De manera simplificada, UMAP sigue tres etapas:

1. **Identificar vecinos:** para cada observación, encuentra un conjunto de observaciones cercanas.

2. **Construir relaciones ponderadas:** asigna pesos que representan la intensidad de las relaciones de vecindad.

3. **Optimizar la representación:** busca coordenadas en el espacio reducido que reproduzcan aproximadamente esas relaciones.

Interpretación

UMAP intenta conservar la estructura de vecindades mediante una representación de baja dimensión.

Parámetros importantes de t-SNE y UMAP

Los resultados dependen de los parámetros elegidos.

t-SNE: perplexity

Controla aproximadamente la escala de las vecindades consideradas.

- Valores menores enfatizan vecindades pequeñas.
- Valores mayores consideran relaciones en escalas más amplias.

UMAP: n_neighbors y min_dist

- `n_neighbors`: controla la escala de las vecindades utilizadas.
- `min_dist`: regula qué tan compactamente pueden disponerse los puntos en la representación.

Importante: diferentes parámetros pueden producir visualizaciones distintas del mismo conjunto de datos.

Comparación: PCA, t-SNE y UMAP

	PCA	**t-SNE**	**UMAP**
Tipo	Lineal	No lineal	No lineal
Objetivo principal	Maximizar varianza	Preservar similitudes locales	Preservar relaciones de vecindad
Interpretación de ejes	Componentes lineales	Sin significado directo	Sin significado directo
Varianza explicada	Sí	No	No
Uso habitual	Reducción y visualización	Visualización	Visualización y representación

Idea fundamental

Ningún método es universalmente mejor. La elección depende de qué propiedades de los datos queremos conservar.

Precauciones al interpretar t-SNE y UMAP

Una visualización atractiva no necesariamente representa fielmente todas las relaciones del conjunto de datos.

- Los ejes no tienen una interpretación directa como en PCA.
- La separación visual entre grupos no demuestra que existan grupos naturales.
- Las distancias entre grupos alejados pueden no representar adecuadamente las distancias originales.
- Los resultados pueden cambiar al modificar parámetros o inicializaciones.
- La presencia de agrupamientos visuales no equivale a una clasificación validada.

Conclusión

t-SNE y UMAP son herramientas de exploración y visualización, no pruebas de que existan grupos bien definidos.

Ejercicio

Supongamos que aplicamos PCA, t-SNE y UMAP al mismo conjunto de datos. Observamos que:

- PCA muestra una nube de puntos con cierto solapamiento.
- t-SNE muestra tres regiones visualmente separadas.
- UMAP muestra dos regiones principales, una de ellas con subestructuras.

Preguntas:

1. ¿Podemos concluir que existen exactamente tres grupos?
2. ¿Por qué los métodos producen representaciones diferentes?
3. ¿Qué información adicional necesitaríamos para evaluar los grupos?