

INTRODUCCIÓN AL APRENDIZAJE DE MÁQUINA - REPASO

Adriana Haydeé Contreras Peruyero

*Escuela Nacional de Estudios Superiores Unidad Juriquilla,
UNAM
haydeeperuyero@unam.com*

Temas Selectos de Aprendizaje
de Máquina
Semestre 2027-1



ENES
JURIQUILLA

- 1 ¿Qué es y porqué usar ML?
- 2 Flujo de trabajo en aprendizaje automático
- 3 Tipos de aprendizaje: supervisado y no supervisado
- 4 Sobreajuste y subajuste
- 5 Compromiso sesgo-varianza
- 6 Preprocesamiento de datos
- 7 Ingeniería de variables
- 8 Escalamiento y normalización
- 9 Manejo de datos faltantes
- 10 Partición de datos en entrenamiento, validación y prueba
- 11 Métricas de desempeño para modelos de regresión y clasificación
- 12 Desbalance de clases

¿QUÉ ES Y PORQUÉ USAR ML?

¿Qué es el aprendizaje automático/máquina(ML)?

¿Qué es el aprendizaje automático/máquina(ML)?

Definición

El ML es la ciencia (arte) de programar computadoras de tal forma que puedan *aprender de los datos*.

¿Qué es el aprendizaje automático/máquina(ML)?

Definición

El ML es la ciencia (arte) de programar computadoras de tal forma que puedan *aprender de los datos*.

Un ejemplo es el filtro de spam de nuestros correos.

¿POR QUÉ USAR ML?

El enfoque tradicional: un filtro de spam

Consideremos cómo escribiríamos un filtro de spam usando técnicas de programación tradicionales:

El enfoque tradicional: un filtro de spam

Consideremos cómo escribiríamos un filtro de spam usando técnicas de programación tradicionales:

1) Primero observaríamos cómo es típicamente el spam. Notaríamos que ciertas palabras o frases (como “4U”, “tarjeta de crédito”, “gratis” y “increíble”) tienden a aparecer mucho en el asunto. También notaríamos patrones en el nombre del remitente, el cuerpo del correo y otras partes del mensaje.

El enfoque tradicional: pasos 2 y 3

- 2) Escribiríamos un algoritmo de detección para cada patrón notado, y el programa marcaría un correo como spam si detecta varios de esos patrones.
- 3) Probaríamos el programa y repetiríamos los pasos 1 y 2 hasta que funcionara lo suficientemente bien para lanzarlo.

El enfoque tradicional

TS_ML_2027-2/Diapositivas/Tema1/figuras/Fig1.png

El problema del enfoque tradicional

El problema del enfoque tradicional

Como el problema es difícil, el programa terminará convirtiéndose en una **larga lista de reglas complejas**, bastante difícil de mantener.

El juego del gato y el ratón

¿Qué pasa si los spammers notan que todos sus correos con “4U” son bloqueados? Podrían empezar a escribir “For U” en su lugar.

Un filtro tradicional tendría que actualizarse para detectar “For U”. Si los spammers siguen evadiendo el filtro, habría que **seguir escribiendo reglas nuevas para siempre**.

EL ENFOQUE DE APRENDIZAJE AUTOMÁTICO

El enfoque de Aprendizaje Automático

El enfoque de Aprendizaje Automático

Un filtro de spam basado en Aprendizaje Automático **aprende automáticamente** qué palabras y frases son buenas predictoras de spam, detectando patrones de palabras inusualmente frecuentes en los ejemplos de spam en comparación con los de correos legítimos (*ham*).

Ventajas

El programa resultante es mucho más **corto**, más **fácil de mantener**, y muy probablemente más **preciso**.

El enfoque de Aprendizaje Automático

TS_ML_2027-2/Diapositivas/Tema1/figuras/Fig2.png

Adaptación automática a los cambios

A diferencia del enfoque tradicional, un filtro de spam basado en Aprendizaje Automático **nota automáticamente** que “For U” se ha vuelto inusualmente frecuente en el spam marcado por los usuarios, y **empieza a marcarlo sin intervención humana**.

Adaptación automática a los cambios

TS_ML_2027-2/Diapositivas/Tema1/figuras/Fig3.png

PROBLEMAS COMPLEJOS Y SIN SOLUCIÓN
ALGORÍTMICA CONOCIDA

Cuando no existe un algoritmo conocido

Otra área donde el Aprendizaje Automático destaca es en problemas que son **demasiado complejos** para los enfoques tradicionales, o que **no tienen un algoritmo conocido**.

Ejemplo: reconocimiento de voz

Se quiere distinguir las palabras “uno” y “dos”. Se podría notar que “dos” comienza con un sonido agudo (“D”), y programar un algoritmo que mida la intensidad de sonidos agudos.

Pero esta técnica **no escala** a miles de palabras, habladas por millones de personas distintas, en ambientes ruidosos y en decenas de idiomas.

La mejor solución (hasta hoy): escribir un algoritmo que aprenda por sí mismo, a partir de muchas grabaciones de ejemplo de cada palabra.

EL APRENDIZAJE AUTOMÁTICO PUEDE AYUDARNOS A
APRENDER

El ML puede ayudar a los humanos a aprender

Los algoritmos de ML pueden **inspeccionarse** para ver qué han aprendido (aunque para algunos algoritmos esto puede ser complicado).

Por ejemplo, una vez entrenado con suficiente spam, un filtro puede inspeccionarse fácilmente para revelar la lista de palabras y combinaciones de palabras que considera los mejores predictores de spam.

Minería de datos

A veces esto revela **correlaciones inesperadas** o **nuevas tendencias**, llevando a una mejor comprensión del problema. Aplicar técnicas de ML para explorar grandes cantidades de datos y descubrir patrones no evidentes se llama *minería de datos* (*data mining*).

El ML puede ayudar a los humanos a aprender

TS_ML_2027-2/Diapositivas/Tema1/figuras/Fig4.png

En resumen: ¿cuándo usar Aprendizaje Automático?

El Aprendizaje Automático es útil para:

- **Problemas** cuyas soluciones existentes requieren mucho ajuste fino o largas listas de reglas: un algoritmo de ML puede simplificar el código y desempeñarse mejor que el enfoque tradicional.
- **Problemas complejos** para los que el enfoque tradicional no ofrece una buena solución: las mejores técnicas de ML quizás sí puedan encontrarla.
- **Entornos cambiantes**: un sistema de ML puede adaptarse a nuevos datos.
- **Obtener información** sobre problemas complejos y grandes cantidades de datos.

FLUJO DE TRABAJO EN APRENDIZAJE AUTOMÁTICO

¿Qué es el aprendizaje automático?

Definición

El aprendizaje automático (*machine learning*) es el estudio de algoritmos que estiman una función desconocida f a partir de datos, sin especificar explícitamente sus reglas.

Formalmente, suponemos que existe una relación

$$Y = f(X) + \varepsilon$$

donde:

- ▶ $X \in \mathbb{R}^p$: vector de variables predictoras
- ▶ Y : variable respuesta
- ▶ ε : error aleatorio, con $E[\varepsilon] = 0$, independiente de X

Objetivo

Objetivo

Construir una estimación $\hat{f}$ de f a partir de datos observados $\{(x_i, y_i)\}_{i=1}^n$, de forma que $\hat{f}(X)$ aproxime bien a Y para observaciones **no vistas**.

Etapas del flujo de trabajo (I)

Un proyecto de aprendizaje automático sigue un **ciclo iterativo**:

1. **Definición del problema:** regresión, clasificación, agrupamiento, etc.
2. **Recolección de datos:** bases de datos, sensores, encuestas; documentar procedencia y sesgos.
3. **Análisis exploratorio (EDA):** distribuciones, atípicos, correlaciones, calidad.
4. **Preprocesamiento:** limpieza, imputación, codificación, escalamiento.
5. **Partición de datos:** entrenamiento / validación / prueba.

Etapas del flujo de trabajo (II)

6. **Selección y entrenamiento del modelo:** elegir familia y ajustar parámetros.
7. **Ajuste de hiperparámetros:** validación cruzada.
8. **Evaluación:** desempeño en el conjunto de prueba (no usado antes).
9. **Interpretación y comunicación:** variables relevantes, equidad, limitaciones.
10. **Despliegue y monitoreo:** producción y vigilancia ante *data drift*.

Importante

El flujo **no es lineal**: los hallazgos del EDA o de la evaluación suelen forzar un regreso a etapas anteriores.

TIPOS DE APRENDIZAJE: SUPERVISADO Y NO SUPERVISADO

Tipos de aprendizaje

Los problemas se clasifican, en primera instancia, según la información disponible durante el entrenamiento.

Aprendizaje supervisado

Se dispone de pares (x_i, y_i) : cada observación tiene una etiqueta o respuesta conocida. El objetivo es aprender $\hat{f} : \mathbb{R}^p \rightarrow \mathcal{Y}$ que generalice bien.

- ▶ **Regresión:** Y cuantitativa continua (ej. precio de una vivienda).
- ▶ **Clasificación:** Y cualitativa/categorica (ej. spam o no).

Tipos de aprendizaje

Los problemas se clasifican, en primera instancia, según la información disponible durante el entrenamiento.

Aprendizaje supervisado

Se dispone de pares (x_i, y_i) : cada observación tiene una etiqueta o respuesta conocida. El objetivo es aprender $\hat{f} : \mathbb{R}^p \rightarrow \mathcal{Y}$ que generalice bien.

- ▶ **Regresión:** Y cuantitativa continua (ej. precio de una vivienda).
- ▶ **Clasificación:** Y cualitativa/categorica (ej. spam o no).

Aprendizaje no supervisado

Solo se dispone de X , sin respuesta Y . El objetivo: descubrir estructura latente (agrupamiento, asociación, reducción de dimensión).

- ▶ **Aprendizaje semi-supervisado:** una fracción pequeña de las observaciones tiene etiqueta y el resto no; se combinan ambos tipos de información. Ej: en reconocimiento de voz.
- ▶ **Aprendizaje por refuerzo:** un agente aprende una política de acción mediante recompensas al interactuar con un entorno. Ej: Vehículos autónomos.

(no se cubrirán en este curso)

Supervisado vs. no supervisado

Criterio	Supervisado	No supervisado
Datos	(X, Y) conocidos	Solo X
Objetivo	Predecir Y para nuevas X	Descubrir estructura en X
Ejemplos	Regresión lineal, árboles, SVM	k-medias, PCA, DB-SCAN
Evaluación	Comparar $\hat{y}$ contra y real	Métricas internas (silueta, inercia) o validación externa

SOBREAJUSTE Y SUBAJUSTE

Sobreajuste y subajuste

Sea $\hat{f}$ el modelo ajustado con un conjunto de entrenamiento.

- ▶ **Error de entrenamiento:** medido sobre las mismas observaciones usadas para ajustar el modelo.
- ▶ **Error de prueba (generalización):** error esperado sobre observaciones nuevas.

Sobreajuste y subajuste

Sea $\hat{f}$ el modelo ajustado con un conjunto de entrenamiento.

- ▶ **Error de entrenamiento:** medido sobre las mismas observaciones usadas para ajustar el modelo.
- ▶ **Error de prueba (generalización):** error esperado sobre observaciones nuevas.

Subajuste (*underfitting*)

El modelo es demasiado simple para capturar la estructura real de los datos. Error de entrenamiento **alto** y error de prueba **igualmente alto**.

Sobreajuste (*overfitting*)

El modelo es demasiado flexible y ajusta el ruido ε . Error de entrenamiento **muy bajo**, error de prueba **considerablemente más alto**.

Error vs. complejidad del modelo

- ▶ $\text{Err}_{\text{train}}$ decrece monótonamente al aumentar la complejidad.
- ▶ Err_{test} decrece al inicio, alcanza un mínimo, y luego aumenta.

Regla práctica

Elegir la complejidad donde Err_{test} es **mínimo**, no donde $\text{Err}_{\text{train}}$ es mínimo.

Esta es la razón fundamental por la que se requiere un conjunto de validación o de prueba independiente del entrenamiento, y por la cual existen las técnicas de regularización.

COMPROMISO SESGO-VARIANZA

Compromiso sesgo-varianza

Para $Y = f(X) + \varepsilon$, con $E[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$, y un punto fijo x_0 :

$$E[(Y - \hat{f}(x_0))^2] = (\text{Sesgo}[\hat{f}(x_0)])^2 + \text{Var}(\hat{f}(x_0)) + \sigma^2$$

donde:

$$\text{Sesgo}[\hat{f}(x_0)] = E[\hat{f}(x_0)] - f(x_0)$$

$$\text{Var}(\hat{f}(x_0)) = E[(\hat{f}(x_0) - E[\hat{f}(x_0)])^2]$$

La esperanza se toma sobre el conjunto de entrenamiento aleatorio usado para construir $\hat{f}$.

A $E[(Y - \hat{f}(x_0))^2]$ se le llama el MSE esperado del conjunto de prueba.

Interpretación

- ▶ **Sesgo**: error sistemático de aproximar un fenómeno complejo con un modelo más simple. Modelos poco flexibles $\Rightarrow$ sesgo alto.
- ▶ **Varianza**: cuánto cambiaría $\hat{f}$ con otro conjunto de entrenamiento. Modelos muy flexibles $\Rightarrow$ varianza alta.
- ▶ σ^2 : **error irreducible**, proviene del ruido inherente en Y ; no se elimina con ningún modelo.

Conclusión

Al aumentar la flexibilidad: el sesgo tiende a **disminuir** y la varianza tiende a **aumentar**.

Resumen

Si queremos minimizar el MSE esperado del conjunto de prueba, necesitamos un método de aprendizaje estadístico que simultáneamente alcance una varianza y sesgo bajos.

PREPROCESAMIENTO DE DATOS

Preprocesamiento de datos

Conjunto de transformaciones aplicadas a los datos crudos **antes** de ajustar un modelo, para asegurar que estén en forma adecuada, consistente y libre de problemas.

Actividades típicas:

- ▶ Limpieza de datos: errores de captura, duplicados, formatos (fechas, unidades).
- ▶ Detección y tratamiento de valores atípicos (*outliers*).
- ▶ Codificación de variables categóricas (one-hot, ordinal, *target encoding*).
- ▶ Escalamiento y normalización.
- ▶ Manejo de datos faltantes.

Advertencia importante

Principio general

Cualquier transformación que dependa de estadísticos de los datos (medias, desviaciones estándar, categorías observadas) debe ajustarse **exclusivamente con el conjunto de entrenamiento**, dentro de un esquema de validación cruzada o de partición train/test.

Esto evita la **fuga de información** hacia el conjunto de prueba.

INGENIERÍA DE VARIABLES

Definición

Construir nuevas variables predictoras a partir de las originales, para exponer más directamente la relación entre X y Y ante el modelo.

A diferencia del preprocesamiento (que corrige/adapta datos existentes), la ingeniería de variables **crea información nueva**.

Técnicas comunes:

- ▶ Transformaciones no lineales: log, raíz cuadrada, potencias.
- ▶ Interacciones: productos entre variables ($X_1 \cdot X_2$).
- ▶ Variables derivadas de fecha/hora.
- ▶ Agregaciones: estadísticos por grupo o ventana temporal.
- ▶ Discretización (*binning*).

ESCALAMIENTO Y NORMALIZACIÓN

Escalamiento y normalización

Muchos algoritmos son sensibles a la escala de las variables: métodos basados en distancias (k-NN, k-medias), descenso de gradiente (redes, regresión logística) y métodos regularizados (Ridge, Lasso).

Estandarización

$$z = \frac{x - \mu}{\sigma}$$

Se busca transformar a que la media sea 0 y la varianza 1. μ, σ (media y desv. estd.) estimados sobre el conjunto de entrenamiento.

Escalamiento y normalización

Normalización Min-Max

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Se busca que queden en un rango $[0, 1]$; sensible a valores atípicos.

Escalamiento robusto

$$x' = \frac{x - \text{mediana}(x)}{\text{RIQ}(x)}$$

Usa mediana y rango intercuartílico; menos sensible a atípicos.

MANEJO DE DATOS FALTANTES

Manejo de datos faltantes

El tratamiento adecuado depende **críticamente del mecanismo** que genera los datos faltantes, no solo de su proporción.

MCAR — *Missing Completely At Random*

La probabilidad de que un valor falte no depende de ningún valor. Escenario más benigno.

MAR — *Missing At Random*

Depende de otras variables observadas, no del valor faltante en sí.

MNAR — *Missing Not At Random*

Depende del propio valor faltante (ej. ingresos muy altos no reportados). El más difícil de tratar.

Buscar sobre los tres métodos de manejo de datos faltantes. Su formulación matemática, ejemplos concretos, como se puede lidiar con este problema.

Se discutirá en la clase del 18 de agosto.

- ▶ **Eliminación de filas** (*listwise deletion*): válida bajo MCAR y proporción pequeña; reduce muestra.
- ▶ **Imputación simple**: media, mediana o moda. Sencilla, pero distorsiona varianza y relaciones.
- ▶ **Imputación por modelo**: regresión, k-NN, o métodos iterativos (MICE).
- ▶ **Indicador de faltante**: variable binaria que indica si el valor fue imputado (relevante bajo MAR/MNAR).

PARTICIÓN DE DATOS EN ENTRENAMIENTO, VALIDACIÓN Y PRUEBA

Partición: entrenamiento, validación y prueba

Conjunto	Uso	Se usa para...
Entrenamiento	Ajustar los parámetros del modelo	Aprender $\hat{f}$
Validación	Elegir hiperparámetros y comparar modelos	Seleccionar entre alternativas
Prueba	Estimar el desempeño final, una sola vez	Reportar el error de generalización

Regla práctica: 60–80% para entrenamiento; el resto entre validación y prueba (depende del tamaño total de la muestra).

Validación cruzada (k-fold)

Con conjuntos de tamaño moderado, reservar una partición fija de validación desperdicia observaciones. La **validación cruzada de k particiones** divide el entrenamiento en k *folds*.

Para cada $j = 1, \dots, k$: se entrena con las $k - 1$ particiones restantes y se evalúa en la partición j , obteniendo Err_j . El error de validación cruzada se estima como:

$$CV(k) = \frac{1}{k} \sum_{j=1}^k \text{Err}_j$$

- ▶ Valores típicos: $k = 5$ o $k = 10$.
- ▶ Caso extremo $k = n$: validación cruzada dejando uno fuera (**LOOCV**, leave-one-out).

MÉTRICAS DE DESEMPEÑO PARA MODELOS DE REGRESIÓN Y CLASIFICACIÓN

Métricas para regresión (I)

Sea y_i el valor observado, $\hat{y}_i$ la predicción, n el número de observaciones.

Error cuadrático medio (MSE):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Raíz del error cuadrático medio (RMSE): $RMSE = \sqrt{MSE}$

(se expresa en las mismas unidades que Y , facilita su interpretación frente al MSE)

Error absoluto medio (MAE):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Penaliza los errores grandes de forma proporcional (no cuadrática); más robusto ante atípicos que el MSE.

Coeficiente de determinación (R^2):

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Mide la proporción de la varianza de Y explicada por el modelo, respecto a un modelo trivial que siempre predice la media $\bar{y}$.

- ▶ $R^2 = 1$: ajuste perfecto.
- ▶ $R^2 = 0$: desempeño igual al de predecir la media.
- ▶ Valores negativos son posibles y ocurren cuando el modelo es peor que predecir la media.

Matriz de confusión

	Predicho: Positivo		Predicho: Negativo
Real: Positivo	Verdadero Positivo (VP)		Falso Negativo (FN)
Real: Negativo	Falso Positivo (FP)		Verdadero Negativo (VN)

Métricas para clasificación: Exactitud

$$\text{Exactitud(accuracy)} = \frac{VP + VN}{VP + VN + FP + FN}$$

Nota

Engañosa cuando las clases están desbalanceadas. Un modelo que siempre predice la clase mayoritaria puede tener una exactitud alta sin ser útil.

Métricas para clasificación: Precisión

$$\text{Precisión} = \frac{VP}{VP + FP}$$

Nota

De todas las observaciones predichas como positivas, qué proporción realmente lo es. Relevante cuando el costo de un falso positivo es alto.

$$\text{Recall} = \frac{VP}{VP + FN}$$

Nota

De todas las observaciones que realmente son positivas, qué proporción fue detectada. Relevante cuando el costo de un falso negativo es alto (por ejemplo, en diagnóstico médico).

Puntaje F1 (media armónica):

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}$$

Nota

Es la media armónica entre precisión y recall; penaliza fuertemente el desbalance entre ambas, siendo útil como resumen único cuando ambas importan.

Curva ROC y AUC: tasa de verdaderos positivos vs. tasa de falsos positivos

$$\left[\frac{FP}{FP + VN} \right]$$

al variar el umbral.

- ▶ $AUC = 1$: separación perfecta.
- ▶ $AUC = 0.5$: no mejor que el azar.

DESBALANCE DE CLASES

Ocurre cuando la distribución de las clases en Y es muy dispareja (ej. detección de fraude: *fraude* $< 1\%$).

¿Por qué es problemático?

- ▶ Muchos algoritmos, al minimizar el error global, favorecen la clase mayoritaria.
- ▶ La exactitud deja de ser informativa: un modelo trivial en un problema 99%/1% logra 99% de exactitud sin utilidad práctica.

Estrategias de tratamiento

- ▶ **Sub-muestreo** (*undersampling*): reduce la clase mayoritaria; descarta información.
- ▶ **Sobre-muestreo** (*oversampling*): duplica u genera observaciones sintéticas. **SMOTE** interpola entre observaciones minoritarias vecinas.
- ▶ **Ponderación de clases**: penaliza más los errores en la clase minoritaria (`class_weight='balanced'`).
- ▶ **Ajuste del umbral de decisión**: en vez de 0.5, según el costo relativo de FP y FN.
- ▶ **Métricas apropiadas**: precisión, recall, F1 o AUC-PR en lugar de exactitud.